## **RayZ Working Soft**

首页

归档

标签

# Caffe中LMDB的使用

发表于 2015-05-25 | 分类于 academic | 2条评论

最近做实验,要用Caffe提取CNN特征。官方的 extract\_feature.bin 很好用,但是输出的特征是放在LMDB里的。以前嫌LMDB麻烦,一直都图方便直接用 ImageDataLayer 来读原始图像。这次绕不过去了,就顺便研究了一下Caffe对LMDB的使用,一些心得写下来和大家分享一下。提取特征的内容下一篇再写。

Caffe 中 DataLayer 默 认 的 数 据 格 式 是 LMDB 。 许 多 example 中 提 供 的 输 入 数 据 是 LMDB 格 式 。 使 用 extract\_features.bin提取特征时支持的输出格式之一也是LMDB。LMDB在Caffe的IO功能中有相当重要的地位。因此,搞明白如何存取Caffe的LMDB数据,对于我们使用Caffe是很有帮助的。

#### **LMDB**

Caffe使用LMDB来存放训练/测试用的数据集,以及使用网络提取出的feature(为了方便,以下还是统称数据集)。数据集的结构很简单,就是大量的矩阵/向量数据平铺开来。数据之间没有什么关联,数据内没有复杂的对象结构,就是向量和矩阵。既然数据并不复杂,Caffe就选择了LMDB这个简单的数据库来存放数据。

LMDB的全称是**Lightning Memory-Mapped Database**,闪电般的内存映射数据库。它文件结构简单,一个文件夹,里面一个数据文件,一个锁文件。数据随意复制,随意传输。它的访问简单,不需要运行单独的数据库管理进程,只要在访问数据的代码里引用LMDB库,访问时给文件路径即可。

图像数据集归根究底从图像文件而来。既然有ImageDataLayer可以直接读取图像文件,为什么还要用数据库来放数据集,增加读写的麻烦呢?我认为,Caffe引入数据库存放数据集,是为了减少IO开销。读取大量小文件的开销是非常大的,尤其是在机械硬盘上。LMDB的整个数据库放在一个文件里,避免了文件系统寻址的开销。LMDB使用内存映射的方式访问文件,使得文件内寻址的开销非常小,使用指针运算就能实现。数据库单文件还能减少数据集复制/传输过程的开销。一个几万,几十万文件的数据集,不管是直接复制,还是打包再解包,过程都无比漫长而痛苦。LMDB数据库只有一个文件,你的介质有多块,就能复制多快,不会因为文件多而慢如蜗牛。

### Caffe中的LMDB数据

接下来要介绍Caffe是如何使用LMDB存放数据的。

Caffe 中 的 LMDB 数 据 大 约 有 两 类 : 一 类 是 输 入 DataLayer 的 训 练 / 测 试 数 据 集 ; 另 一 类 则

是 extract\_feature 输出的特征数据。

#### Datum数据结构

首先需要注意的是,Caffe并不是把向量和矩阵直接放进数据库的,而是将数据通过<u>caffe.proto</u>里定义的一个 datum 类来封装。数据库里放的是一个个的 datum 序列化成的字符串。Datum的定义摘录如下:

```
1 message Datum {
2   optional int32 channels = 1;
3   optional int32 height = 2;
4   optional int32 width = 3;
5   // the actual image data, in bytes
6   optional bytes data = 4;
7   optional int32 label = 5;
8   // Optionally, the datum could also hold float data.
9   repeated float float_data = 6;
10   // If true data contains an encoded image that need to be decoded
11   optional bool encoded = 7 [default = false];
12 }
```

一个Datum有三个维度, channels, height ,和 width ,可以看做是少了num维度的 Blob 。存放数据的地方有两个: byte\_data 和 float\_data ,分别存放整数型和浮点型数据。图像数据一般是整形,放在 byte\_data 里,特征向量一般是浮点型,放在 float\_data 里。 label 存放数据的类别标签,是整数型。 encoded 标识数据是否需要被解码 (里面有可能放的是JPEG或者PNG之类经过编码的数据)。

Datum这个数据结构将数据和标签封装在一起,兼容整形和浮点型数据。经过Protobuf编译后,可以在Python和C++中都提供高效的访问。同时Protubuf还为它提供了序列化与反序列化的功能。存放进LMDB的就是 Datum 序列化生成的字符串。

#### Caffe中读写LMDB的代码

要想知道Caffe是如何使用LMDB的,最好的方法当然是去看Caffe的代码。Caffe中关于LMDB的代码有三类: 生成数据集、读取数据集、生成特征向量。接下来就分别针对三者进行分析。

#### 生成数据集

生成数据集的代码在examples,随数据集提供,比如MNIST。

首先, 创建访问LMDB所需的一些变量:

```
1 MDB_env *mdb_env;
2 MDB_dbi mdb_dbi;
3 MDB_val mdb_key, mdb_data;
4 MDB_txn *mdb_txn;
5 ...
```

mdb\_env 是整个数据库环境的句柄, mdb\_dbi 是环境中一个数据库的句柄, mdb\_key 和 mdb\_data 用来存放向数据库中输入数据的"值"。 mdb\_txn 是数据库事物操作的句柄,"txn"是"transaction"的缩写。

然后, 创建数据库环境, 创建并打开数据库:

```
5
     CHECK_EQ(mdb_env_create(&mdb_env), MDB_SUCCESS) << "mdb_env_create failed";</pre>
6
     CHECK_EQ(mdb_env_set_mapsize(mdb_env, 1099511627776), MDB_SUCCESS) // 1TB
7
         << "mdb_env_set_mapsize failed";
8
     CHECK_EQ(mdb_env_open(mdb_env, db_path, 0, 0664), MDB_SUCCESS)
9
         << "mdb_env_open failed";
10
     CHECK_EQ(mdb_txn_begin(mdb_env, NULL, 0, &mdb_txn), MDB_SUCCESS)
         << "mdb_txn_begin failed";
11
     CHECK_EQ(mdb_open(mdb_txn, NULL, 0, &mdb_dbi), MDB_SUCCESS)
12
         << "mdb_open failed. Does the lmdb already exist? ";</pre>
13
14 } else {
     LOG(FATAL) << "Unknown db backend" << db_backend;
15
16 }
```

第3行代码为数据库创建文件夹,如果文件夹已经存在,程序会报错退出。也就是说,程序不会覆盖已有的数据库。已有的数据库如果不要了,需要手动删除。第13行处创建并打开了一个数据库。需要注意的是,LMDB的一个环境中是可以有多个数据库的,数据库之间以名字区分。 mdb\_open()的第二个参数实际上就是数据库的名称(char \*)。当一个环境中只有一个数据库的时候,这个参数可以给 NULL。

最后,为每一个图像创建 Datum 对象,向对象内写入数据,然后将其序列化成字符串,将字符串放入数据库中:

```
1 Datum datum;
 2 datum.set_channels(1);
 3 datum.set_height(rows);
4 datum.set_width(cols);
5 for (int item_id = 0; item_id < num_items; ++item_id) {</pre>
     image_file.read(pixels, rows * cols);
 7
     label_file.read(&label, 1);
     datum.set_data(pixels, rows*cols);
datum.set_label(label);
 8
9
     snprintf(key_cstr, kMaxKeyLength, "%08d", item_id);
10
11
     datum.SerializeToString(&value);
12
     string keystr(key_cstr);
13
14
     // Put in db
     if (db_backend == "lmdb") { // lmdb
15
16
       mdb_data.mv_size = value.size();
17
       mdb_data.mv_data = reinterpret_cast<void*>(&value[0]);
18
       mdb_key.mv_size = keystr.size();
       mdb_key.mv_data = reinterpret_cast<void*>(&keystr[0]);
19
20
       CHECK_EQ(mdb_put(mdb_txn, mdb_dbi, &mdb_key, &mdb_data, 0), MDB_SUCCESS)
21
            << "mdb_put failed";
22
     } else {
23
       LOG(FATAL) << "Unknown db backend" << db_backend;
24
25
26
     if (++count % 1000 == 0) {
27
       // Commit txn
       if (db_backend == "lmdb") { // lmdb
28
29
          CHECK_EQ(mdb_txn_commit(mdb_txn), MDB_SUCCESS)
              << "mdb_txn_commit failed";
30
31
          CHECK_EQ(mdb_txn_begin(mdb_env, NULL, 0, &mdb_txn), MDB_SUCCESS)
32
              << "mdb_txn_begin failed";
       } else {
33
34
          LOG(FATAL) << "Unknown db backend" << db_backend;
35
36
     }
37 }
```

放入数据的Key是图像的编号,前面补0至8位。需要注意的是18至21行, MDB\_val 类型的 mdb\_data 和 mdb\_key 中存放的是数据来源的指针,以及数据的长度。第20行的 mdb\_put() 函数将数据存入数据库。每 隔1000个图像commit一次数据库。只有commit之后,数据才真正写入磁盘。

#### 读取数据集

Caffe中读取LMDB数据集的代码是 DataLayer ,用在网络的最下层,提供数据。 DataLayer 采用顺序遍历 的方式读取数据,不支持打乱数据顺序,只能随机跳过前若干个数据。

首先,在 DataLayer 的 DataLayerSetUp 方法中,打开数据库,并获取迭代器 cursor :

```
1 db_.reset(db::GetDB(this->layer_param_.data_param().backend()));
2 db_->Open(this->layer_param_.data_param().source(), db::READ);
3 cursor_.reset(db_->NewCursor());
```

然后,在每一次的数据预取时, InternalThreadEntry() 方法中,从数据库中读取字符串,反序列化为 Datum对象,再从Datum对象中取出数据:

```
1 Datum datum;
2 datum.ParseFromString(cursor_->value());
```

其中, cursor\_->value()获取序列化后的字符串。 datum.ParseFromString()方法对字符串进行反序 列化。

最后,要将 cursor\_向前推进:

```
1 cursor ->Next();
2 if (!cursor ->valid()) {
3
    DLOG(INFO) << "Restarting data prefetching from start."
        cursor_->SeekToFirst();
4
5 }
```

如果 cursor->valid( ) 返回false,说明数据库已经遍历到头,这时需要将 cursor\_ 重置回数据库开头。

不支持样本随机排序应该是 DataLayer 的致命弱点。如果数据库的key能够统一,其实可以通过对key随机枚 举的方式实现。

#caffe

#Imdb

论文阅读:《Language Models for Image Captioning:

< 用Caffe提取深度特征

The Quirks and What Works >>

#### 2条评论



#### NettyNio

博主,DataLayer读取Imdb的代码块不是很清楚啊,能再说说吗

2015年10月16日 回复 顶 参转发

#### 咫尺天涯





社交帐号登	登录: 微信 微博 QQ 人人 更多»	
7,	说点什么吧	
	Θ	发布

RayZ's Blog正在使用多说

© 2015 RayZ

由 <u>Hexo</u> 强力驱动 | 主题 - <u>NexT.Mist</u>