

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得安徽大学或其他教育机构的学位或证书而使用过的材料。与一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：尹稚芹

签字日期：2015 年 6 月 2 日

学位论文版权使用授权书

本学位论文作者完全了解安徽大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权安徽大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：尹稚芹

导师签名：

签字日期：2015 年 6 月 2 日

签字日期：

尹稚芹
2015 年 6 月 4 日

摘 要

多级离心泵是一种将机械能转化成输出液体动能的机械装置,其性能建模的准确性对机泵系统的耦合匹配效率有着直接影响。对于多级离心泵而言,目前还没有成熟的建模方法。伴随着计算机水平的迅猛发展, MATLAB 软件被广泛应用于未知模型的建立和预测。因此,本文基于 MATLAB 仿真平台,采用黑箱建模的方法对多级离心泵进行性能预测建模。

本文的主要研究工作如下:

1) 首先,简要介绍基于最小二乘法的曲线拟合原理,在此基础上采用实测数据分别得到多级离心泵的扬程、功率、效率与流量的关系,并利用 GUI 界面创建性能曲线拟合界面窗口。

2) 然后,以上述流量、扬程、效率数据作为输入量,功率作为输出量,建立多级离心泵的 BP 神经网络性能预测模型,并对预测结果进行分析。

3) 最后,采用遗传算法对上述模型进行优化。仿真对比实验证实:相较于上述的 BP 神经网络性能预测模型,经过遗传函数优化后的多级离心泵性能预测模型更加精确。

本论文的研究工作得到国家科技支撑计划课题“大型流体机械节能技术与应用”(2013BAF01B02)的资助。

关键词:离心泵性能预测、多级离心泵效率、BP 神经网络、遗传算法优化

Abstract

Multistage centrifugal pump is a mechanism that converts the mechanical energy into kinetic energy of the output liquid. The accuracy of predictive model directly affects the efficiency of the entire pump system. The consummate model for multistage centrifugal pump has not been formed. In recent years, with the development of computer technology, MATLAB software has been widely used in establishing and predicting the unknown model. In this paper, the black-box modeling method is proposed for the performance predictive modeling of multistage centrifugal pump. The main work of the paper is as follows:

1) The principle of least-squares curve fitting method was introduced, and the measured data was used to acquire the relation of head, power and flow in multistage centrifugal. In addition, the fitting curves visualization was created by the MATLAB GUI toolkit, based on the least squares method.

2) The prediction model based on BP neural network toolbox is formed using the data of flow, lift and efficiency as the input, the data of power as the output. The forecast results are also analyzed.

3) The genetic algorithm is used to optimize BP neural network algorithm. Compared to the BP neural network model of multistage centrifugal pump, the genetic algorithm optimization model is more accurate.

The work of the paper is supported by the national science and technology support Project of China “The research and application of large fluid mechanical energy-saving technology (2013BAF01B02)”.

Keywords: Centrifugal performance prediction; The efficiency of centrifugal pump; BP neural network; Genetic algorithm optimization

目录

摘要	I
Abstract.....	II
第一章 绪论	1
1.1 课题研究背景以及意义	1
1.2 多级离心泵性能预测建模的研究现状	2
1.3 MATLAB 仿真平台简介	4
1.4 本文的主要研究内容	4
第二章 基于最小二乘法的多级离心泵性能预测模型	6
2.1 最小二乘法拟合模型的基本原理	6
2.2 多级离心泵性能模型的可视界面设计 & 分析	9
2.2.1 GUI 设计工具简介	9
2.2.2 多级离心泵性能模型的 GUI 界面设计	11
2.2.3 性能模型拟合结果分析	12
2.3 本章小结	14
第三章 基于 BP 神经网络的多级离心泵性能预测模型	15
3.1 BP 神经网络的基本原理	15
3.2 基于 BP 神经网络工具箱的性能预测建模	22
3.2.1 建模机理	22
3.2.2 仿真结果分析	24
3.3 本章小结	26
第四章 基于遗传算法优化的多级离心泵性能预测模型	27
4.1 遗传算法的基本原理	27
4.1.1 遗传算法的构成要素	27
4.1.2 遗传算法的基本操作	28
4.2 遗传算法优化的 BP 神经网络预测建模	30

4.2.1 优化的基本原理及优化建模	30
4.2.2 仿真结果分析	33
4.3 本章小结	36
第五章 总结与展望	37
5.1 总结	37
5.2 展望	37
参考文献	38
致 谢	42

第一章 绪论

1.1 课题研究背景以及意义

多级离心泵是一类被普遍应用的通用流体传输机械,被广泛用于民用、工业、排污、消防和化工等领域^[1]。据统计,水泵消耗的电能总量将近占国家耗电总量的 20%,耗油总量约占 5%于国家耗油总量,是使用范围仅次于电机、被大规模应用的机械设备。

与此同时,现代社会的迅速发展使得很多领域对于多级离心泵功能性要求越来越高。而且从一定程度上看,水泵的性能越好,效率就会越高,维护工作也会相对较易。但是传统多级离心泵的规划设计一般借助于经验以及理论相结合的方法,即通过大量的计算,制造出测试样机,统计测试样机在各种工况点的运行性能。如果性能不满足,则需要重新设计并制造新的样机,因而导致整个过程周期长且设计成本较高。随着制造技术以及现代水泵研究理论的发展,传统设计方法的不足逐步得以解决。本文的设计方法就是利用计算机对多级离心泵的工作性能进行预测,并且在此基础上进行方案优化,满足用户需要,达到节能降耗的目的。

通常,我们利用电机向多级离心泵传输动力。通过大量调研,我们发现在实际运行中主要存在两种情况:1、如果提供动力源的拖动电机功率较大,多级离心泵的工况效率值就会很低,缺乏经济性。2、反之,作为动力源的拖动电机有用功率较小,就易产生电机超载或烧坏的后果。显而易见,原动机配置的是否适当直接影响多级离心泵的经济效益以及安全运行产生^[2]。本文要实现的电机与多级离心泵的耦合系统框图如图 1-1 所示,我们要实现的功能是使作为负载的多级离心泵可以在电机的拖动下高效运行。因此,要想提高机泵系统的功率以及效率,就要精确预测以及分析多级离心泵的工况模型的输出功率,使电机传输功率和拖动负载所需功率相互平衡,保证系统安全。因此,研究多级离心泵的性能预测模型具有十分重要的意义。

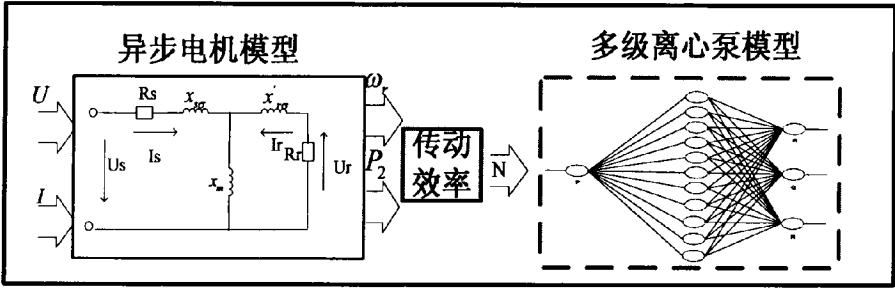


图 1-1 异步电机—多级离心泵耦合匹配模型示意图

Fig.1-1 The schematic of asynchronous motor - multistage centrifugal pump model

1.2 多级离心泵性能预测建模的研究现状

对于泵的性能预测模型，国内外的研究者做了很多的研究与实验，并且取得大量研究成果，总结起来可分为以下三类：一是流场分析法，二是水力损失法，三是神经网络法^[3]。

所谓流场分析法即建立内部流场特性与泵的外部特性之间的联系，此法是研究分析水泵的主要研究方向。该分析方法主要包括获得水泵内流场的特征以及建立外部特性与内部流场间的联系。对于泵内的流场特征，国内外的研究相对较多，其中包括：对水泵的叶轮、蜗壳以及压水室的内部流场进行三维数值模拟，以求能确保性能预测的精确度。对于内部流动是湍流的水泵而言，利用 CFD（计算流体力学）对湍流进行数据模拟是一个发展热点。湍流是一种在空间以及时间场内都是非线性的、没有秩序可言的流体运动。一般 CFD 中叙述湍流的基础方程是 N-S。基于 N-S 方程，根据不同的分析角度，关于湍流的数值模拟方法可归结为三种^[4]：第一种是直接数值模拟方法（DNS），第二种是雷诺时均法（RANS），第三种是大涡模拟（LES）。虽然直接数值模拟法是研究湍流原理的有效手段，可以获得湍流场的精确信息，但是受到计算资源、速度以及容量的限制，此方法在实际工况使用的不多。雷诺平均算法是根据已有的雷诺应力模型，简单的根据 RANS 方程算出湍流的量，由于其对计算机的性能要求较低，所以雷诺数范围内全部的工况问题都能解决。但是对不同种类的湍流，必须使用不一样的雷诺应力模型。而且对同一种类问题，如果边界允许条件范围不一样，也需改正模型常数。所以这种方法不能对涡旋的方向和大小进行分类、对漩涡的动力学问题分析不够周到，且不能分析流体的内部机理问题。湍流法是区别于上两种手段的一种数值

模拟方法,对比雷诺时均算法,大涡模拟能够模拟大尺度的湍流运动,其使用的湍流亚网格应力模型几乎不受边界的形状和流动类别的干扰,更具普遍的使用价值。分析小尺度的湍流时,计算容量小于 DNS,节省计算资源。但是其不足之处在于需要庞大的计算能力,且实际的湍流极为复杂,数值模拟需要非常多的计算时间,对计算机处理数据的能力要求较高。目前对三维湍流进行模拟计算的软件包括 FLUENT、FIDAP、STARCD 等。对于基于流场分析法创建的多级离心泵预测模型,其重点在于创建内部的流场特征和外特性之间的关系。至今国内外对这个问题的研究较少^[5-10]。利用数值模拟对水泵性能预测的好处是只需确定准确的水泵内、外特性之间的联系,预测精确度就会较高。用流场分析法来预测多级离心泵的模型是水泵未来发展的一个重要方向。

利用水力损失来预测水泵的性能模型,是使用较为广泛的一种方法。该方案首先研究水力模型损失的本质以及影响因子,找出水泵的结构和所有水力损失之间的相互联系,对流体做出条件假设,以简化水力的损失模型。水泵叶轮和抽水室以及压水室内中的水力损失^[11]构成了水泵水力损失的重要部分。对于多级离心泵而言,蜗壳就是压水室的主要形式,所以对于多级离心泵来说压水室内的损失就是指蜗壳的水力损失^[12]。其分析方法是采用一维方法计算蜗壳内的扩散段部分水力损失,采用二维或准三维的方法^[13]计算蜗壳螺旋段的水力损失。对于水力损失法而言,精确计算水力损失将会使预测精确度产生很大的变化。基于水力损失法能够考虑水泵内所有因素的作用,对于实际应用来说具有很高的精确性以及实用性。但是在应用时需要特定的水泵建立简化的水力损失模型,才能计算损失量,所以其计算步骤稍显复杂且不具普适性。

神经网络是由多个处理结构互相连接而形成的非线性网络,它是对人的大脑抽象以及简化模拟人脑的各种反应。神经网络涵盖了四个重要特点:一是具有自适应功能,二是具有泛化功能,三是非线性映射功能,四是神经网络的处理是高度并行的。所以人工神经网络可以化解很多繁琐问题。神经网络具有多种形式,有前馈网络和反馈网络。前馈神经网络中使用较多的是 BP 神经网络和 RBF 神经网络。本文采用的是 BP 神经网络, BP 神经网络是一个前馈型单向传播的多层次网络^[14]。利用 BP 神经网络预测多级离心泵的性能^[15],首先需要选取模型的参数来训练网络,然后再用少数优秀的模型参数来验证网络。如果训练误差在设定

的范围内,就可以继续对性能预测,否则要接着训练网络。利用 BP 神经网络进行预测多级离心泵的性能模型,具有映射能力强,训练后运行加速等优点。

1.3 MATLAB 仿真平台简介

MATLAB (矩阵实验室) 是 MATrix LABoratory 的缩写,是由美国 The MathWorks 公司出品的数学软件。MATLAB 含有较多的库函数,用户无需重复编程就能够调用并使用已有的库函数。

基于 MATLAB 中的 Simulink 仿真是用于仿真以及分析动态多变量系统的交互工具。它不仅能够调用软件自带的标准模型库,用户也能创建满足自己需求的模型库来模拟、描述、评价以及细分精确系统行为。Simulink 支持可视化的图形用户界面 (GUI),用户只需拖动图标操作就能够构造不同的仿真框图的搭建,且可以观察自然界存在的摩擦、风阻等非线性以及不可预测的因子对系统的影响,且可以改变待观察的参数,那么使用者就可以专注于编写算法和设计模块结构上。

作为一款功能强大的软件, MATLAB 还包含为用户提供一个可编程设计的图形用户界面 (GUI) [16-19]。GUI 是使用者和计算编写的程序的交流方式, GUI 是包含图形对象,包含图标栏、窗口、菜单栏以及编辑文本的用户可视界面。用户选取、点击这些对象就会产生动作,如设计图形或者实现程序的调用。GUI 的优点就是可以向别人演示或提供应用程序,进而实现复杂功能的界面。创建 GUI 的方式有两种:一是用 M 文件来创建,二是利用 GUIDE 向导完成 MATLAB 图形。利用 M 函数文件编写 GUI 是最基本的操作方法,因为用户利用他法实现 GUI 界面时,为了完成图形控件的各种不同的功能,也必须编写 M 代码来实现功能。利用 GUIDE 来实现 GUI 界面的优点是操作效率高,可以任意地对部件进行摆放布局,于此同时会生成 GUI 交互对应的两种格式的文件,即 FIG 文件以及 M 文件。其中 FIG 文件包括:对 GUI 图形窗口的图形对象的完整叙述以及所有有关对象的基本信息[20]。M 函数文件含有控制函数和 GUI 设计以及各子对象回调函数,其作用是使可视化操作界面能够实现不同的特性功能。

1.4 本文的主要研究内容

本文首先采用最小二乘法拟合得到多级离心泵的性能参数关系,并通过 GUI

工具建立多级离心泵的性能曲线界面，实现性能预测的可视化。然后根据已采集的实验样本数据，借助 BP 神经网络工具箱训练以及预测多级离心泵的模型。最后，利用遗传算法对 BP 神经网络模型进行优化。通过遗传算法优化后的结构与 BP 神经网络预测模型相比较，发现后者模型的预测性能更接近于实际工况。

论文的章节安排以及主要工作如下：

第一章介绍课题的研究意义以及研究背景，介绍当前泵性能预测建模的现状，比较了几种方法的优缺点。同时，简要介绍仿真平台——MATLAB 软件。

第二章采用最小二乘拟合曲线法，得到多级离心泵的扬程、功率、效率和流量的函数关系。利用 MATLAB 的 GUI 平台，将最小二乘法推导的曲线可视化，并与实测实验数据进行对比。

第三章基于 BP 神经网络具有非线性函数的拟合能力，利用工具箱对多级离心泵的性能预测模型进行黑箱建模，从而实现多级离心泵性能预测模型的输出。

第四章首先阐述遗传算法的基本原理以及优点，然后利用遗传算法对 BP 神经网络的预测模型进行优化，解决 BP 神经网络预测模型容易陷进局部最小值的缺点。最后，对比仿真结果可得到：通过遗传算法函数优化后的预测模型更加精确。

第五章对上述章节内容进行总结，并提出未来的研究方向。

第二章 基于最小二乘法的多级离心泵性能预测

2.1 最小二乘法拟合模型的基本原理

所谓曲线拟合就是将测量数据拟合为一条有律可循的曲线,对于所测量的数据点而言不一定都是在拟合的曲线上,只需要接近它们即可。保证实验样本点到经过拟合得到的曲线上点的距离的平方误差和最小,这就是最小二乘法曲线拟合的原理。最小二乘拟合逼近法的基本思想如下^[16-17]:

整体来说,对于给定的一组关于变量 x 和 y 的数据, $\{(x_i, y_i), i = 0, 1, 2, \dots, m\}$, 选定一组系数参数 $A = (a_0, a_1, \dots, a_n)$, 使得:

$$S = \sum_{i=1}^m \frac{1}{m} [P(x_i) - y_i]^2 \quad (2-1)$$

的值最小的多项式:

$$P(x) = \sum_{j=1}^n a_j x^j = a_0 + a_1 x + \dots a_n x^n \quad (2-2)$$

是数据变量 (x_i, y_i) 的经最小二乘法拟合的基本形式。所以基于最小二乘推导拟合方程曲线时, 第一步是建立拟合方程式 $P(x)$ 。

由函数的微分知识可知, 若要使平方差取值最小, 那么 a_k 需要满足

$$\frac{\partial S}{\partial a_k} = 0, \quad k = 0, 1, 2, \dots, n \quad (2-3)$$

则可以推导出:

$$\begin{aligned} \frac{\partial S}{\partial a_k} &= \frac{2}{m} \sum_{i=1}^m [P(x_i) - y_i] \frac{\partial P(x_i)}{\partial a_k} = \frac{2}{m} \sum_{i=1}^m [\sum_{j=0}^n a_j x_i^j - y_i] x_i^k \\ &= \frac{2}{m} \{ \sum_{j=0}^n a_j \sum_{i=1}^m x_i^{j+k} - \sum_{i=1}^m x_i^k y_i \} \end{aligned} \quad (2-4)$$

$$\text{设 } S_i = \sum_{i=1}^m y_i, \quad l_i = \sum_{i=1}^m x_i^j y_i$$

式 (2-4) 的结果为

$$\sum_{j=0}^m s_{j+k} a_j = l_k, k = 0, 1, \dots, n \quad (2-5)$$

将上式展开

$$\left(\sum_{i=1}^m x_i^k\right) a_0 + \left(\sum_{i=1}^m x_i^{k+1}\right) a_1 + \dots + \left(\sum_{i=1}^m x_i^{k+n}\right) a_n = \sum_{i=1}^m y_i x_i^k, k = 0, 1, \dots, n \quad (2-6)$$

展开得

$$\begin{bmatrix} m & \sum_{i=1}^m x_i & \dots & \sum_{i=1}^m x_i^n \\ \sum_{i=1}^m x_i & \sum_{i=1}^m x_i^2 & \dots & \sum_{i=1}^m x_i^{n+1} \\ \dots & \dots & \dots & \dots \\ \sum_{i=1}^m x_i^n & \sum_{i=1}^m x_i^{n+1} & \dots & \sum_{i=1}^m x_i^{2n} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \dots \\ a_n \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^m y_i \\ \sum_{i=1}^m x_i y_i \\ \dots \\ \sum_{i=1}^m x_i^n y_i \end{bmatrix} \quad (2-7)$$

式 (2-7) 是多项式的拟合方程。

其中

$$X = \begin{bmatrix} m & \sum_{i=1}^m x_i & \dots & \sum_{i=1}^m x_i^n \\ \sum_{i=1}^m x_i & \sum_{i=1}^m x_i^2 & \dots & \sum_{i=1}^m x_i^{n+1} \\ \dots & \dots & \dots & \dots \\ \sum_{i=1}^m x_i^n & \sum_{i=1}^m x_i^{n+1} & \dots & \sum_{i=1}^m x_i^{2n} \end{bmatrix}, P(x) = \begin{bmatrix} \sum_{i=1}^m y_i \\ \sum_{i=1}^m x_i y_i \\ \dots \\ \sum_{i=1}^m x_i^n y_i \end{bmatrix}, A = \begin{bmatrix} a_0 \\ a_1 \\ \dots \\ a_n \end{bmatrix}$$

有时为了提高对非线性结构模型拟合的精度, 需要对其进行多层次的拟合。

利用此方法拟合可以得到三条多级离心泵的性能曲线, 分别包括扬程—流量、功率—流量以及效率—流量曲线。下面我们采用资料数据, 利用系统辨识建立多级离心泵的数学模型。以多级离心泵的流量和扬程为例, 应用最小二乘法对性能曲线进行相关拟合。其中 P 为功率, H 为流量, Q 为扬程, n 为叶轮转速。

表 1 流量 (Q) —扬程 (H) 部分实测数据

Table 1 The measured data of Flow rate (Q)-Head (H)

i	1	2	3	4	5
$Q_i(\text{m}^3/\text{h})$	937.75	983.14	1067.71	1136.19	1177.13
$H_i(\text{Mpa})$	267.42	264.98	260.46	254.87	250.90

根据相似定律可知

$$\begin{cases} \frac{Q}{Q'} = \frac{n}{n'} \\ \frac{H}{H'} = \left(\frac{n}{n'}\right)^2 \\ \frac{P}{P'} = \left(\frac{n}{n'}\right)^3 \end{cases} \quad (2-8)$$

由上述关系可以得到泵的扬程与流量之间是二次方的关系，那么利用公式 (2-8) 对其进行拟合：

$$H(Q) = a_0 + a_1 Q + a_2 Q^2 \quad (2-9)$$

设 $A = [a_0, a_1, a_2]^T$ 是常数矩阵。

将表格中的数据代入(2-9)，可得到下式

$$\begin{bmatrix} 1 & 937.75 & 937.75^2 \\ 1 & 983.14 & 983.14^2 \\ 1 & 1067.71 & 1067.71^2 \\ 1 & 1136.19 & 1136.19^2 \\ 1 & 1177.13 & 1177.13^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 267.42 \\ 264.98 \\ 260.46 \\ 254.87 \\ 250.90 \end{bmatrix} \quad (2-10)$$

其中，令

$$A = \begin{bmatrix} 1 & 937.75 & 937.75^2 \\ 1 & 983.14 & 983.14^2 \\ 1 & 1067.71 & 1067.71^2 \\ 1 & 1136.19 & 1136.19^2 \\ 1 & 1177.13 & 1177.13^2 \end{bmatrix}, P = \begin{bmatrix} 267.42 \\ 264.98 \\ 260.46 \\ 254.87 \\ 250.90 \end{bmatrix} \quad (2-11)$$

那么对于待定系数 a_i 来说， $A^T A a = A^T P$ ，可以解得

$$\begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 214.84 \\ 1.725 \\ -1.89 \times 10^{-3} \end{bmatrix} \quad (2-12)$$

将数据代入式（2-9）可以得到扬程—流量拟合曲线的关系：

$$H(Q)=214.84+1.725Q-1.89\times10^{-3} \tag{2-13}$$

采用类似的处理方法，可以得到功率—流量拟合曲线的关系：

$$P(Q)=-2987+20.124Q-0.03416Q^2+2.054\times10^{-5}Q^3 \tag{2-14}$$

同理，效率—流量拟合曲线如下所示：

$$\eta(Q)=7.69\times10^{-2}-5.76\times10^{-7}(Q-1136.19)^2 \tag{2-15}$$

2.2 多级离心泵性能模型的可视界面设计及分析

2.2.1 GUI 设计工具简介

GUI 是用户与计算机的一种可视化交互方式。利用 GUI 编程，不仅需要编写内核数据程序，而且还需编写控制界面的程序。GUI 的前台界面是由一组交互组件构成的，在编辑界面可以通过直接点击的方式来激活这些按钮对象，以实现我们需要完成的界面窗口。然后通过编辑内部回调函数来完成前台界面按钮所要实现的动作与事件，完成预定的功能。

GUI 结构模块结构如图 2-1 所示：

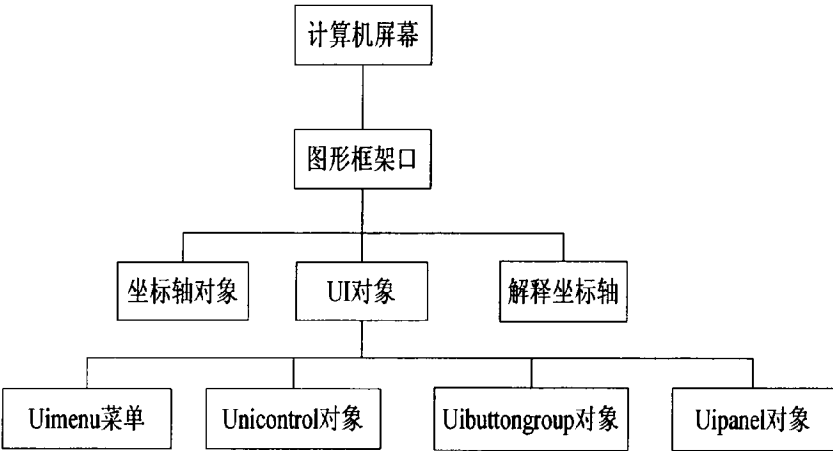


图 2-1 GUI 结构模块图

Fig.2-1 The structure module of GUI

软件的主界面是软件开始运行时候的界面，也就是进入最小二乘曲线拟合的子界面的接口。其中设计界面的方式有两种：使用 M 文件和使用 Guide 创建 GUI。

其中，通过编写 M 文件来创建函数，并设置前台界面的所有相关联组件的基本属性，需要较强的程序编写能力以及逻辑能力。而本文使用的 Guide 辅助设计则比较简单。首先我们需要创建空白的 Guide，然后在空白界面上根据所要实现的功能来拖放控件。接着再对控件进行编写回调函数和动作函数，就可以实现我们所需的功能窗口了。本文就是利用 Guide 辅助设计用户可视界面的方法：

1.完成 GUI 图形界面布局；

2.GUI 编写回调函数。

进行界面设计的首先启动 GUI，步骤为【File】-【New】-【GUI】、直接点击快捷图标、或者在命令行输入：guide，都可以启动一个 GUI 空白界面，如下图 2-2 所示：




图 2-2 空白 GUI 界面图

Fig.2-2 The blank interface map of GUI

如图 2-2 所示 GUI 的对象选择区包含了很多可供使用的 GUI 对象，从上至下依次为选择对象（Select），触控按钮（Push Button），滑动条（Slider），单选按钮（Radio Button），复选框（Check Box），可编辑文本（Edit Text），静态文本标签（Static Text），弹出式菜单（Pop-up Menu），列表框（Listbox），切换按钮（Toggle Button），表格（Table），坐标轴（Axes），面板（Panel），按钮组（Button Group），Active X 控件（Active X Control）。其中前 9 个是属于 uicontrol 对象，且与 Panel 和 Button Group 一起都是属于 UI 对象。Table、Axes 的作用是处理数据，使其对用户可视。Active X Control 是用来美观 MATLAB 界面。

2.2.2 多级离心泵性能模型的 GUI 界面设计

根据设计需要，首先添加一个列表框（Listbox），双击 Listbox，设置其属性，将字符高度（Font Size）属性设为 10。更改字符串属性（string），其属性从上至下依次为流量 Q、扬程 H、功率 P 和效率 η 。其中我们可以看出 value 的值分别对应上面的字符串，当 value 值为 1 时，对应第一个字符串，为 2 时，对应着第二个字符串，依次类推。接着增加三个触控按钮（Push Button），修改其字符串文本为“读入 x 轴参数”、“读入 y 轴参数”以及“绘制曲线按钮”，且其字符串大小设置为 10。添加两个文本框用来输入 x 轴参数和 y 轴参数，将其默认的字符串删除，并且设置字符的高度为 10。其作用是决定坐标系上输出的参数，点击触控按钮就会在文本框显示相应的参数^[14]。利用对齐图标按钮，将图中的按钮进行对齐设置。最后添加一个坐标轴对象，用来显示利用最小二乘拟合得到的曲线结果。完成编辑后的用户界面如下图 2-3 所示

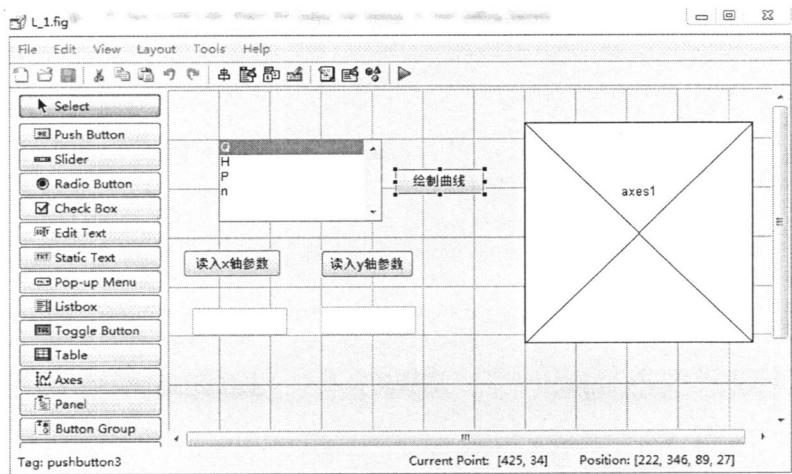


图 2-3 GUI 控制界面图

Fig.2-3 The control surface figure of GUI

然后编辑控件的回调函数（Callback），其步骤是点击鼠标右键按钮，选取【View Callbacks】--【Callback】。首先编辑 Push Button1 的回调函数：

```
selected_index=get(handles.listbox1,'value');  
%获取 listbox 的 value 值，获取被选中的参数；  
str=get(handles.listbox1,'string');  
%获取 listbox 的字符串；
```



```

set(handles.edit1,'string',str{selected_index})
%把获得的字符串显示在编辑文本框 edit1 中;
x=handles.CS{selected_index};
%得到获取的 x 轴参数对应的参数值;
handles.x=x;
%保存获取的参数值
guidata(hObject,handles)
%更新 handles 结构体;
同时对于“读入 y 轴的参数”的回调函数也是类似的方法;
对于“绘制曲线”的回调函数:
axes(handles.axes1); %将坐标系 1 设置为当前坐标系;
plot(handles.x,handles.y) %绘制曲线;
axis equal

```

在编辑 listbox 的回调函数时，需要定义四个参数以及算法的设置。

2.2.3 性能模型拟合结果分析

利用最小二乘法对数据曲线拟合，得到如下的界面。

选中 Listbox 中的流量 Q ，选择“读入 x 轴参数按钮”，在编辑文本框中就会显示流量 Q ，同样选中 Listbox 中的扬程 H ，点击“读入 y 轴参数”按钮，纵坐标的值就会是扬程 H 。其中根据相似定律，流量 Q 和扬程 H 呈二次关系，与经过最小二乘法拟合的曲线吻合。实际输出点与拟合曲线的对比如图 2-4 所示，说明利用最小二乘法拟合的预测结果与实际结果之间的误差较小。




图 2-4 扬程--流量曲线拟合图

Fig.2-4 The curve fitting diagram of head-flow

选中 Listbox 中的流量 Q，选择“读入 x 轴参数按钮”，在编辑文本框中就会显示流量 Q，接着选中 Listbox 中的功率 P，点击“读入 y 轴参数”的按钮，纵坐标的值就会是效率 P。根据离心泵叶轮的相似定律知道功率和流量是呈三次方关系，与经过最小二乘法拟合的曲线结果是一致的，如图 2-5 所示。实际输出结果与拟合结果之间几乎重合，说明利用最小二乘法拟合功率与流量的关系具有较高的实用价值。




图 2-5 功率--流量曲线拟合图

Fig.2-5 The curve fitting diagram of power-flow

选中 Listbox 中的流量 Q，选择“读入 x 轴参数按钮”那么在编辑文本框中就会显示流量 Q，接着选中 Listbox 中的效率 n，点击“读入 y 轴参数”的按钮，纵坐标的值就会是效率 η 。根据最小二乘法拟合的图像结果如图 2-6 所示，效率

与流量是二次函数关系式。结果显示在低效率点的拟合结果较精确，在高效率区域的拟合结果不理想。

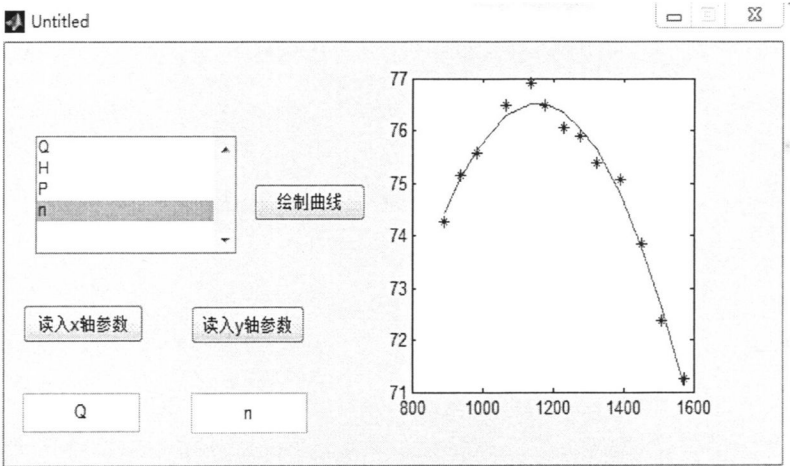


图 2-6 效率–流量曲线拟合图

Fig.2-6 The curve fitting diagram of efficiency-flow

由上述三图可以看出，利用最小二乘法拟合的多级离心泵性能曲线在一定程度上是可以满足性能分析的，但是在某些点的误差比较大。为了提高预测性能模型的精确度，本文在下一章拟利用 BP 神经网络的函数拟合能力对系统进行黑箱建模。

2.3 本章小结

本章利用最小二乘法拟合数据获得多级离心泵特性曲线的函数关系，更加方便分析多级离心泵的运行性能。同时，基于 MATLAB 的 GUI 界面平台进行编程，实现多级离心泵性能拟合曲线的可视化。

第三章 基于 BP 神经网络的多级离心泵性能预测模型

3.1 BP 神经网络的基本原理

BP 神经网络是一个多层次前馈网络，该网络包括输入节点、输出节点以及一至多层的隐含层节点，在同一层之间节点之间不存在耦合关系^[20-22]。经输入层节点输入，顺序地经过各隐含层节点，最终至输出节点输出。经过一层节点，其输出性能仅能作用于相邻下一层。其基本网络结构如图 3-1 所示。

神经元变换函数通常是 Sigmoid 函数、对数函数和线性函数。Sigmoid 函数能将输入的非线性系数放大，能够将输入的负无穷小信号变为正无穷大的信号，利用对数形式，将信号变为在区间[0,1]之间的输出信号。输入的信号若比较大，放大系数就会较小，利用 Sigmoid 函数就能最大程度逼近非线性的输入以及输出^[23]。其中 Sigmoid 函数的一般形式如下：

$$y = f(u) = \frac{1}{1 + e^{-u}} \quad (3-1)$$

此时 $f(u)$ 的形式可用导数形式表示：

$$f'(u) = f(u)[1 - f(u)] \quad (3-2)$$

在输出层中，线性函数是神经元的变换输出函数。可以看出 BP 神经网络为一个从输入到输出的非线性映射，那么 BP 神经网络对简易非线性函数多次复合，就能够逼近随机的复杂非线性函数^[24-26]。

BP 神经网络算法包括前向信号的传播和反向误差的传播。计算实际输出的方向是从输入节点到输出节点的前向传播，计算修正权值和阈值则就是从输出节点到输入节点的反向传播。其模型网络结构图如图 3-1 所示：




图 3-1 BP 神经网络结构讲解图

Fig.3-1 The structure of BP neural network

BP 算法的最终本质为求解误差函数，得到其最小值。此算法所使用的是非线性的梯度下降法，系数的修改方向是按照误差函数的负梯度方向^[22]。如图 3-1 所示为前馈网络图，节点间的传递函数为 Sigmoid 函数， net_i 、 O_i 分别为节点 i 的输入和输出。在输出层中第 k 节点的期望输出函数是 y_k ，那么节点 j 的输入就为：

$$net_j = \sum_i w_{ji} O_i \quad (3-3)$$

$$O_j = f(net_j) \quad (3-4)$$

$$net_k = \sum_j w_{kj} O_j \quad (3-5)$$

$$\hat{y}_k = O_k = f(net_k) \quad (3-6)$$

其中， \hat{y}_k 表示实际输出， $e_k = y_k - \hat{y}_k$ 表示误差信号方程。

输出层总共含 n 个神经元，其误差平方函数是：

$$E = \frac{1}{2} \sum_{k=1}^n (y_k - \hat{y}_k)^2 \quad (3-7)$$

BP 神经网络是按照误差函数的负梯度方向来对权值进行修改，那么权值可改写为：

$$w_{i+1} = w_i + \Delta w_i = w_i - \eta g_i (i \text{ 为迭代次数}) \quad (3-8)$$

$$g_i = \frac{\partial E}{\partial w} \Big|_{w=w_i} \quad (3-9)$$

用 Δw_{kj} 表示输出层神经元的权值修改量：

$$\Delta w_{kj} = -\eta \frac{\partial E}{\partial w_{kj}} \quad (3-10)$$

η 是学习速率，即表示步长。

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial e_k} \frac{\partial e_k}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial net_k} \frac{\partial net_k}{\partial w_{kj}} \quad (3-11)$$

$$= -e_k f'(net_k) O_j \quad (3-12)$$

由于此式表示输出层，那么 y_k 为常数，表示输出的期望值，由误差信号 e_k 的定义可知：

$$\frac{\partial E}{\partial e_k} = e_k \quad (3-13)$$

根据误差函数的定义可得：

$$\frac{\partial e_k}{\partial \hat{y}_k} = -1 \quad (3-14)$$

由式 (3-6) 得到：

$$\frac{\partial \hat{y}_k}{\partial net_k} = f'(net_k) \quad (3-15)$$

由公式 (3-5) 得到：

$$\frac{\partial net_k}{\partial w_{kj}} = O_j \quad (3-16)$$

那么最后可以得到：

$$\Delta w_{kj} = -\eta \frac{\partial E}{\partial w_{kj}} = \eta e_k f'(net_k) O_j \quad (3-17)$$

定义输出层的学习误差为 $\delta_k = e_k f'(net_k)$

那么式 (3-17) 可表示为：

$$\Delta w_{kj} = -\eta \frac{\partial E}{\partial w_{kj}} = \eta e_k f'(net_k) O_j = \eta \delta_k O_j \quad (3-18)$$

隐含层神经元权值的修改量为 Δw_{ji}

$$\Delta w_{ji} = -\eta \frac{\partial E}{\partial w_{ji}} \quad (3-19)$$

$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial e_k} \frac{\partial e_k}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial net_k} \frac{\partial net_k}{\partial O_j} \quad (3-20)$$

根据公式 (3-3) 和 (3-4) 可得到下式:

$$\frac{\partial E}{\partial O_j} = \frac{\partial E}{\partial e_k} \frac{\partial e_k}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial net_k} \frac{\partial net_k}{\partial O_j} \quad (3-21)$$

对于隐含层权值的变化需要考虑上一层对权值的影响。那么上式改为:

$$\begin{aligned} \frac{\partial E}{\partial O_j} &= \sum_{k=1}^m e_k \frac{\partial e_k}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial net_k} \frac{\partial net_k}{\partial O_j} \\ &= \sum_{k=1}^m e_k (-1) f'(net_k) \frac{\partial net_k}{\partial O_j} \end{aligned} \quad (3-22)$$

由公式 (3-5) 可知 $\frac{\partial net_k}{\partial O_j} = w_{kj}$

$$\text{那么 } \frac{\partial E}{\partial O_j} = - \sum_{k=1}^m e_k f'(net_k) w_{kj} \quad (3-23)$$

根据输出层的学习误差可得到:

$$\frac{\partial E}{\partial O_j} = - \sum_{k=1}^m e_k f'(net_k) w_{kj} = - \sum_{k=1}^m \delta_k w_{kj} \quad (3-24)$$

将式 (3-24) 与隐含层输出权值修改量代入 (3-19) 得到:

$$\begin{aligned} \Delta w_{ji} &= -\eta \frac{\partial E}{\partial O_j} f'(net_j) O_i \\ &= \eta \sum_{k=1}^m \delta_k w_{kj} f'(net_j) O_i \end{aligned} \quad (3-25)$$

另隐含层的学习误差

$$\delta_j = \sum_{k=1}^m \delta_k w_{kj} f'(net_j) \quad (3-26)$$

得到

$$\Delta w_{ji} = -\eta \frac{\partial E}{\partial w_{ji}} = \eta \delta_j O_i \quad (3-27)$$

根据上面得到的结果可以看出, BP 神经网络的误差反向传播实际是根据输出层的计算误差 e_k 与输出层的传递函数的导数的乘积来求得输出层的学习误差。

由于隐含层中没有目的矢量值，所以要根据输出层的神经元权值 w_{kj} 与输出层的学习误差 δ_k 以及隐含层传递函数的导数的乘积来求隐含层的学习误差 δ_j 。然后根据公式 (3-18) 以及 (3-27) 来求得输出层和隐含层的权值变化，最后再根据式 (3-8) 求得更新后的权值。

对于不同的给定的教师信号来训练 BP 神经网络时，需根据上述方法反复的修正连接权值，让训练矢量的误差平方和远远低于误差目标时停止训练。最后使得到的输出近似等于希望输出。BP 神经网络算法流程图如 3-2 所示，选择 ω 的初始值就是初始化过程，一般情况都会取零点左右的很小的随机数。

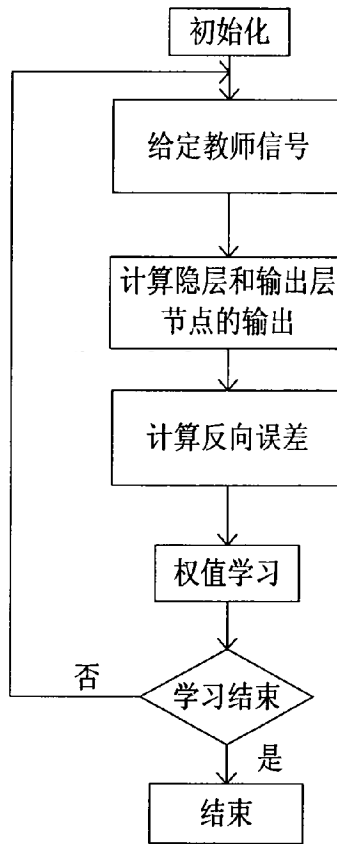


图 3-2 BP 神经网络算法流程图

Fig.3-2 The flow chart of BP neural network

BP 神经网络能完成不依附于模型的非线性映射关系。在连接权中存储着输入输出信息，在数目众多的连接权中，少量的神经元破坏对输入输出之间的关系产生不大的影响，具备较优的容错功能是 BP 神经网络的特点。

BP 神经网络算法虽然被普遍的使用,但其自身伴随着一些问题和不足^[22-28]:

(1) 在处理一些复杂的问题时,需要很长的时间进行训练,所以它的学习效率不是很高,且收敛速度较慢。

(2) 当神经网络的权值被调整的很大时,就会使大多数的神经元加权和变大,那么传递函数就会工作在 Sigmoid 饱和区,此时 S 函数的求导的值会变得特别小,就会使神经网络的权值调节中断。

(3) BP 神经网络收敛的解有可能是局部最小解而非全局最小解。

为了解决训练问题我们从算法上着手。目前有两种方法:第一种为标准梯度下降改进法,第二种为优化标准值的改进方法^[42]。本文所采用的是第二种方法,即 Levenberg-Marquardt BP (LMBP) 算法。该方法对于预测性能指数是均方误差的 BP 神经网络具有较高的应用价值。该种算法是基于牛顿算法以及梯度下降法的一种算法。保留了梯度下降法在刚开始下降速度比较快的接近最优值的优点,牛顿法则是在最优值的左右生成一个较好的搜索方向。BP 神经网络的梯度下降法是采用一级泰勒级数,牛顿法是基于二级泰勒级数的。牛顿法的基本思想是求解 $F(x)$ 的二次驻点,即利用二次函数去逼近 $F(x)$,接着再求驻点。其中 $F(x)$ 是以均方和形式来表示权值的误差曲面。主要算法为:

$$\nabla F(x) = A_k \Delta x_k + g_k \quad (3-28)$$

函数 $F(x)$ 关于 Δx_k 的梯度函数是:

$$\nabla^2 F(x) = A_k \quad (3-29)$$

令上式的结果为 0,那么:

$$\Delta x_k = -A_k^{-1} g_k \quad (3-30)$$

牛顿算法就为下式:

$$x_{k+1} = x_k - A_k^{-1} g_k \quad (3-31)$$

上式 A_k 是此时权值误差函数的二次导数矩阵(海森矩阵)。 g_k 是梯度

$$A_k = \frac{\partial^2 E}{\partial w^2} \Big|_{w=w_k} \quad (3-32)$$

$$g_k = \frac{\partial E}{\partial w} \Big|_{w=w_k} \quad (3-33)$$

主要的算法如下：

将 $F(x)$ 用二次平方和的形式表示，即：

$$F(x) = \sum_{i=1}^N e_i^2(x) = \mathbf{e}^T(x) \mathbf{e}(x) \quad (3-34)$$

其第 j 个梯度的分量为：

$$[\nabla F(x)]_j = \frac{\partial F(x)}{\partial x_j} = 2 \sum_{i=1}^N e_i(x) \frac{\partial e_i(x)}{\partial x_j} \quad (3-35)$$

将梯度转化为矩阵的形式：

$$\nabla F(x) = 2 J^T(x) \mathbf{e}(x) \quad (3-36)$$

其中 J 是雅克比矩阵，是误差对权值以及阈值的一次导数。

$$J(x) = \begin{bmatrix} \frac{\partial e_1(x)}{\partial x_1} & \frac{\partial e_1(x)}{\partial x_2} & \cdots & \frac{\partial e_1(x)}{\partial x_n} \\ \frac{\partial e_2(x)}{\partial x_1} & \frac{\partial e_2(x)}{\partial x_2} & \cdots & \frac{\partial e_2(x)}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial e_N(x)}{\partial x_1} & \frac{\partial e_N(x)}{\partial x_2} & \cdots & \frac{\partial e_N(x)}{\partial x_n} \end{bmatrix}$$

海森矩阵：

$$H = 2 J^T J \quad (3-37)$$

梯度的表达式：

$$g = 2 J^T e \quad (3-38)$$

该算法的表现形式为：

$$x_{k+1} = x_k - [J^T(x_k) J(x_k) + \mu_k I]^{-1} J^T(x_k) \mathbf{e}(x_k) \quad (3-39)$$

此算法不需计算海森矩阵，它的训练速度却近似于海森矩阵。当 μ_k 变小时，其算法就会变为小步长梯度下降法。如下所示：

$$x_{k+1} \approx x_k - \frac{1}{\mu_k} J^T(x_k) \mathbf{e}(x_k) = x_k - \frac{1}{2\mu_k} \nabla F(x) \quad (3-40)$$

在利用 LMBP 进行迭代时，要随时更改 μ 的值，如果收敛了就减小 μ 的值，

如果结果变差则增加 μ 的值, 此时算法会朝好的方向逼近。当平方误差和慢慢变小至低于目标误差值时, 此算法就是收敛的, 说明此种优化方法对神经网络的收敛速度的提升有很大的帮助。

本文的 BP 神经网络算法的优劣是根据均方误差函数 MSE 来衡量预测输出与实际输出的差距来判定。MSE 越小, 表示预测模型的精确度越高。N 表示样本数量, MSE 的表现形式如下:

$$MSE = \frac{\sum_{k=1}^N (y_k - \hat{y}_k)^2}{N} \quad (3-41)$$

3.2 基于 BP 神经网络工具箱的性能预测建模

3.2.1 建模机理

MATLAB 神经网络工具箱是以神经网络的知识理论作为依据, 利用 MATLAB 语言函数来编写各种公式的运算、矩阵的操作以及方程的求解等子程序, 将其应用到神经网络的训练以及设计。用户根据需求来调用子程序, 以能够完成神经网络的设计、训练、初始化权值以及结果的输出。BP 神经网络主要会用到三个网络函数即 newff、sim 以及 train。其中 newff 是设置 BP 神经网络的参数的函数, 函数的形式为^[31]:

$net = newff\{(P,T),S,TF,BTF,BLF,PF,IPF,OPF,DDF\}$

(P, T): 输入输出数据矩阵; 定义输入量的极值;

S: 一个列向量, 包含除输入层的隐含层节点数量;

TF: 节点传递函数列向量;

BTF: 是神经网络的训练函数名称, 是一个字符串变量。本文所使用的即为 Levenberg—Marquardt 训练函数;

BLF: 网络学习函数; 包括: 带动量项学习规则 lerngdm 以及 BP 神经网络的学习规则 learnngd;

PF: 性能分析函数, 包括: 含有动量项的 BP 神经网络学习规则 lerngdm 以及均值绝对误差性能分析函数 mac;

IPF: 输入处理函数;

OPF: 输出处理函数;

DDF: 验证数据划分函数^[31]。

一般情况下, 前 6 个参数在使用中需要设置, 后面 4 个参数系统会默认。

BP 神经网络的训练函数 train 函数^[31]。其函数形式为:

$$[\text{net}, \text{tr}] = \text{train}(\text{NET}, \text{X}, \text{T}, \text{Pi}, \text{Ai})$$

NET: 待训练网络;

X: 输入数据矩阵;

T: 输出数据矩阵;

Pi: 初始化输入层条件;

Ai: 初始化输出层条件;

net: 训练好的网络;

tr: 训练过程记录。

前面 3 个参数在使用中需要设置, 后面 2 个参数系统会默认。

将完成训练的网络预测输出的函数即 sim 函数^[31], 其基本形式为

$$y = \text{sim}(\text{net}, x)$$

net: 训练好的网络;

x: 输入数据;

y: 网络预测数据。

利用 BP 神经网络进行多级离心泵的建模时, 首先要获取训练用的数据。然后, 利用三次样条插值获取数据, 以保证数据曲线具备良好的光滑特性以及收敛特性。最后, 利用测试数据实现建模。具体实现过程如图 3-3 流程所示。

本文基于实际情况取 110 组数据, 随机选取 100 组作为样本数据, 拟将流量、扬程和效率作为输入, 功率作为输出, 实现多级离心泵 BP 网络的初始设置。将训练数据进行归一化, 接着对多级离心泵的 BP 神经网络模型进行训练。这里采用的是 Levenberg-Marquardt (LM) 算法, 同时, 通过实验验证, 当隐含层节点数小于 11, BP 神经网络不能建立精确的映射关系, 网络预测误差大。节点数大于 11 时, 虽然训练样本预测结果较准确, 但是其他样本点的预测误差就会较大。当隐含层节点数设置为 11 时, 神经网络的收敛性最好。预测训练结束后, 通过

训练好的多级离心泵神经网络模型预测非线性输出结果，最后，通过另外 10 组数据与预测的输出进行比较，分析误差 e ，这里将误差的大小设置为 $1e-5$ ，从而保证多级离心泵 BP 神经网络模型的准确性。

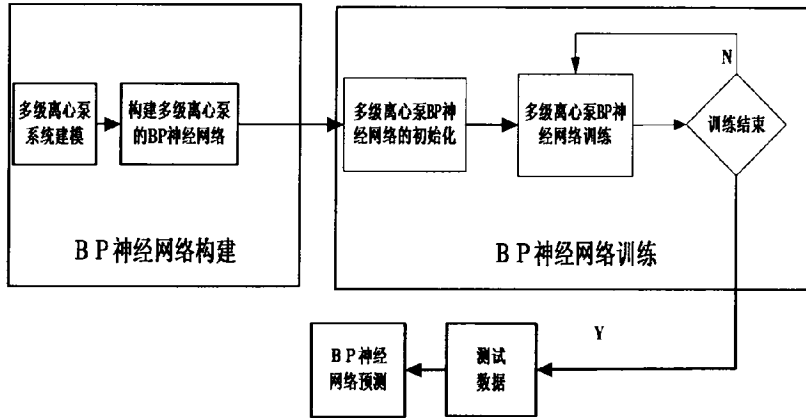


图 3-3 BP 神经网络对多级离心泵预测建模的流程图

Fig.3-3 The flow chart of multistage centrifugal pump predicted by BP neural network

3.2.2 仿真结果分析

BP 神经网络预测模型的训练结果如图 3-4 所示。经过 5 次迭代训练，BP 神经网络的训练误差收敛于 $5.2444e-7$ ，其值是小于设置的误差极限 $1e-5$ ，说明训练之后的网络能准确的预测输出。训练成功后，将后 10 组数据作为测试样本对网络进行测试验证其正确性。




图 3-4 BP 神经网络的训练结果

Fig.3-4 The training results of BP neural network

图 3-5 所示为 BP 神经网络的预测输出。经实验数据验证，预测模型得到的输出值与实际的输出结果比较，通过式（3-41）算出均方误差 MSE 的大小为 0.0128，说明预测模型描述实验数据具有较高的精确度。

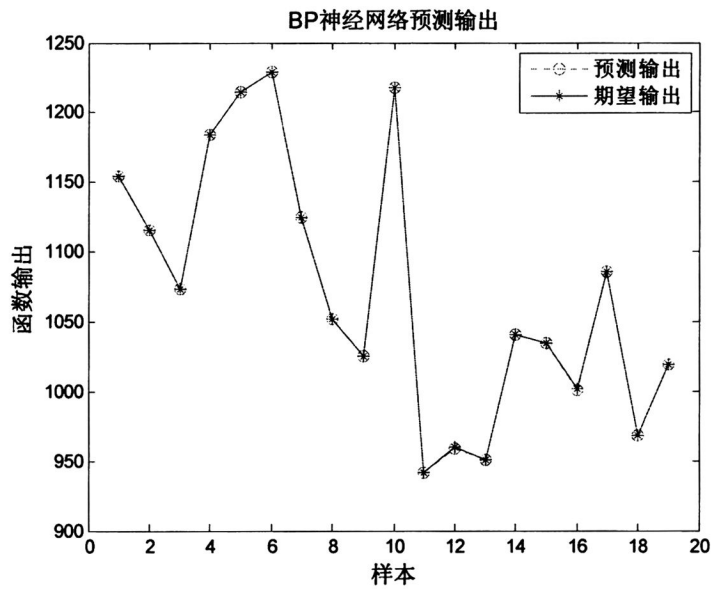


图 3-5 BP 神经网络的预测输出

Fig.3-5 The predicted output of BP neural network

BP 神经网络的预测误差如图 3-6 所示。观察可知，BP 神经网络预测模型的输出结果存在一定的误差，且在一些测试数据样本点的误差较大，波动范围大致在 $[-0.1, 0.06]$ 。由此可见，BP 神经网络的预测模型存在一定弊端，所以拟在后续章节采用遗传算法对该模型进行优化设计，消除误差波动以获得稳定输出。

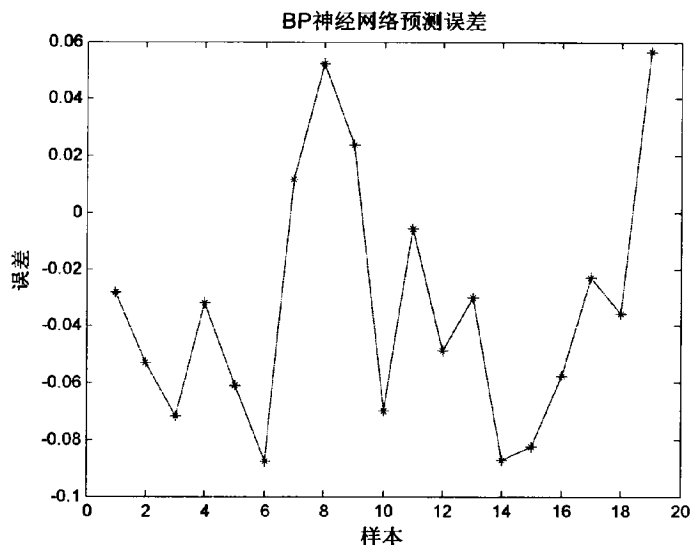


图 3-6 BP 神经网络的预测误差

Fig.3-6 The predicted error of BP neural network

3.3 本章小结

本章基于 BP 神经网络的基本概念和工具箱，建立了多级离心泵的性能预测模型。内容包括 BP 神经元建模、BP 神经网络预测模型的流程步骤，以及在此基础上进行的仿真结果分析。

第四章 基于遗传算法优化的多级离心泵性能预测模型

4.1 遗传算法的基本原理

4.1.1 遗传算法的构成要素

遗传算法（GA）是由美国 Michigan 大学 Holland 教授提出来对大自然的生物进化论以及遗传机制进行模拟形成的一类随机搜索、最优化方法。遗传算法结合达尔文的生物进化基本原理，将该理论应用到经参数优化而产生的编码串联群中，接着根据优胜劣汰的原则，留下比上一代优秀的新群体。一次接一次的循环，逐渐将群体的个体适应度提升，至条件满足为止。遗传算法的本质为对全局进行搜索的一类并行、高效的算法方式^[41]，并在搜索的过程中不断的自适应调整以得到最好的方案。

遗传操作、适应度函数、染色体编码方法以及运行参数^[42]是构成遗传算法的四个基本要素。

（1）染色体编码即表现为对个体进行编码，用确定长度的二进制串代表群体的个体或者将个体进行编码成一个实数串，等位基因都是根据二值符号集构成，二值符号集为{0,1}。初始群体中个体基因是由均分分部的随意数组成。

（2）适应度函数指基于遗传算法公式，根据进化目标来编写的函数。通过函数算法来算出与个体适应度成正比的进化概率，以供选择算子完成选取任务。适应度函数是遗传算法唯一的反馈指标，凭借适应度函数值来衡量染色体的优劣，进而决定染色体遗传至后一代的概率。

（3）遗传操作是算法的基本且必不可少的操作步骤，基本的遗传算子为：选择、交叉以及变异。具体的操作将会在下节中会细细叙述。

（4）运行参数是指算法在初始化操作时的参数，包含有群体的大小 M (即个体数量)、遗传的代数 T 、交叉概率 P_c 以及变异概率 P_m 。

其基本的形式可定义如下：

$$SGA = (C, E, P_0, M, \Phi, \Gamma, \Psi, T)$$

这 8 个元素代表:

C: 遗传个体的编码的方法;

E: 关于遗传个体的适应度评价;

P_0 : 初始选择的群体;

M: 被选择的群体的大小;

Φ : 选择操作步骤;

Γ : 交叉操作步骤;

Ψ : 变异操作步骤;

T: 运算终止满足的条件。

图 4-1 是遗传算法的基本流程框图。

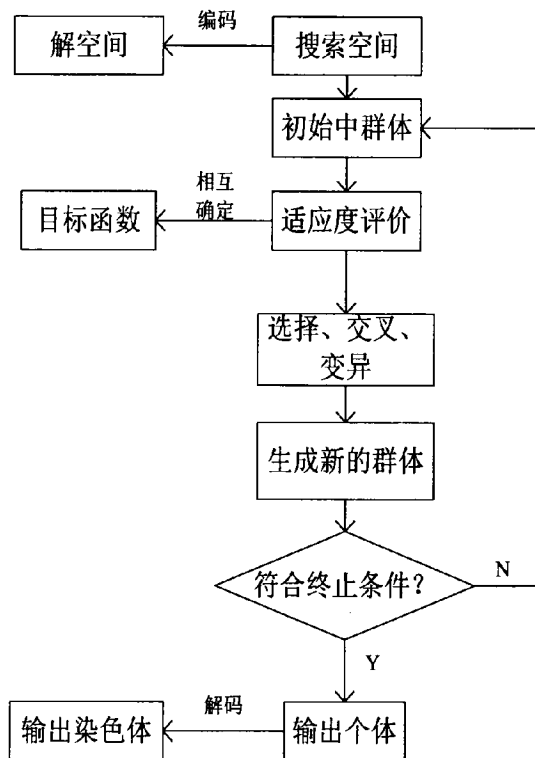


图 4-1 遗传算法的基本流程框图

Fig.4-1 The flow chart of genetic algorithm

4.1.2 遗传算法的基本操作

遗传算法的基本操作为: 选择、交叉以及变异^[44-51]。

1.选择操作,即为在当下的种群中选取生命力较强的优良个体到新群体中,使他们可以作为父代繁殖下一代子孙。即遵循一定的方法从第 m 代群体选择一个优良品种作为父代遗传至 $m+1$ 代群体中。选择算子应用最多的方法是比例选择遗传算子法,具有高适应度的个体被选择到的可能性较大。使用比例算子详细的操作步骤如下:

(1) 计算群体的适应度总和。

(2) 算出每一个体相对适应度的值,该适应度的值就是正比于该个体遗传至后一代的机会大小。

(3) 确定全部个体被选中的次数。

2.交叉操作,即选取任意两个不同的染色体,通过随机选取染色体的一点、多点互相交换点的位置,以获得全新的两个染色体数字编码串是获得全新优秀个体的必要手法。染色体交叉方式包括单点编码交叉和多点编码交叉以及均匀的交叉。对于交叉算子的实现和设计原则是在保证现个体优良性状的前提下,不过多的破坏表征这些优良性状的编码串,而且还能产生较好的新的个体性状。

(1) 单点交叉就是将一双要互配对的优良个体首先设定交叉概率,然后在交叉点的位置点处互相交换这对个体的一部分染色体,以生成全新个体后代。

(2) 多点交叉就是保证在第一变量到第一个交叉点区间内的染色体不相互交换的前提下,对剩余的交叉位置点可以不重复且随机选择相互交换,以产生新的下一代。

(3) 均匀交叉是一种更加广义化的交叉,因为其每个染色体的点都可以作为交叉点,随机产生掩码,该掩码是与个体等长的 $\{0,1\}$ 掩码。掩码片断是代表由哪一个父辈个体向下一代个体产生遗传的变量值。

3.变异操作,即从群体中任意选取个体,对个体的染色体以某种变异概率进行基因突变为其他等位基因。变异操作作为遗传算法中生成全新的个体中重要的一个步骤,它是遗传算法的不可缺少的操作。其基本操作为在基因码的小部分中进行随意搜索并与选择算子进行结合,确保其可行性,表现出算法有在局部随机进行随机搜索的本领,保证了染色体的多样性,保证算法的可行性。实质上的操作即为将二进制编码中的1和0以一定的概率互相变化。

利用遗传算法对预测模型优化,具有很多优点:

一是因为遗传算法对于可行解具有普遍性，它解决的问题不是参数，是经参数编码获得的新的基因后代个体。

二是群体的搜索特性，鉴于传统搜索都是单点的搜索方式，遗传算法使用的方法为在同一时刻并行处理很多个体。利用算法对区域中存在的大量的解的结果进行优化评估，说明遗传算法具备很好的全局搜索最优功能。

三是遗传算法可以只用适应度数值对基因个体进行是否可遗传评估鉴定，并实现遗传操作步骤。并且遗传算法的定义域是能够被随意假设而不约束于连续可微。

四是遗传算法利用概率变迁去完成搜索方向的确定，根据内在并行搜索机制引导搜索方向，解决了算法陷入局部最优的困扰。利用遗传算法可以利用自然进化机制快速可靠的解决困难的问题，在研究计算中得到大量的应用。

遗传算法的所含的缺陷以及本节进行的修正：

（1）遗传算法本身的局限性：对于算法的精确度、算法的复杂度以及算法的可信度等没有定量且没有有效的研究计算方法；且遗传算法在遗传操作时优化其效率较低。

（2）改进方法：本文采用的是标定适应度函数以及增加群体的多样性来解决上述问题的。

4.2 遗传算法优化的 BP 神经网络预测建模

4.2.1 优化的基本原理及优化建模

遗传算法具有很多优点，其中最大的优点是只用适应度函数，而不采用梯度算法和其他信息。即使对多态非线性函数，也能够得到全局最优解^[52]。其中遗传算法优化 BP 神经网络的多级离心泵预测模型基本框图如图 4-2 所示。

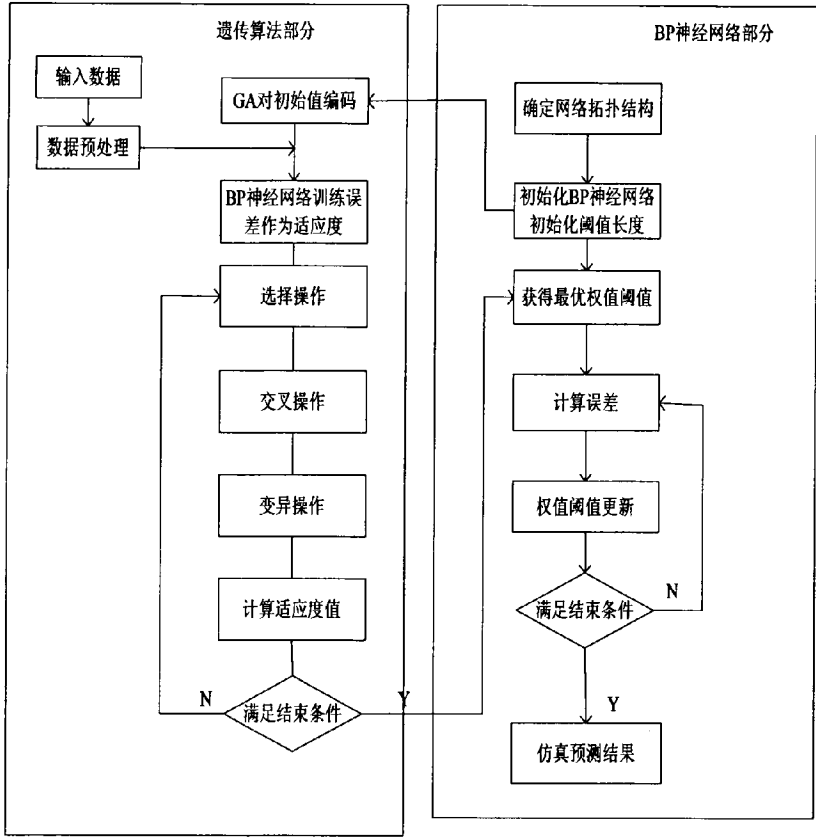


图 4-2 利用遗传算法优化的 BP 神经网络流程图

Fig.4-2 The flow chart of BP neural network optimized by Genetic algorithm

其基本思想为：首先在一定的区域内对 BP 神经网络的权值以及阈值编码，生成初始种群；接着根据遗传算法的进化原理，保证神经网络预测误差最小的前提下进行多次迭代，以获取一组最优的权值和阈值；最后把这组权值和阈值代入 BP 神经网络作为训练开始的初始权值和阈值。

由前面章节的内容知道 BP 神经网络是基于梯度法的搜寻全局最优解的高度非线性函数，易陷入局部极小点，这样就不能完成学习目标。遗传算法是全局寻优方式，利用遗传算法去优化 BP 神经网络，能够让 BP 神经网络具备自适应进化的能力，这样就能生成可以进化的 BP 神经网络。

其中基于遗传算法优化 BP 神经网络（GABP）性能预测模型的操作包括：使连接权值进行进化网络结构进化以及学习规则进化^[44-56]。

其中神经网络连接权包括关于该神经系统的所有信息，随意给定一组初始权值是获取权值的传统方式，接着根据既定的改变准则，不断的在训练过程中修改

与调整,最后获得比较理想的一个权值分布。利用遗传算法优化 BP 学习算法获得权值的方法是先将确定的网络权值以及阈值用二进制形式来表示,然后把二进制串连接成一个基因链码。再利用遗传算法迭代直至产生最优权值,其具体的步骤如下:

(1) 对随机产生的分布权值完成编码操作从而做出一个能够代表网络权值分布的码链。对于已经确定的学习规则和神经网络结构,一个编码链就相对一个权值以及阈值确定的神经网络。

(2) 算出 BP 神经网络产生的误差函数,接着计算合适的适应度函数值。

(3) 选择由步骤(2)产生的适应度较大的个体,将其作为优种个体基因遗传至后一代。

(4) 对当代的群体染色体进行处理,处理的方法包括变异以及交叉等。

(5) 循环以上操作,促使初始权值分布不停的优化进化,到实现训练的目标。

单独的采用神经网络和遗传算法去完成权值的分布都不是最理想的,其中遗传进化的优点是可以在复杂多峰的、非线性的空间中进行全局最优搜索,但它不是基于误差函数梯度信息的。但是若已知梯度信息时,利用遗传算法的优化不一定比 BP 神经网络算法好。那么把遗传算法和 BP 神经网络算法结合训练是一种比较好的路径。

遗传算法对 BP 神经网络结构进行优化是使用直接编码法和语法编码法两种方法。因为应用神经网络时,神经网络的选择是根据经验反复实验和修正得到的,所以利用遗传算法自动优化 BP 神经网络结构是必要的。遗传算法是利用二进制来表示一条边,“1”和“0”分别表示有无这条边。然后将设计好的二进制串加入基因,就能够完成网络结构的进化。

遗传算法对学习规则的进化方法包含两种,对学习参数的进化以及学习规则的进化。学习规则的进化就是对权值规则进化或者是对学习本身进行进化,这样就使进化后的网络可以更加的适应变换外界条件。

对于遗传算法优化网络的实现,详细步骤见流程图。本文采用的是先由 BP 神经网络得到初始权值和阈值,接着再用遗传算法来优化该值。这样就能确保 BP 网络能更加准确预测模型的输出。优化的具体步骤包括:

(1) 种群初始化：在区间内选择权值以及阈值对其使用编码操作，以产生初始化种群。通过编码的群体代表一种新的网络权值。

(2) 适应度函数的确定：经过对神经网络误差的计算，按照误差越大的个体其适应度值越小的经验定律，获取适应度函数。

(3) 遗传算子操作：其作用是根据选择、变异、交叉等操作是经过群体中的个体一代传至一代的进化规律。将最优秀的个体保存且与赌轮选择结合的方法，使得进化时个体的最优性状可以免除被交叉变异破坏。当使用一点交叉的方法随机的设定某个交叉点。最终根据前后的两个个体编码互换产生新的两个后代个体。

(4) 变异操作：变异操作采用的方法是位点变异。在将个体完成编码并随机确定基因位点。使用确定好的变异概率操作这些基因值使其变异。如果算法的结果根据交叉算子的值靠近最优的区间，使用变异算子来加快最优的解的收敛速度。这样既保证了群体基因编码的多样性，还是得收敛迅速且不会有未成熟的收敛。

(5) 混合训练神经网络即结合遗传算法以及 BP 神经网络，利用遗传算法对 BP 网络的初始权值的分布情况进行优化，根据解的区域空间选择一个特别好的区域空间进行搜索，最后发挥 BP 神经网络的优点，在这个相对较小的解的区域空间内寻找出最好的解。

这两个算法结合的基本点是将遗传算法所含有的进化和 BP 网络所使用的梯度下降法的反向传递训练相结合。基于遗传算法的优点，将 BP 网络的权值做一个全局的搜索并优化，缩减最优解范围，使得函数训练误差达到要求，在一定的区间范围之内，利用 BP 神经网络的算法进一步修正权值。按照这样的步骤反复循环至权值的误差最小。简要来说就是先使用遗传算法来优化权值，接着利用 BP 神经网络来选择并输出最优的公差值。

4.2.2 仿真结果分析

基于遗传算法以及 BP 神经网络的理论，利用 MATLAB 软件编程完成遗传算法优化的多级离心泵 BP 神经网络预测建模。

首先是对种群进行初始化，进化的代数即迭代次数设置为 20，种群的交叉概率设置为 0.4，其变异的概率选择为 0.08。接着编写适应度函数，对于适应度

函数的编写主要是用来训练 BP 神经网络的预测模型，并且将训练数据的预测误差作为个体的适应度。选取适应度较高的优秀个体去组合成新种群。接着利用概率交叉获得新个体，最后利用变异操作随机选择一个个体。本文利用 for 循环编写，循环往复，并不停的进行变异操作，随机任意选取染色体，在此基础上随机选择变异的点。按照概率变异得到新的个体。经过迭代求解最优的初始阈值以及权值，并且把最优的初始值赋予神经网络训练，利用 BP 神经网络拟合这个非线性函数。利用优化后的 BP 神经网络预测模型进行结果输出，并与实际数据对比。

遗传算法优化的 BP 神经网络训练结果如图 4-3 所示。经过 36 次迭代训练，训练误差的最小值收敛于 $2.0539\text{e-}08$ ，远小于设置的训练误差 $1\text{e-}5$ ，说明预测输出与实验数据之间的偏差满足要求。由此可以看出遗传算法优化后的 BP 神经网络性能预测模型输出精度更高。




图 4-3 遗传算法优化的 BP 神经网络训练结果

Fig.4-3 The training result of BP neural network optimized by genetic algorithm

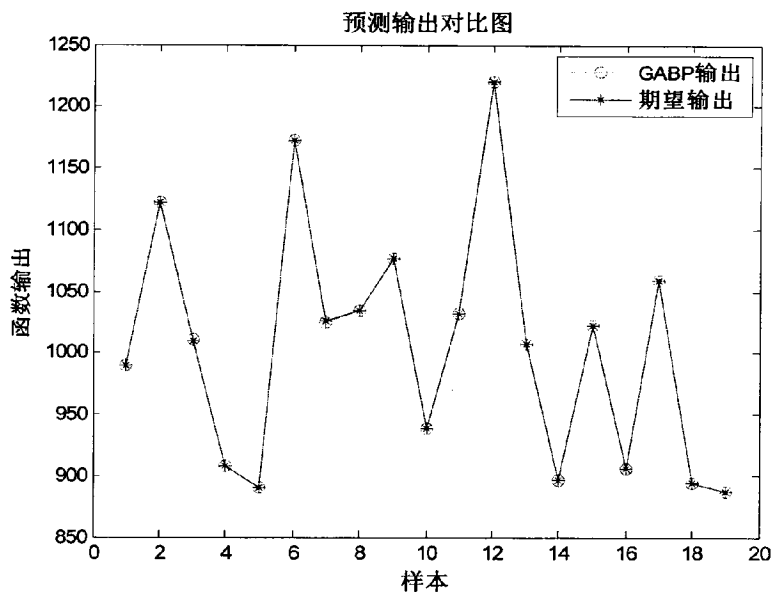


图 4-4 GABP 预测输出对比图

Fig.4-4 The contrast figure of the predicted output

由图 4-4 所示，经过遗传算法优化后的 BP 神经网络性能预测模型的输出结果与实际期望输出几乎重合。经实验数据验证，由式 (3-41) 可得均方误差 MSE 的大小为 $4.732e-5$ ，相对于 BP 神经网络建模缩小近 300 倍，由此可以说明经过优化后的模型能够更加精确的预测输出。




图 4-5 遗传算法优化后的 BP 神经网络预测误差

Fig.4-5 The contrast figure of the predicted error

由图 4-5 可以看出, BP 神经网络的预测误差范围是【-0.4,0.3】,且波动较大。而通过遗传算法优化的 BP 神经网络预测模型的预测误差分布较为稳定,误差值维持在[-0.01,0.01]。由此可见,遗传算法提高了预测模型的自适应能力,使系统的预测输出更加精确。

4.3 本章小结

本章根据遗传算法的全局寻优功能,把最优的初始权值和阈值赋给 BP 神经网络。同时,采用 BP 神经网络预报预测误差,建立基于遗传算法优化的多级离心泵 BP 神经网络性能预测模型。仿真结果显示,该预测模型精度更高且收敛性更好。

第五章 总结与展望

5.1 总结

传统多级离心泵的性能预测建模一直是一个特别繁琐的过程,需要不断的实验,消耗大量的物力与财力。本文基于 MATLAB 软件平台,使用三种方法对多级离心泵进行性能建模。主要内容与结论如下:

(1)首先根据叶轮相似定律,找出多级离心泵输出性能参数之间的关系,利用最小二乘法对多级离心泵进行建模,使得多级离心泵的输出参数便于分析。同时利用 MATLAB GUI 的窗口界面拟合出 $H-Q$ 曲线、 $P-Q$ 曲线和 $\eta-Q$ 曲线,通过输出的曲线图可以看出实测数据与拟合曲线之间的趋势基本一致,误差在允许的范围之内,说明了最小二乘法拟合模型的实用性。

(2)利用 BP 神经网络的函数拟合能力,将未知系统看作一个黑箱。其中,流量、扬程以及效率作为输入,功率作为输出。通过输入输出函数训练改进的 BP 神经网络算法,不断地调整权值与阈值,实现误差最小,从而使多级离心泵的预测输出更加精确。通过对比计算分析,得出其预测误差比最小二乘法拟合误差缩小近百倍。

(3)利用遗传算法优化 BP 神经网络预测的多级离心泵模型,其预测输出误差能维持在很小的范围之内。误差的范围维持在【-0.01,0.01】左右,实现了提高预测模型精确度以及收敛性的目标。

5.2 展望

完成上述工作的同时,本文仍存在一些需要完善和补充的地方。对于今后的工作主要提出以下两点展望:

(1)在遗传算法优化的多级离心泵性能预测模型的基础上,进一步优化算法以及初始值、交叉概率等,从而减少预测模型输出值与实际工况值之间的误差。

(2)在上述预测模型的基础上与异步电机进行耦合系统分析,优化控制电机使得多级离心泵尽可能工作在高效区。

参考文献

- [1] 《离心泵设计基础》编写组.离心泵设计基础[M].机械工业出版社,1974
- [2] 谈明高,袁寿其,刘厚林.离心泵性能预测的研究现状及展望[J].水泵技术,2005
- [3] 刘厚林,流道式无堵塞泵 CAD 软件开发及三维不可压湍流计算.[D]江苏大学
博士学位论文,2001
- [4] 罗海斌.离心泵叶轮流场速度分布规律与外特性研究.[D]中国农业大学硕士
论文,1999
- [5] 王国玉,左志刚,曹树良.水泵水轮机内三维紊流流场计算与性能分析.[J]水利
水电技术,2001, (5)
- [6] 张克危,孙建平,贾纵谟.混流泵的性能预测[J].华中理工大学学报,1996
- [7] Medvitz R.B.etal. Performance Analysis of Cavitating Flow in Centrifugal Pumps
Using Multiphase CFD[C]. Proceedings of the ASME Fluids Engineering Division
Summer Meeting, v1,2003,p445-453
- [8] Tremante A.et al. Numerical performance prediction and experimental validation
of an axial pump under two—phase flow (liquid/gas)[J].American Society of
Mechanical Engineers Petroleum Division (Publication)PD,v2,2002,p755-760
- [9] Sun J.et al. Off—design performance prediction for diffuser pumps[J].
Proceedings Institution of Mechanical Engineers,Part A:Journal of the Power and
Energy,v215,n2,2001,p191-202
- [10] Zhang Rui. Numerical prediction of cavitation—Improving pump design
WORLD PUMPS[J].November,2001,p26-28
- [11] 谈明高.离心泵的性能预测原理及其软件开发[D].江苏大学,2006
- [12] 杨军虎,张学静.离心泵性能预测发展运行与应用[D],2003
- [13] 罗华飞,MATLAB GUI 设计学习手记[M].北京航空航天大学出版社,2011.02
- [14] 胡大明,陈开谱,孙勇.水泵效率曲线拟合的 MATLAB—GUI 设计[J].中国农村
水利水电,2008
- [15] 聂书彬,关醒凡,刘厚林.利用人工神经网络预测离心泵性能的探索[J].水泵技
术,2002
- [16] 常玉连,高胜,郭俊忠.油田注水系统最优控制数学模型及设计[J].石油机械,

- 2001;29 (12)
- [17] B.O.Bringedal, S.A.Morud, N.A.Hall. Online Water Injection Optimization, prevention of reservoir damage[C]. SPE102831—MS,2006
- [18] 魏海坤.神经网络结构设计的理论与方法[M],北京国防工业出版社,2005
- [19] 阎平凡,张长水. 人工神经网络与模拟进化计算[M].清华大学出版社,2000
- [20] 刘国荣, 多变量系统模糊/神经网络自适应控制[M].科学出版社,2012
- [21] 王小平,曹立明.遗传算法理论/应用与软件实现[M].西安交通大学出版社,2002
- [22] 张丽飞.遗传算法优化 BP 神经网络的数字滤波器的应用研究[D].硕士论文,西华大学,2007
- [23] 邵仕泉.基于 BP 神经网络的遗传算法在数字滤波器设计中的应用[D].硕士论文,中国电子科技大学,2005
- [24] Zhou Hao, Cen Kefa ,Mao Jianbo,Combing neural network and genetic algorithms to optimize low NOX pulverized coal combustion Fuel [J].2001, (80): 2163—2169
- [25] M.Kolehmainen,H.Martikainen,J.Ruuskanen Neural networks and periodic components used in air Quality forecasting,Atmospheric Environment[C],2001
- [26] 周敏.遗传算法的若干改进及应用[D].硕士论文,中国科学院,2001
- [26] 李享梅,赵天.改善遗传神经网络收敛性的研究[J].计算机应用,2005
- [27] 彭松,方祖祥.BP 神经网络学习算法的联合优化[J].电路与系统学报,2000
- [28] 张磊,胡春,钱锋.BP 算法局部极小问题的改进措施[J].重庆交通学院学报 2004,17 (9): 33-34
- [29] 金聪.函数优化中实数型遗传算法的研究[J].小型微型计算机系统, 2000
- [30] 王小川,史峰,郁磊等,MATLAB 神经网络的 43 个案例分析[M].北京航空航天大学出版社.2013
- [31] 闻骥骏,沈典栋,沈成武.改进自适应遗传算法研究及其应用[J].交通与计算机,2003
- [32] 王智平,刘在德,高成秀.遗传算法在 BP 神经网络权值学习中的应用[J].甘肃工业大学学报,2001
- [33] 杨海清.遗传算法的改进及应用研究[D].硕士论文,浙江工业大学,2004
- [34] Bessauo M, Slarry P, A genetic algorithm with real—value coding to optimize

- multimodal continuous functions[C]. Struct Multidisc Optim,2001
- [35] 冯永华,林梅.水泵过载及电机配置问题分析[J].现代机械,2007
- [36] 何忠华.城市需水量预测研究[D].安徽理工大学硕士论文,2009
- [37] 陈杰等著.MATLAB 宝典[M].电子工业出版社,2011
- [38] 许聚武,沈晓梅,华昕若,肖红.基于 MATLAB-GUI 的建筑热工缺陷分析软件的设计[J].农业技术与装备,2010
- [39] 童新安.基于灰色系统与神经网络的组合预测方法及应用研究[D].西安电子科技大学,2012
- [40] 阴辉,张志刚,刘培学.人工神经网络 BP 算法的改进与分析[J].硅谷,2008
- [41] 贺电.大型风电场短期功率预测研究[D].北京交通大学,2011
- [42] Andrew C C. comparing neural networks and regression model for ozone forecasting[C]. J. Air&waste manage. Assoc.2007,(47):653-663
- [43] 郭辉,许令锋,吴卫东等.基于 GA-BP 神经网络的铝箔腐蚀工艺研究[J].热加工工艺,2014
- [44] 黄丽.BP 算法改进及应用研究[D].重庆师范大学硕士论文,2008
- [45] 刘益民.基于改进 BP 神经网络的 PID 控制研究方法[D].中国科学院研究生院,2007
- [46] 黄煜坤.基于 BP 神经网络算法的入侵检测技术[J].电子测试,2015
- [47] 段候锋.基于遗传算法优化 BP 神经网络的变压器故障诊断[D].北京交通大学硕士论文,2008
- [48] 陈政.一种改进的遗传算法优化 BP 网络的研究及应用[D].暨南大学硕士论文,2010
- [49] 郑卫燕.基于遗传算法的 BP 网络优化研究及应用[D].哈尔滨工程大学硕士论文,2008
- [50] 吴仕勇.基于数值计算方法的 BP 神经网络及遗传算法的优化研究[D].云南师范大学硕士论文,2006
- [51] Yingshi Han. Pengfei Guo. Xuezhi Wang. The enhanced genetic algorithms for the optimization design[C]. Biomedical Engineering and Informatics (BMEI),2010 3rd International Conference on.2010
- [52] Heris, J.E.A. Oskoei, M.A. Modified genetic algorithm for solving n-queens

- problem[C]. Intelligent Systems (ICIS), 2014 Iranian Conference on.2014
- [53] Li Cen. Mei Wang. Application of Hybrid Genetic Algorithm-BP Neural Networks to Diagnosis of Lung Cancer[C]. Computer Science and Software Engineering, 2008 International Conference on.2008, Page(s): 36 - 39
- [54] Shan Li. Haibing Chen. JunXian Yun. LiuZheng Zhou. Optimization for Cyclosporine Blood Concentration Prediction Based on Genetic Algorithm - BP Neural Network[C]. Genetic and Evolutionary Computing, 2008.WGEC '08. Second International Conference on.2008. Page(s): 161 – 165
- [55] Li Hui. Hu Cai-xia. Li Ying. The BP neural network model and application based on genetic algorithm[C]. Electric Information and Control Engineering (ICEICE), 2011 International Conference on. 2011, Page(s): 795 – 798

致 谢

在安徽大学度过的六年时光，是我这一辈子中宝贵的记忆。难以忘却同学、朋友、老师对我的影响以及帮助。

本论文是在导师王群京老师、温旭老师的指导下完成的，我要向他们表示最真挚的感谢。王老师和温老师严谨的工作态度以及作风、细心的指导学生、忘我的工作热情都深深的感动了我，对他们这种无私奉献的敬业精神表示钦佩。

同时，还要感谢李国丽老师、过希文老师。他们在课题上给予我启发，给我们营造比较活跃而不失严谨的学习氛围，督促我们努力学习进步，在此向他们表示深深的敬意和诚挚的感谢。

在此，特别感谢我的家人，辛辛苦苦的把我养大，最大程度满足我的精神以及物质生活。