



# (12)发明专利申请

(10)申请公布号 CN 106980846 A

(43)申请公布日 2017. 07. 25

(21)申请号 201710299192.4

(22)申请日 2017.05.01

(71)申请人 刘至键

地址 523320 广东省东莞市石龙镇广播电视大楼

(72)发明人 刘至键

(51)Int.Cl.

G06K 9/00(2006.01)

G06K 9/62(2006.01)

G06N 3/04(2006.01)

G06N 3/08(2006.01)

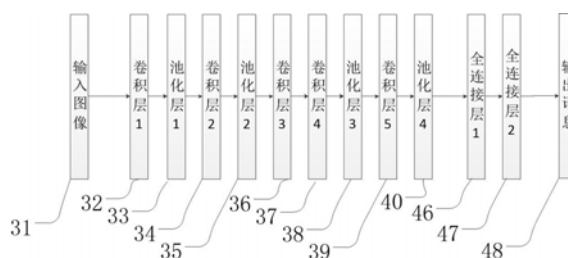
权利要求书3页 说明书13页 附图1页

## (54)发明名称

一种基于深度卷积网络的汽车配件识别装置

## (57)摘要

本发明所公开的一种基于深度卷积网络的汽车配件识别装置,是因应现代社会汽车配件的种类繁多,汽车的品牌汽车的类型越来越多,每一类型汽车的配件种类超过一万种,使汽车制造、维护维修的配套带来很大的难度。使用深度卷积网络技术结合电子信息技术对图像处理后,利用预先训练得到的深度卷积网络识别目标汽车配件图像,达到提高识别率的作用,适合于汽车配件储运、汽配销售等行业应用需要。



1. 一种基于深度卷积网络的汽车配件识别装置,包括摄像模块、图像采集模块、亮度均衡控制模块、深度卷积网络服务器、显示驱动模块、微显示终端、补光灯,其特征在于所述的摄像模块与图像采集模块连接,所述的图像采集模块与亮度均衡控制模块连接,所述的亮度均衡控制模块与深度卷积网络服务器连接,所述的深度卷积网络服务器与显示驱动模块连接,所述显示驱动模块与微显示终端连接,所述亮度均衡控制模块与补光灯连接;所述的亮度均衡控制模块用于对来自摄像模块的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯;所述的微显示终端是0.37英寸的 LCoS透视显示器;所述的深度卷积网络服务器采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2。

2. 如权利要求1所述的一种基于深度卷积网络的汽车配件识别装置,其特征在于所述深度卷积网络的训练步骤具体包括:步骤一,获取带有属性及参数标记的汽车配件图像样本;步骤二,利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类;根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数;步骤三所述利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类具体为:利用预先设置有初始参数的卷积核与所述汽车配件图像样本进行卷积计算;经过池化层的池化操作以及全连接层1和全连接层2的全连接操作,得到所述汽车配件图像样本的汽车配件属性概率;所述根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数,具体为:当所述汽车配件属性概率与所述汽车配件的属性信息之间存在差异时,调整所述卷积核中的参数,直至输出的汽车配件属性概率与所述汽车配件的属性信息相符。

3. 如权利要求1所述的一种基于深度卷积网络的汽车配件识别装置,其特征在于,所述深度卷积网络的参数具体为使用深度卷积网络的训练工具通过tensorflow进行训练,从输入到输出的计算过程为:

卷积层 1 计算公式是  $h_{1,a}^l = f(u_{1,a}^l) = f(x^l \otimes W^{1,a} + b^{1,a})$ , 其中  $x^l$  表示输入,  $W^{1,a}$  表示卷积核,  $b^{1,a}$  表示偏置,  $h_{1,a}^l$  表示输出;

池化层 1 计算公式是  $h_{2,a}^l = g(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,a}^l) + \gamma_2)$ , 其中  $h_{1,a}^l$  表示输入,  $\beta_2$  表示权值,  $\gamma_2$  表示偏置,  $h_{2,a}^l$  表示输出;

卷积层 2 计算公式是  $h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{2,\alpha_i}^l \otimes W_{\alpha_i}^{3,\omega} + b^{3,\omega})$ , 其中池化面  $h_{2,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{3,\omega}$  表示卷积核,  $b^{3,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2, \dots, \alpha_\tau)$ ,  $h_{3,a}^l$  表示输出;

池化 2 计算公式是  $h_{4,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_4)$ , 其中  $h_{3,a}^l$  表示输入,  $\beta_4$  表示权值,  $\gamma_4$  表示偏置,  $h_{4,a}^l$  表示输出;

卷积层 3 计算公式是  $h_{5,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{4,\alpha_i}^l \otimes W_{\alpha_i}^{5,\omega} + b^{5,\omega})$ , 其中池化面  $h_{4,a}^l$  ( $1 \leq i \leq \tau$ )

是输入,  $W_{\alpha_i}^{5,\omega}$  表示卷积核,  $b^{5,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \cdots \alpha_\tau)$ ,  $h_{5,a}^l$  表示输出;

卷积层 4 计算公式是  $h_{6,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{5,\alpha_i}^l \otimes W_{\alpha_i}^{6,\omega} + b^{6,\omega})$ , 其中池化面  $h_{5,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{6,\omega}$  表示卷积核,  $b^{6,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \cdots \alpha_\tau)$ ,  $h_{6,a}^l$  表示输出;

池化 3 计算公式是  $h_{7,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_7 \text{down}_{\lambda_7, \tau_7}(h_{6,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_7)$ , 其中  $h_{6,a}^l$  表示输入,  $\beta_7$  表示权值,  $\gamma_7$  表示偏置,  $h_{7,a}^l$  表示输出;

卷积层 5 计算公式是  $h_{8,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{7,\alpha_i}^l \otimes W_{\alpha_i}^{8,\omega} + b^{8,\omega})$ , 其中池化面  $h_{7,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{8,\omega}$  表示卷积核,  $b^{8,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \cdots \alpha_\tau)$ ,  $h_{8,a}^l$  表示输出;

池化 4 计算公式是  $h_{9,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_9 \text{down}_{\lambda_9, \tau_9}(h_{8,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_9)$ , 其中  $h_{8,a}^l$  表示输入,  $\beta_9$  表示权值,  $\gamma_9$  表示偏置,  $h_{9,a}^l$  表示输出;

$$H_9^l = h_{9,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l;$$

$$H_k^l = \sigma(u_k^l) = \sigma(W^k H_{k-1}^l + b^k), 12 \leq k \leq R$$

所述tensorflow的参数包括:卷积层1的卷积核尺寸为 $11 \times 11$ ,颜色通道为3,卷积核数量为64,卷积步长为 $4 \times 4$ ,图片每 $4 \times 4$ 区域只取样一次,横向间隔是4,纵向间隔是4,每次取样的卷积核为 $11 \times 11$ ;池化层1的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层2的卷积核尺寸为 $5 \times 5$ ,输入通道数为64,卷积核数量为192,卷积步长为1;池化层2的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层3的卷积核尺寸为 $3 \times 3$ ,输入通道数为192,卷积核数量为384,卷积步长为1;卷积层4的卷积核尺寸为 $3 \times 3$ ,输入通道数为384,卷积核数量为256,卷积步长为1;池化层3的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层5的卷积核尺寸为 $3 \times 3$ ,输入通道数为256,卷积核数量为256,卷积步长为1;池化层4的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。

4.如权利要求1所述的一种基于深度卷积网络的汽车配件识别装置,其特征在于所述深度卷积网络的运行步骤包括:获取待识别汽车配件图像,利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像;识别通过所述卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2,于全连接层2输出节点为所述汽车配件图像的汽车配件属性概率,根据所述汽车配件属性概率确定所述待识别汽车配件图像的汽车配件属性信息;在获取待识别汽车配件图像之后、在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像之前,进一步包括:对所述待识别汽车配件图像进行预处理;所述预处理至少包括以下一种操作:裁剪、边界填充、翻转、饱和度平衡、色调平衡、对比度平衡、直方图均衡、镜像操作、随机剪切、中心化、均值化、调整大小resize;步骤包括:获取待识别汽车配件图像;训练深度卷积网络;所述深度卷积网络的网络结构包括卷积层、池化层和全连接层,所述卷积层的后面连接所述池化层,所述池化层后

面连接所述全连接层,最后的全连接层上的每个输出节点为所述汽车配件图像的汽车配件属性概率;识别步骤是利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像;根据所述汽车配件属性概率确定所述待识别汽车配件图像的汽车配件属性信息。

## 一种基于深度卷积网络的汽车配件识别装置

### 技术领域

[0001] 本发明涉及计算机视觉技术领域,尤其涉及一种基于深度卷积网络的汽车配件识别装置。

### 背景技术

[0002] 汽车配件的种类繁多,汽车的品牌汽车的类型越来越多,每一类型汽车的配件种类超过一万种,使汽车制造、维护维修的配套带来很大的难度。随着深度卷积网络技术的发展,通过图像识别分析图像和检测物体的特征,以判别汽车配件带来了可能。

### 发明内容

[0003] 本发明的目的是公开一种基于深度卷积网络的汽车配件识别装置及装置,以解决现有技术中的对汽车配件识别方法单一、效率低、准确率低的问题。

[0004] 本发明的一种基于深度卷积网络的汽车配件识别装置,包括摄像模块、图像采集模块、亮度均衡控制模块、深度卷积网络服务器、显示驱动模块、微显示终端、补光灯,其特征在于所述的摄像模块与图像采集模块连接,所述的图像采集模块与亮度均衡控制模块连接,所述的亮度均衡控制模块与深度卷积网络服务器连接,所述的深度卷积网络服务器与显示驱动模块连接,所述显示驱动模块与微显示终端连接,所述亮度均衡控制模块与补光灯连接;所述的亮度均衡控制模块用于对来自摄像模块的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯;所述的微显示终端是0.37英寸的 LCoS透视显示器;所述的深度卷积网络服务器采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2。

[0005] 本发明中所述的深度卷积网络,其特征在于所述深度卷积网络的训练步骤具体包括:步骤一,获取带有属性及参数标记的汽车配件图像样本;步骤二,利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类;根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数;步骤三所述利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类具体为:利用预先设置有初始参数的卷积核与所述汽车配件图像样本进行卷积计算;经过池化层的池化操作以及全连接层1和全连接层2的全连接操作,得到所述汽车配件图像样本的汽车配件属性概率;所述根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数,具体为:当所述汽车配件属性概率与所述汽车配件的属性信息之间存在差异时,调整所述卷积核中的参数,直至输出的汽车配件属性概率与所述汽车配件的属性信息相符。本发明中所述的深度卷积网络,其特征在于,所述训练所述深度卷积网络的参数具体为使用深度卷积网络的训练工具通过tensorflow进行训练,从输入到输出的计算过程为:

卷积层1计算公式是  $h_{1,a}^l = f(u_{1,a}^l) = f(x^l * W^{1,a} + b^{1,a})$ , 其中  $x^l$  表示输入,  $W^{1,a}$  表



示卷积核,  $b^{1,a}$  表示偏置  $h_{1,a}^l$  表示输出;

池化层 1 计算公式是  $h_{2,a}^l = g(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,a}^l) + \gamma_2)$ , 其中  $h_{1,a}^l$  表示输入,  $\beta_2$  表示权值,  $\gamma_2$  表示偏置,  $h_{2,a}^l$  表示输出;

卷积层 2 计算公式是  $h_{3,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{2,a_i}^l * W_{a_i}^{3,\omega} + b^{3,\omega})$ , 其中池化面  $h_{2,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{3,\omega}$  表示卷积核,  $b^{3,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{3,a}^l$  表示输出;

池化 2 计算公式是  $h_{4,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_4)$ , 其中  $h_{3,a}^l$  表示输入,  $\beta_4$  表示权值,  $\gamma_4$  表示偏置,  $h_{4,a}^l$  表示输出;

卷积层 3 计算公式是  $h_{5,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{4,a_i}^l * W_{a_i}^{5,\omega} + b^{5,\omega})$ , 其中池化面  $h_{4,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{5,\omega}$  表示卷积核,  $b^{5,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{5,a}^l$  表示输出;

卷积层 4 计算公式是  $h_{6,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{5,a_i}^l * W_{a_i}^{6,\omega} + b^{6,\omega})$ , 其中池化面  $h_{5,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{6,\omega}$  表示卷积核,  $b^{6,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{6,a}^l$  表示输出;

池化 3 计算公式是  $h_{7,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_7 \text{down}_{\lambda_7, \tau_7}(h_{6,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_7)$ , 其中  $h_{6,a}^l$  表示输入,  $\beta_7$  表示权值,  $\gamma_7$  表示偏置,  $h_{7,a}^l$  表示输出;

卷积层 5 计算公式是  $h_{8,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{7,a_i}^l * W_{a_i}^{8,\omega} + b^{8,\omega})$ , 其中池化面  $h_{7,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{8,\omega}$  表示卷积核,  $b^{8,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{8,a}^l$  表示输出;

池化 4 计算公式是  $h_{9,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_9 \text{down}_{\lambda_9, \tau_9}(h_{8,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_9)$ , 其中  $h_{8,a}^l$  表示输入,  $\beta_9$  表示权值,  $\gamma_9$  表示偏置,  $h_{9,a}^l$  表示输出;

$$H_9^l = h_{9,(a_1,a_2,\dots,a_\tau)}^l;$$

$$H_k^l = \sigma(u_k^l) = \sigma(W^k H_{k-1}^l + b^k), 12 \leq k \leq R$$

所述tensorflow的参数包括:卷积层1的卷积核尺寸为 $11 \times 11$ ,颜色通道为3,卷积核数量为64,卷积步长为 $4 \times 4$ ,图片每 $4 \times 4$ 区域只取样一次,横向间隔是4,纵向间隔是4,每次取样的卷积核为 $11 \times 11$ ;池化层1的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层2的卷积核尺寸为 $5 \times 5$ ,输入通道数为64,卷积核数量为192,卷积步长为1;池化层2的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层3的卷积核尺寸为 $3 \times 3$ ,输入通道数为192,卷积核数量为384,卷积步长为1;卷积层4的卷积核尺寸为 $3 \times 3$ ,输入通道数为384,卷积核数量为256,卷积步长为1;池化层3的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层5的卷积核尺寸为 $3 \times 3$ ,输入通道数为256,卷积核数量为256,卷积步长为1;池化层4的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。

[0006] 本发明中所述的深度卷积网络,其特征在于所述深度卷积网络的运行步骤包括:

获取待识别汽车配件图像,利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像;识别通过所述卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2,于全连接层2输出节点为所述汽车配件图像的汽车配件属性概率,根据所述汽车配件属性概率确定所述待识别汽车配件图像的汽车配件属性信息。在获取待识别汽车配件图像之后、在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像之前,进一步包括:对所述待识别汽车配件图像进行预处理;所述预处理至少包括以下一种操作:裁剪、边界填充、翻转、饱和度平衡、色调平衡、对比度平衡、直方图均衡、镜像操作、随机剪切、中心化、均值化、调整大小resize;步骤包括:获取待识别汽车配件图像;训练深度卷积网络;所述深度卷积网络的网络结构包括卷积层、池化层和全连接层,所述卷积层的后面连接所述池化层,所述池化层后面连接所述全连接层,最后的全连接层上的每个输出节点为所述汽车配件图像的汽车配件属性概率;识别步骤是利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像;根据所述汽车配件属性概率确定所述待识别汽车配件图像的汽车配件属性信息。

[0007] 本发明的有益效果如下:本发明所公开的一种基于深度卷积网络的汽车配件识别装置,采用摄像模块获取待识别汽车配件图像时,亮度均衡控制模块对来自摄像模块的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯解决了深度学习图像识别技术中待识别汽车配件所处环境光线亮度以及光照角度造成阴影而产生的误差的问题;所述的微显示终端是0.37英寸的 LCoS透视显示器用于近距显示;在获取到待识别汽车配件图像之后,利用预先训练得到的深度卷积网络识别所述待识别汽车配件图像,依次经过卷积层、池化层和全连接层后得到汽车配件属性概率,从而确定汽车配件属性信息。由于本发明所提供的方案利用了深度卷积网络识别汽车配件,深度卷积网络足以刻画和区分物体,以解决现有技术中的对汽车配件识别方法单一、效率低、准确率低的问题。

[0008]

## 附图说明

[0009] 图1为本发明一种基于深度卷积网络的汽车配件识别装置中深度卷积网络的结构示意图。

[0010] 图2为本发明一种基于深度卷积网络的汽车配件识别装置的结构示意图。

[0011] 附图标记说明,图中:31.输入图像、32.卷积层1、33.池化层1、34.卷积层2、35.池化层2、36.卷积层3、37.卷积层4、38.池化层3、39.卷积层5、40.池化层4、46.全连接层1、47.全连接层2、48.输出讯息、51.微显示终端,52.摄像模块、53.补光灯、54.支架、55.待识别汽车配件、61.图像采集模块、62.亮度均衡控制模块、63.深度卷积网络服务器、64.显示驱动模块。

[0012]

## 具体实施方式

[0013] 为了使本发明的技术方案及优点更加清楚明白,以下结合附图对本发明的示例性实施例进行进一步详细的说明,显然,所描述的实施例仅是本发明的一部分实施例,而不是所有实施例的穷举。并且在不冲突的情况下,本说明中的实施及实施例中的特征可以互相

结合。

[0014] 本发明提出了一种基于深度卷积网络的汽车配件识别装置,下面进行说明。

[0015] 图1为本发明一种基于深度卷积网络的汽车配件识别装置的结构示意图,图2为本发明一种基于深度卷积网络的汽车配件识别装置中深度卷积网络的结构示意图;

如图所示,所述基于深度学习的汽车配件识别装置的实施中可以包括如下步骤:

步骤101、通过网络爬虫从指定网站中获取的已知图像样本用于训练识别汽车配件图像;

步骤102、采用摄像模块52获取待识别汽车配件55图像时,采用亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53的发光亮度,以解决深度学习图像识别技术中待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差的问题,经处理后的待识别汽车配件55图像进入深度卷积网络服务器63,利用深度卷积网络服务器63中预先训练得到的深度卷积网络识别所述待识别汽车配件55图像;所述深度卷积网络的网络结构包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2,最后的全连接层2上的每个输出节点为所述汽车配件图像的汽车配件属性概率;

步骤103、根据所述汽车配件属性概率确定所述待识别汽车配件55图像的汽车配件属性信息,输出讯息,输出讯息由深度卷积网络服务器63到显示驱动模块64到微显示终端51。

[0016] 其中,深度学习(deep learning)属于神经网络的一种,近年来在计算机视觉、语音识别等领域有较多应用,它是一种解决训练问题的深层神经网络,本发明实施例中的深度卷积网络可以包括卷积层、池化层和全连接层这三个层次,其中:卷积层(Convolution),通过卷积运算使得原信号特征增强并降低噪音,采用tensorflow能对卷积层中的卷积运算进行加速的效果提高了基于深度学习的汽车配件识别装置的运行效率,在本实施例中用tf.nn.conv2d函数。池化层(Pooling),减小过拟合,通过减小输入的尺寸来提高性能,对输入降采样,并为后续层保留重要信息,主要采用tensorflow来减小输入的尺寸,实现池化层的效率,本实施例中用tf.nn.max\_pool和tf.nn.avg\_pool函数。全连接层(Full Connected),全连接层的每个神经元都与下一层的每个神经元相连,将所述待识别汽车配件55图像作为输入,从输入层到卷积层通过卷积操作,通过卷积后获得了所述待识别汽车配件55图像的特征;从卷积层到池化层的过程可以称为池化过程,目的在于减少上一层的特征数量;经过卷积层和池化层之后得到的特征会由全连接层进行分类,经过全连接层的计算处理,最终输出结果。所述全连接层上的每个输出节点为所述汽车配件图像的汽车配件属性概率,即每个输出节点上输出的是该汽车配件属于某个属性的概率,例如:第一个输出节点为该汽车配件属于汽车皮碗的概率、第二个输出节点为该汽车配件属于制动气室隔膜的概率等,最终根据汽车配件属性概率确定出该汽车配件的属性信息,即,根据概率大小确定出该汽车配件具体属于哪种名称,例如:第一个输出节点为该汽车配件属于汽车皮碗的概率为90%,其他节点输出的概率均小于90%,则可以确定该汽车配件为汽车皮碗。本发明实施例所提供的汽车配件识别方法及装置,在获取到待识别汽车配件55图像之后,无需用户手动定义特征再进行分类,直接利用预先训练得到的深度卷积网络即可识别所述待识别汽车配件55图像,依次经过卷积层、池化层和全连接层后得到汽车配件属性概率,从而确定汽车配件属性信息。由于本发明实施例所提供的方案利用的是深度卷积网络识别汽车配



件,深度卷积网络足以刻画和区分物体,相比现有的人工定义特征进行分类的方式准确性更高。

[0017] 在实施例中,用于训练的图像样本的来源可以为很多方式,比如用网络爬虫从网上收集、汽车配件图册或自行拍摄;本实施例中通过网络爬虫从指定网站中获取的已知图像样本后,再采用手工标注的方式进行标注,所述标记包括汽车配件的属性信息。利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类;根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数。

[0018] 具体实施时,可以获取若干汽车配件图像样本,这些样本可以包括各类汽车配件图像,标记汽车配件的属性信息,属性信息中包括名称。例如:获取近2000类汽车配件图像,将近2000类汽车配件图像进行人工标定,标定数据的图像数量可以大于2万张。然后利用预先设置有初始参数的深度卷积网络对所述汽车配件图像进行softmax分类,计算各个样本属于的汽车配件类别的概率,使用tf.argmax函数选择预测的输出值中具有最大概率的那个类别,将tf.equal与期望的类别进行比较,使用tf.reduce\_mean计算准确率,经实验准确率可以达到约95%。

[0019] 所述深度卷积网络的全连接层上的每一个输出节点对应该图片是相应汽车配件类别的概率。将输出概率与真实标记(可以为与输出概率等长数组)进行比较,计算二者的差异。具体实施时,利用交叉熵损失函数来度量模型输出结果与真实值之间的差异。将该差异反逐层反传到所述深度卷积网络中,进行模型的参数训练。本发明实施例利用深度卷积网络模型不断训练参数,从而使得所述深度卷积网络可以精确的识别汽车配件,无需人工参与即可利用机器深度学习自动达到分类的目的。实施中,所述利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类,具体可以为:利用预先设置有初始参数的卷积核与所述汽车配件图像样本进行卷积计算;经过池化层的池化操作以及全连接层的全连接操作,得到所述汽车配件图像样本的汽车配件属性概率;所述根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数,具体可以为:当所述汽车配件属性概率与所述汽车配件的属性信息之间存在差异时,调整所述卷积核中的参数,直至输出的汽车配件属性概率与所述汽车配件的属性信息相符。例如:假设输出的汽车配件属性概率为汽车皮碗的概率最大,如果所述预先标记的汽车配件属性信息为制动气室隔膜,那么重新调整所述卷积核中的参数,再进行卷积层、池化层、全连接层的识别,直至所述输出的汽车配件属性概率为汽车皮碗最大,与所述真实的汽车配件属性信息相符,完成所述卷积核参数的训练。

[0020]

在具体实施时,在所述深度卷积网络的训练步骤具体包括:步骤一,获取带有属性及参数标记的汽车配件图像样本;步骤二,利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类;根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数;步骤三所述利用预先设置有初始参数的深度卷积网络对所述汽车配件图像样本进行分类具体为:利用预先设置有初始参数的卷积核与所述汽车配件图像样本进行卷积计算;经过池化层的池化操作以及全连接层1和全连接层2的全连接操作,得到所述汽车配件图像样本的汽车配件属性概

率;所述根据所述深度卷积网络输出结果与所述汽车配件的属性信息之间的差异逐层反传至所述深度卷积网络,训练所述深度卷积网络的参数,具体为:当所述汽车配件属性概率与所述汽车配件的属性信息之间存在差异时,调整所述卷积核中的参数,直至输出的汽车配件属性概率与所述汽车配件的属性信息相符。

[0021]

本发明实施中

所述训练所述深度卷积网络的参数具体为使用深度卷积网络的训练工具通过tensorflow进行训练,从输入到输出的计算过程为:

卷积层 1 计算公式是  $h_{1,a}^l = f(u_{1,a}^l) = f(x^l \otimes W^{1,a} + b^{1,a})$ , 其中  $x^l$  表示输入,  $W^{1,a}$  表示卷积核,  $b^{1,a}$  表示偏置  $h_{1,a}^l$  表示输出;

池化层 1 计算公式是  $h_{2,a}^l = g(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,a}^l) + \gamma_2)$ , 其中  $h_{1,a}^l$  表示输入,  $\beta_2$  表示权值,  $\gamma_2$  表示偏置,  $h_{2,a}^l$  表示输出;

卷积层 2 计算公式是  $h_{3,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{2,a_i}^l \otimes W_{a_i}^{3,\omega} + b^{3,\omega})$ , 其中池化面  $h_{2,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{3,\omega}$  表示卷积核,  $b^{3,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{3,a}^l$  表示输出;

池化 2 计算公式是  $h_{4,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_4)$ , 其中  $h_{3,a}^l$  表示输入,  $\beta_4$  表示权值,  $\gamma_4$  表示偏置,  $h_{4,a}^l$  表示输出;

卷积层 3 计算公式是  $h_{5,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{4,a_i}^l \otimes W_{a_i}^{5,\omega} + b^{5,\omega})$ , 其中池化面  $h_{4,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{5,\omega}$  表示卷积核,  $b^{5,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{5,a}^l$  表示输出;

卷积层 4 计算公式是  $h_{6,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{5,a_i}^l \otimes W_{a_i}^{6,\omega} + b^{6,\omega})$ , 其中池化面  $h_{5,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{6,\omega}$  表示卷积核,  $b^{6,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{6,a}^l$  表示输出;

池化 3 计算公式是  $h_{7,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_7 \text{down}_{\lambda_7, \tau_7}(h_{6,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_7)$ , 其中  $h_{6,a}^l$  表示输入,  $\beta_7$  表示权值,  $\gamma_7$  表示偏置,  $h_{7,a}^l$  表示输出;

卷积层 5 计算公式是  $h_{8,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{7,a_i}^l \otimes W_{a_i}^{8,\omega} + b^{8,\omega})$ , 其中池化面  $h_{7,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{8,\omega}$  表示卷积核,  $b^{8,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$ ,  $h_{8,a}^l$  表示输出;

池化 4 计算公式是  $h_{9,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_9 \text{down}_{\lambda_9, \tau_9}(h_{8,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_9)$ , 其中  $h_{8,a}^l$  表

示输入,  $\beta_g$  表示权值,  $\gamma_g$  表示偏置,  $h_{g,a}^l$  表示输出;

$$H_g^l = h_{g,(\alpha_1, \alpha_2, \dots, \alpha_r)}^l;$$

$$H_k^l = \sigma(u_k^l) = \sigma(W^k H_{k-1}^l + b^k), 12 \leq k \leq R$$

所述tensorflow的参数包括:卷积层1的卷积核尺寸为 $11 \times 11$ ,颜色通道为3,卷积核数量为64,卷积步长为 $4 \times 4$ ,图片每 $4 \times 4$ 区域只取样一次,横向间隔是4,纵向间隔是4,每次取样的卷积核为 $11 \times 11$ ;池化层1的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层2的卷积核尺寸为 $5 \times 5$ ,输入通道数为64,卷积核数量为192,卷积步长为1;池化层2的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层3的卷积核尺寸为 $3 \times 3$ ,输入通道数为192,卷积核数量为384,卷积步长为1;卷积层4的卷积核尺寸为 $3 \times 3$ ,输入通道数为384,卷积核数量为256,卷积步长为1;池化层3的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层5的卷积核尺寸为 $3 \times 3$ ,输入通道数为256,卷积核数量为256,卷积步长为1;池化层4的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。

[0022] 根据所述初始参数的卷积核进行卷积计算,在经过池化层、全连接层,最终输出所述汽车配件图像样本的汽车配件属性概率。判断所述输出的汽车配件属性概率是否与所述汽车配件的属性信息相符或一致,当图像的汽车配件属性概率与所述汽车配件的属性信息之间存在差异时,调整所述卷积计算的参数,直至输出的汽车配件属性概率与所述汽车配件的属性信息相符。例如:假设输出的汽车配件属性概率为汽车皮碗的概率最大,如果所述预先标记的汽车配件属性信息为制动气室隔膜,那么重新调整所述卷积核中的参数,再进行卷积层、池化层、全连接层的识别,直至所述输出的汽车配件属性概率为汽车皮碗最大,与所述真实的汽车配件属性信息相符,完成所述卷积核参数的训练。实施中,所述训练所述深度卷积网络的参数具体可以为使用深度网络训练工具 tensorflow进行训练,所述tensorflow的参数包括:学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。

[0023] 具体实施时,可以采用深度网络训练工具tensorflow进行模型训练,TensorFlow是相对高阶的机器学习库,支持自动求导,简化了线上部署的复杂度,并让手机这种内存和CPU资源都紧张的设备可以运行复杂模型。

[0024] 使用tensorflow时参数可以设置为如下所示:学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。本发明实施例采用深度网络训练工具对模型进行训练,发明人通过试验发现学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005时训练效果最佳。

[0025] 在实施中,所述的深度卷积网络服务器63采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2;最后一个全连接层的输出个数为汽车配件属性分类的数目。本发明实施例所设计的深度卷积网络,在确保所述深度卷积网络的计算量适中的同时提升了分类识别的准确性,克服浅层网络特征提取不充分的问题。实施中,所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像具体可以为:在卷积层,将所述待识别汽车配件55图像与预先训练得到的卷积核进行卷积计算,输出一个或多个特征图像;在池化层,对所述卷积层的输出进行池化操作;在全连接层,对所述上一层的输出进行全连接操作,所

述最后的全连接层的节点个数与汽车配件属性分类的数目相同;对所述最后的全连接层的输出进行分类,得到汽车配件属性概率。

[0026]

实施例1,一种基于深度卷积网络的汽车配件识别装置,包括摄像模块52、图像采集模块61、亮度均衡控制模块62、深度卷积网络服务器63、显示驱动模块64、微显示终端51、补光灯53,其特征在于所述的摄像模块52与图像采集模块61连接,所述的图像采集模块61与亮度均衡控制模块62连接,所述的亮度均衡控制模块62与深度卷积网络服务器63连接,所述的深度卷积网络服务器63与显示驱动模块64连接,所述显示驱动模块64与微显示终端51连接,所述亮度均衡控制模块62与补光灯53连接;

所述的亮度均衡控制模块62用于对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53;

所述的微显示终端51是0.37英寸的 LCoS透视显示器用于近距显示;

所述的深度卷积网络服务器63采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2;

所述深度卷积网络的运行步骤包括:采用摄像模块52获取待识别汽车配件55图像时,亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;

所述的微显示终端51是0.37英寸的 LCoS透视显示器用于近距显示;

获取待识别汽车配件55图像,利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像;识别通过所述卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2,于全连接层2输出节点为所述汽车配件图像的汽车配件属性概率,根据所述汽车配件属性概率确定所述待识别汽车配件55图像的汽车配件属性信息。在获取待识别汽车配件55图像之后、在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像之前,进一步包括:对所述待识别汽车配件55图像进行预处理;所述预处理至少包括以下一种操作:裁剪、边界填充、翻转、饱和度平衡、色调平衡、对比度平衡、直方图均衡、镜像操作、随机剪切、中心化、均值化、调整大小resize。步骤包括:获取模块,用于获取待识别汽车配件55图像;训练模块,用于训练深度卷积网络;所述深度卷积网络的网络结构包括卷积层、池化层和全连接层,所述卷积层的后面连接所述池化层,所述池化层后面连接所述全连接层,最后的全连接层上的每个输出节点为所述汽车配件图像的汽车配件属性概率;识别步骤是利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像;确定步骤是根据所述汽车配件属性概率确定所述待识别汽车配件55图像的汽车配件属性信息。

[0027] 全连接层结点均为 4096。输出层结点数依据待识别汽车配件55类别数而定,即根据应用场景实际情况的经验或历史数据而定。例如,根据经验,汽车配件种类约为2000种,则应用于汽车配件识别时,输出成接点数定为2000。实施中,在获取待识别汽车配件55图像之后、在所述利用预先训练得到的深度卷积网络。

[0028] 识别所述待识别汽车配件55图像之前,所述方法可以包括:所述预先训练得到的



卷积核可以与某种汽车配件属性相对应,所述待识别汽车配件55图像可以分别与多个卷积核进行卷积计算,从而最后输出该待识别汽车配件55图像为不同种类的汽车配件属性的概率。

[0029] 实施中,在获取待识别汽车配件55图像之后,在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像之前,所述方法可以进一步包括:对所述待识别汽车配件55图像进行预处理;所述预处理至少包括以下一种操作:旋转、直方图均衡、白平衡、镜像操作、随机剪切、中心化、均值化、调整大小resize。

[0030] 本发明实施中采用摄像模块52获取待识别汽车配件55图像时,亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;通过在识别图像之前先对所述待识别汽车配件55图像进行预处理,从而改进后续识别的可靠性。

[0031] 下面以实例进行说明。具体实施时,本发明实施例中的汽车配件识别过程可以为连续作业,摄像模块52连续获取待识别汽车配件55图像进行识别,具体如下:步骤一、摄像模块52拍摄待识别汽车配件55图像,以汽车皮碗为例;步骤二、图像采集模块61将摄像模块52拍摄的图像进行模数转换及对比度均衡;

步骤三、亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53的补光量,解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;

步骤四、亮度均衡控制模块62将待识别汽车配件55图像传送给深度卷积网络服务器63进行汽车配件识别;深度卷积网络服务器63采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2;

所述训练所述深度卷积网络的参数具体为使用深度卷积网络的训练工具通过tensorflow进行训练,从输入到输出的计算过程为:

卷积层1计算公式是  $h_{1,a}^l = f(u_{1,a}^l) = f(x^l \otimes W^{1,a} + b^{1,a})$ , 其中  $x^l$  表示输入,  $W^{1,a}$  表示卷积核,  $b^{1,a}$  表示偏置  $h_{1,a}^l$  表示输出;

池化层1计算公式是  $h_{2,a}^l = g(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,a}^l) + \gamma_2)$ , 其中  $h_{1,a}^l$  表示输入,  $\beta_2$  表示权值,  $\gamma_2$  表示偏置,  $h_{2,a}^l$  表示输出;

卷积层2计算公式是  $h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{2,\alpha_i}^l \otimes W_{\alpha_i}^{3,\omega} + b^{3,\omega})$ , 其中池化面  $h_{2,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{3,\omega}$  表示卷积核,  $b^{3,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \dots \alpha_\tau)$ ,  $h_{3,a}^l$  表示输出;

池化2计算公式是  $h_{4,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_4)$ , 其中  $h_{3,a}^l$  表示输入,  $\beta_4$  表示权值,  $\gamma_4$  表示偏置,  $h_{4,a}^l$  表示输出;



卷积层3计算公式是  $h_{5,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{4,a_i}^l \otimes W_{a_i}^{5,\omega} + b^{5,\omega})$  , 其中池化面  $h_{4,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{5,\omega}$  表示卷积核,  $b^{5,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$  ,  $h_{5,a}^l$  表示输出;

卷积层4计算公式是  $h_{6,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{5,a_i}^l \otimes W_{a_i}^{6,\omega} + b^{6,\omega})$  , 其中池化面  $h_{5,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{6,\omega}$  表示卷积核,  $b^{6,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$  ,  $h_{6,a}^l$  表示输出;

池化3计算公式是  $h_{7,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_7 \text{down}_{\lambda_7, \tau_7}(h_{6,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_7)$  , 其中  $h_{6,a}^l$  表示输入,  $\beta_7$  表示权值,  $\gamma_7$  表示偏置,  $h_{7,a}^l$  表示输出;

卷积层5计算公式是  $h_{8,(a_1,a_2,\dots,a_\tau)}^l = f(\sum_{i=0}^{\tau} h_{7,a_i}^l \otimes W_{a_i}^{8,\omega} + b^{8,\omega})$  , 其中池化面  $h_{7,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{a_i}^{8,\omega}$  表示卷积核,  $b^{8,\omega}$  表示偏置, 其中  $\omega = (a_1, a_2 \dots a_\tau)$  ,  $h_{8,a}^l$  表示输出;

池化4计算公式是  $h_{9,(a_1,a_2,\dots,a_\tau)}^l = g(\beta_9 \text{down}_{\lambda_9, \tau_9}(h_{8,(a_1,a_2,\dots,a_\tau)}^l) + \gamma_9)$  , 其中  $h_{8,a}^l$  表示输入,  $\beta_9$  表示权值,  $\gamma_9$  表示偏置,  $h_{9,a}^l$  表示输出;

$$H_9^l = h_{9,(a_1,a_2,\dots,a_\tau)}^l ;$$

$$H_k^l = \sigma(u_k^l) = \sigma(W^k H_{k-1}^l + b^k), 12 \leq k \leq R$$

所述tensorflow的参数包括:卷积层1的卷积核尺寸为 $11 \times 11$ ,颜色通道为3,卷积核数量为64,卷积步长为 $4 \times 4$ ,图片每 $4 \times 4$ 区域只取样一次,横向间隔是4,纵向间隔是4,每次取样的卷积核为 $11 \times 11$ ;池化层1的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层2的卷积核尺寸为 $5 \times 5$ ,输入通道数为64,卷积核数量为192,卷积步长为1;池化层2的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层3的卷积核尺寸为 $3 \times 3$ ,输入通道数为192,卷积核数量为384,卷积步长为1;卷积层4的卷积核尺寸为 $3 \times 3$ ,输入通道数为384,卷积核数量为256,卷积步长为1;池化层3的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层5的卷积核尺寸为 $3 \times 3$ ,输入通道数为256,卷积核数量为256,卷积步长为1;池化层4的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;学习率为 $0.007 \sim 0.01$ ,学习动量项为 $0.91 \sim 0.95$ ,权重衰减系数为 $0.0004 \sim 0.0005$ 。全连接层结点均为4096。输出层结点数依据待识别汽车配件55类别数而定,即根据应用场景实际情况的经验或历史数据而定。例如,根据经验,汽车配件种类约为2000种,则应用于汽车配件识别时,输出成接点数定为2000。

[0032] 采用本发明实施例所提供的模型可以区分出将近2000类的汽车配件,运行实验的准确率 $>90\%$ 。

[0033] 实施例2,一种基于深度卷积网络的汽车配件识别装置,包括摄像模块52、图像采集模块61、亮度均衡控制模块62、深度卷积网络服务器63、显示驱动模块64、微显示终端51、

补光灯53,其特征在于所述的摄像模块52与图像采集模块61连接,所述的图像采集模块61与亮度均衡控制模块62连接,所述的亮度均衡控制模块62与深度卷积网络服务器63连接,所述的深度卷积网络服务器63与显示驱动模块64连接,所述显示驱动模块64与微显示终端51连接,所述亮度均衡控制模块62与补光灯53连接;所述的亮度均衡控制模块62用于对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53;所述的微显示终端51是0.37英寸的 LCoS透视显示器用于近距显示;所述的深度卷积网络服务器63采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2;所述的一种基于深度卷积网络的汽车配件识别装置中摄像模块52、微显示终端51、补光灯53安装在眼镜外型的支架54上。

[0034] 所述深度卷积网络的运行步骤包括:采用摄像模块52获取待识别汽车配件55图像时,亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;所述的微显示终端51是0.37英寸的 LCoS透视显示器用于近距显示,使用 LCoS透视显示器,直接安装在支架54上,使用时能同时观看到样本和获得输出讯息;获取待识别汽车配件55图像,利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像;识别通过所述卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2,于全连接层2输出节点为所述汽车配件图像的汽车配件属性概率,根据所述汽车配件属性概率确定所述待识别汽车配件55图像的汽车配件属性信息。在获取待识别汽车配件55图像之后、在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像之前,进一步包括:对所述待识别汽车配件55图像进行预处理;所述预处理至少包括以下一种操作:裁剪、边界填充、翻转、饱和度平衡、色调平衡、对比度平衡、直方图均衡、镜像操作、随机剪切、中心化、均值化、调整大小resize。步骤包括:获取模块,用于获取待识别汽车配件55图像;训练模块,用于训练深度卷积网络;所述深度卷积网络的网络结构包括卷积层、池化层和全连接层,所述卷积层的后面连接所述池化层,所述池化层后面连接所述全连接层,最后的全连接层上的每个输出节点为所述汽车配件图像的汽车配件属性概率;识别步骤是利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像;确定步骤是根据所述汽车配件属性概率确定所述待识别汽车配件55图像的汽车配件属性信息。

[0035] 全连接层结点均为 4096。输出层结点数依据待识别汽车配件55类别数而定,即根据应用场景实际情况的经验或历史数据而定。例如,根据经验,汽车配件种类约为2000种,则应用于汽车配件识别时,输出成接点数定为2000。实施中,在获取待识别汽车配件55图像之后、在所述利用预先训练得到的深度卷积网络。

[0036] 识别所述待识别汽车配件55图像之前,所述方法可以包括:所述预先训练得到的卷积核可以与某种汽车配件属性相对应,所述待识别汽车配件55图像可以分别与多个卷积核进行卷积计算,从而最后输出该待识别汽车配件55图像为不同种类的汽车配件属性的概率。

[0037] 实施中,在获取待识别汽车配件55图像之后,在所述利用预先训练得到的深度卷积网络识别所述待识别汽车配件55图像之前,所述方法可以进一步包括:对所述待识别汽

车配件55图像进行预处理;所述预处理至少包括以下一种操作:旋转、直方图均衡、白平衡、镜像操作、随机剪切、中心化、均值化、调整大小resize。

[0038] 本发明实施中采用摄像模块52获取待识别汽车配件55图像时,亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;通过在识别图像之前先对所述待识别汽车配件55图像进行预处理,从而改进后续识别的可靠性。

[0039] 下面以实例进行说明。具体实施时,本发明实施例中的汽车配件识别过程可以为连续作业,摄像模块52连续获取待识别汽车配件55图像进行识别,具体如下:步骤一、摄像模块52拍摄待识别汽车配件55图像,以汽车皮碗为例;步骤二、图像采集模块61将摄像模块52拍摄的图像进行模数转换及对比度均衡;

步骤三、亮度均衡控制模块62对来自摄像模块52的图像亮度平均值进行检测,根据亮度平均值结果控制补光灯53的补光量,解决了待识别汽车配件55所处环境光线亮度以及光照角度造成阴影而产生的误差;

步骤四、亮度均衡控制模块62将待识别汽车配件55图像传送给深度卷积网络服务器63进行汽车配件识别;深度卷积网络服务器63采用深度卷积网络,所述深度卷积网络包括卷积层1、池化层1、卷积层2、池化层2、卷积层3、卷积层4、池化层3、卷积层5、池化层4、全连接层1和全连接层2;

所述训练所述深度卷积网络的参数具体为使用深度卷积网络的训练工具通过tensorflow进行训练,从输入到输出的计算过程为:

卷积层1计算公式是  $h_{1,a}^l = f(u_{1,a}^l) = f(x^l * W^{1,a} + b^{1,a})$ , 其中  $x^l$  表示输入,  $W^{1,a}$  表示卷积核,  $b^{1,a}$  表示偏置,  $h_{1,a}^l$  表示输出;

池化层1计算公式是  $h_{2,a}^l = g(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,a}^l) + \gamma_2)$ , 其中  $h_{1,a}^l$  表示输入,  $\beta_2$  表示权值,  $\gamma_2$  表示偏置,  $h_{2,a}^l$  表示输出;

卷积层2计算公式是  $h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{2,\alpha_i}^l * W_{\alpha_i}^{3,\omega} + b^{3,\omega})$ , 其中池化面  $h_{2,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{3,\omega}$  表示卷积核,  $b^{3,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \dots \alpha_\tau)$ ,  $h_{3,a}^l$  表示输出;

池化2计算公式是  $h_{4,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_4)$ , 其中  $h_{3,a}^l$  表示输入,  $\beta_4$  表示权值,  $\gamma_4$  表示偏置,  $h_{4,a}^l$  表示输出;

卷积层3计算公式是  $h_{5,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{4,\alpha_i}^l * W_{\alpha_i}^{5,\omega} + b^{5,\omega})$ , 其中池化面  $h_{4,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{5,\omega}$  表示卷积核,  $b^{5,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \dots \alpha_\tau)$ ,  $h_{5,a}^l$  表示输出;

卷积层4计算公式是  $h_{6,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{5,\alpha_i}^l * W_{\alpha_i}^{6,\omega} + b^{6,\omega})$ , 其中池化面

$h_{5,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{6,\omega}$  表示卷积核,  $b^{6,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \cdots \alpha_\tau)$ ,  $h_{6,a}^l$  表示输出;

池化 3 计算公式是  $h_{7,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_7 \text{down}_{\lambda_7, \tau_7}(h_{6,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_7)$ , 其中  $h_{6,a}^l$  表示输入,  $\beta_7$  表示权值,  $\gamma_7$  表示偏置,  $h_{7,a}^l$  表示输出;

卷积层 5 计算公式是  $h_{8,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = f(\sum_{i=0}^{\tau} h_{7,\alpha_i}^l \otimes W_{\alpha_i}^{8,\omega} + b^{8,\omega})$ , 其中池化面  $h_{7,a}^l$  ( $1 \leq i \leq \tau$ ) 是输入,  $W_{\alpha_i}^{8,\omega}$  表示卷积核,  $b^{8,\omega}$  表示偏置, 其中  $\omega = (\alpha_1, \alpha_2 \cdots \alpha_\tau)$ ,  $h_{9,a}^l$  表示输出;

池化 4 计算公式是  $h_{9,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l = g(\beta_9 \text{down}_{\lambda_9, \tau_9}(h_{8,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l) + \gamma_9)$ , 其中  $h_{8,a}^l$  表示输入,  $\beta_9$  表示权值,  $\gamma_9$  表示偏置,  $h_{9,a}^l$  表示输出;

$$H_9^l = h_{9,(\alpha_1, \alpha_2, \dots, \alpha_\tau)}^l;$$

$$H_k^l = \sigma(u_k^l) = \sigma(W^k H_{k-1}^l + b^k), 12 \leq k \leq R$$

所述tensorflow的参数包括:卷积层1的卷积核尺寸为 $11 \times 11$ ,颜色通道为3,卷积核数量为64,卷积步长为 $4 \times 4$ ,图片每 $4 \times 4$ 区域只取样一次,横向间隔是4,纵向间隔是4,每次取样的卷积核为 $11 \times 11$ ;池化层1的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层2的卷积核尺寸为 $5 \times 5$ ,输入通道数为64,卷积核数量为192,卷积步长为1;池化层2的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层3的卷积核尺寸为 $3 \times 3$ ,输入通道数为192,卷积核数量为384,卷积步长为1;卷积层4的卷积核尺寸为 $3 \times 3$ ,输入通道数为384,卷积核数量为256,卷积步长为1;池化层3的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;卷积层5的卷积核尺寸为 $3 \times 3$ ,输入通道数为256,卷积核数量为256,卷积步长为1;池化层4的池化尺寸为 $3 \times 3$ ,取样步长为 $2 \times 2$ ;学习率为0.007~0.01,学习动量项为0.91~0.95,权重衰减系数为0.0004~0.0005。全连接层结点均为4096。输出层结点数依据待识别汽车配件55类别数而定,即根据应用场景实际情况的经验或历史数据而定。例如,根据经验,汽车配件种类约为2000种,常用品种为1000种则应用于汽车配件识别时,输出成接点数定为500。

[0040] 采用本发明实施例所提供的模型可以区分出1000类的汽车配件,运行实验的准确率 $>90\%$ 。

[0041] 本发明实施例采用了深度网络,由于深度网络有着一层层提取物体特征的优势,相比现有的浅层网络更能提取出待识别汽车配件的本质特征,从而提升了模型效果,采用本发明实施例所提供的技术方案进行识别在一定程度上提高了准确性,降低了误识别和漏识别现象。






图1




图2