



# (12)发明专利申请

(10)申请公布号 CN 107229787 A

(43)申请公布日 2017. 10. 03

(21)申请号 201710373342.1

(22)申请日 2017.05.24

(71)申请人 南京航空航天大学

地址 211106 江苏省南京市江宁区将军大道29号

(72)发明人 龚频 何建平 汤晓斌 王鹏  
韩镇阳

(74)专利代理机构 南京钟山专利代理有限公司  
32252

代理人 戴朝荣

(51)Int.Cl.

G06F 17/50(2006.01)

G06N 3/08(2006.01)

G01T 1/36(2006.01)


权利要求书1页 说明书7页 附图6页

## (54)发明名称

一种基于近似系数与深度学习的伽马能谱分析方法

## (57)摘要

本发明公开了一种基于近似系数与深度学习的伽马能谱分析方法,包括以下步骤:采用蒙特卡洛方法对伽马探测器进行建模并模拟感兴趣核素能谱,得到模拟能谱;使用伽马探测器测量能谱,对能谱进行平滑处理和按照时间比例本底扣除,得到净计数谱;采用小波分解方法提取模拟能谱的近似系数,对模拟能谱的近似系数进行归一化处理,采用小波分解方法提取净计数谱的近似系数,对净计数谱的近似系数进行归一化处理;将模拟能谱的近似系数作为深度学习网络的训练样本从而预测伽马探测器实测的能谱中核素的组成。本发明通过提取模拟能谱的近似系数,采用模拟样本训练深度学习并将其用于实测能谱核素组成预测,以达到快速、稳定的能谱核素识别。



1. 一种基于近似系数与深度学习的伽马能谱分析方法,其特征在于:包括以下步骤:

步骤1:采用蒙特卡洛方法对伽马探测器进行建模并模拟感兴趣核素能谱,得到模拟能谱;

步骤2:使用伽马探测器测量实际的能谱,并采用平滑算法对测量的能谱进行平滑处理,对平滑处理后的能谱按照时间比例本底扣除,得到净计数谱;

步骤3:采用小波分解方法提取步骤1中模拟能谱的近似系数,对模拟能谱的近似系数进行归一化处理,采用小波分解方法提取步骤2中净计数谱的近似系数,对净计数谱的近似系数进行归一化处理;

步骤4:将步骤3中归一化处理后的模拟能谱的近似系数作为深度学习网络的训练样本从而建立深度学习模型,将归一化后的净计数谱的近似系数作为深度学习模型的输入向量从而预测步骤2中的伽马探测器实测的能谱中核素的组成。

2. 根据权利要求1所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述蒙特卡洛方法采用蒙特卡洛程序,所述蒙特卡洛程序采用MORSE、MCNP、EGS、GEANT4、FLUKA、SuperMC、Phits或GADRAS中的一种或几种。

3. 根据权利要求1所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述平滑算法采用重心法、高斯滤波法、最小二乘滤波法、小波平滑法、移动平均值法、粒子滤波法或卡尔曼滤波法中的一种或几种。

4. 根据权利要求1所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述小波分解方法采用的小波分解母函数为Daubechies、Coiflets、Symlets、Fejer-Korovkin filters、Discrete Meyer、Biorthogonal或Reverse Biorthogonal中的一种或几种。

5. 根据权利要求4所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述小波分解方法采用的小波分解级数为1、2、3、4或5中的一种或几种。

6. 根据权利要求1所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述步骤3中的对模拟能谱的近似系数进行归一化处理采用线性函数归一化或0均值标准化。

7. 根据权利要求1所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述的步骤4中的深度学习网络采用深度置信网络、深度神经网络、卷积神经网络、堆叠式自动编码器或卷积自动编码器中的一种或几种。

8. 根据权利要求7所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述的步骤4中的深度学习网络采用的深度学习框架为DeepLearnToolbox、Caffe、CNTK、TensorFlow、Theano、Torch、Keras、Lasagne、DSSTNE、MXNet、DeepLearning4J、ConvNetJS、Chainer或Scikit-Learn中的一种或多种。

9. 根据权利要求8所述的基于近似系数与深度学习的伽马能谱分析方法,其特征在于:所述深度学习网络包括3层神经网络,3层神经网络分别为输入层、隐含层和输出层,所述隐含层的个数为1-50。

## 一种基于近似系数与深度学习的伽马能谱分析方法

### 技术领域

[0001] 本发明属于伽马能谱分析领域,具体涉及一种基于近似系数与深度学习的伽马能谱分析方法。

### 背景技术

[0002] 伽马能谱分析的精确性与可靠性在很大程度上取决于对重叠峰的处理,核素特征峰位作为伽马能谱信息主要携带者,通常会存在相互重叠的情况。由于伽马探测器能量分辨率的限制及天然本底辐射的干扰,从重叠峰严重的伽马能谱中提取有效的信息变得十分困难。虽然传统神经网络将全谱输入可以解决这一难题,但由于其隐含层个数的限制,使其学习能力及预测能力较低,需要手动进行特征提取,以降低数据维度。

### 发明内容

[0003] 本发明所要解决的技术问题是针对上述现有技术的不足提供一种基于近似系数与深度学习的伽马能谱分析方法,本基于近似系数与深度学习的伽马能谱分析方法通过提取模拟能谱的近似系数,采用模拟样本训练深度学习并将其用于实测能谱核素组成预测,以达到快速、稳定的能谱核素识别。

[0004] 为实现上述技术目的,本发明采取的技术方案为:

[0005] 一种基于近似系数与深度学习的伽马能谱分析方法,包括以下步骤:

[0006] 步骤1:采用蒙特卡洛方法对伽马探测器进行建模并模拟感兴趣核素能谱,得到模拟能谱;

[0007] 步骤2:使用伽马探测器测量实际的能谱,并采用平滑算法对测量的能谱进行平滑处理,对平滑处理后的能谱按照时间比例本底扣除,得到净计数谱。

[0008] 步骤3:采用小波分解方法提取步骤1中模拟能谱的近似系数,对模拟能谱的近似系数进行归一化处理,采用小波分解方法提取步骤2中净计数谱的近似系数,对净计数谱的近似系数进行归一化处理。

[0009] 步骤4:将步骤3中归一化处理后的模拟能谱的近似系数作为深度学习网络的训练样本从而建立深度学习模型,将归一化后的净计数谱的近似系数作为深度学习模型的输入向量从而预测步骤2中的伽马探测器实测的能谱中核素的组成。

[0010] 作为本发明进一步改进的技术方案,所述蒙特卡洛方法为蒙特卡洛程序,所述蒙特卡洛程序采用MORSE、MCNP、EGS、GEANT4、FLUKA、SuperMC、Phits或GADRAS中的一种或几种。

[0011] 作为本发明进一步改进的技术方案,所述平滑算法采用重心法、高斯滤波法、最小二乘滤波法、小波平滑法、移动平均值法、粒子滤波法或卡尔曼滤波法中的一种或几种。

[0012] 作为本发明进一步改进的技术方案,所述小波分解方法采用的小波分解母函数为Daubechies、Coiflets、Symlets、Fejer-Korovkin filters、Discrete Meyer、Biorthogonal或Reverse Biorthogonal中的一种或几种。

[0013] 作为本发明进一步改进的技术方案,所述小波分解方法采用的小波分解级数为1、2、3、4或5中的一种或几种。

[0014] 作为本发明进一步改进的技术方案,所述步骤3中的对模拟能谱的近似系数进行归一化 处理采用线性函数归一化或0均值标准化。

[0015] 作为本发明进一步改进的技术方案,所述的步骤4中的深度学习网络采用深度置信网络、深度神经网络、卷积神经网络、堆叠式自动编码器或卷积自动编码器中的一种或几种。

[0016] 作为本发明进一步改进的技术方案,所述的步骤4中的深度学习网络采用的深度学习框架为DeepLearnToolbox、Caffe、CNTK、TensorFlow、Theano、Torch、Keras、Lasagne、DSSTNE、MXNet、DeepLearning4J、ConvNetJS、Chainer或Scikit-Learn中的一种或多种。

[0017] 作为本发明进一步改进的技术方案,所述深度学习网络包括3层神经网络,3层神经网络分别为输入层、隐含层和输出层,所述隐含层的个数为1-50。

[0018] 本发明与现有技术相比,具有以下优点和效果:

[0019] (1) 本发明采用小波分解技术提取模拟能谱的近似系数和净计数谱的近似系数,在保留 原始能谱形状的条件下,有效的减少了噪声的干扰及信号维度;

[0020] (2) 本发明采用模拟能谱的近似系数进行训练深度学习,克服了实验室放射源数量不足 的难题,可用于多种( $\geq 9$ )核素的稳定识别;

[0021] (3) 本发明具有不受探测时间、探测距离和核素个数的影响,识别速度快( $\geq 1s$ )、探测率高等优点,可用于门式辐射监测器、核素识别仪以及其他辐射监测设备;

[0022] (4) 本发明通过使用伽马探测器测量实际的能谱,并采用平滑算法对测量的能谱进行平滑 处理,对平滑处理后的能谱按照时间比例本底扣除,得到净计数谱,通过模拟能谱的近似系数作为深度学习网络的训练样本从而预测伽马探测器实测的能谱中核素的组成,克服了由于 伽马探测器能量分辨率的限制及天然本底辐射的干扰,直接从重叠峰严重的伽马能谱中提取 有效的信息变得十分困难的问题。

[0023] (5) 本发明采取的深度学习网络,例如深度置信网络可以对训练样本进行无监督的学习,即能自动学习数据中的高阶相关性,可完成一个自动能谱数据特征提取的过程,而传统的神 经网络依赖于手动特征提取,特征向量的维度等参数需要被确定,这个过程对工作人员专业 知识要求较高,缺乏智能化。

## 附图说明

[0024] 图1是本发明的流程框图。

[0025] 图2是本发明的实验环境图。

[0026] 图3是实施例不同时间下 $^{238}\text{Pu}$ 通道输出值随样本编号变化图。

[0027] 图4是实施例不同时间下 $^{60}\text{Co}$ 通道输出值随样本编号变化图。

[0028] 图5是实施例不同时间下 $^{137}\text{Cs}$ 通道输出值随样本编号变化图。

[0029] 图6是实施例不同核素( $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ )的探测率(%)随距离的变化。

[0030] 图7是实施例 $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ 在ARID处所对应的能谱。

[0031] 图8是实施例运动放射源样本在不同时间下各核素通道输出值。

[0032] 图9是实施例运动放射源样本各核素在识别时间点处对应的能谱。

## 具体实施方式

[0033] 下面根据图1至9对本发明的具体实施方式作出进一步说明,以下实施例是对本发明的解释而本发明并不局限于以下实施例。

[0034] 参见图1,一种基于近似系数与深度学习的伽马能谱分析方法,包括以下步骤:

[0035] 步骤1:采用蒙特卡洛方法对伽马探测器进行建模并模拟感兴趣核素能谱,得到模拟能谱。

[0036] 具体的,通过蒙特卡洛程序对相应伽马探测器进行建模及感兴趣核素能谱进行模拟,相当于虚拟一个探测器,然后在这个虚拟环境中,放置一些放射源,来获得能谱。蒙特卡洛方法又叫随机抽样法或统计实验法,属于计算数学的一个分支,它能够真实地模拟实际物理过程,解决问题与实际非常符合。蒙特卡洛程序是基于蒙特卡洛方法的用于计算三维复杂几何结构中的中子、光子、电子或耦合中子/光子/电子输运问题的通用软件包,基于实际探测器尺寸、材料组成等参数可以使用蒙特卡洛程序对其模型建立,并确定其对中子、光子和电子的响应。使用蒙特卡洛程序模拟感兴趣核素能谱,可以克服实验室放射性核素数量不够的难题,可以更容易获得各核素的成谱规律,进而获得大规模样本数据,可以使深度学习具有更强的学习及预测能力。所述蒙特卡洛程序采用MORSE、MCNP、EGS、GEANT4、FLUKA、SuperMC、Phits或GADRAS中的一种或几种。

[0037] 步骤2:使用伽马探测器测量实际的能谱,并采用平滑算法对测量的能谱进行平滑处理,对平滑处理后的能谱按照时间比例本底扣除,得到净计数谱。

[0038] 具体的,通过使用伽马探测器测量实际的能谱并进行平滑及按时间比例本底扣除。在本底扣除之前,先对本底谱或放射性核素谱进行平滑处理,一方面可以去除能谱中包含的噪声作用,另一方面可以抑制天然本底辐射的涨落性,可以更好的评估天然本底辐射,以达到较好的本底扣除效果。平滑算法采用重心法、高斯滤波法、最小二乘滤波法、小波平滑法、移动平均值法、粒子滤波法、卡尔曼滤波法中的一种或几种。

[0039] 步骤3:采用小波分解方法提取步骤1中模拟能谱的近似系数,对模拟能谱的近似系数进行归一化处理,采用小波分解方法提取步骤2中净计数谱的近似系数,对净计数谱的近似系数进行归一化处理。

[0040] 具体的,采用小波分解技术提取能谱的近似系数并将其归一化,对于多数信号,低频部分是最重要的,它是信号的标识,与之相反的即噪声。小波分析中,将它们成为近似部分和细节部分。采用一阶小波变换可以将信号分解为近似部分和细节部分,这个过程可以迭代,即继续采用一阶小波变换将近似信号进行分解,迭代次数即为分解级数。将得到的近似系数进行归一化,可以消除由探测时间、核素活度、探测距离、核素个数等因素的不同而造成能谱强度的不同这一效应,显著的提高了深度学习的学习能力及预测能力。所述小波分解方法采用的小波分解母函数为Daubechies、Coiflets、Symlets、Fejer-Korovkin filters、Discrete Meyer、Biorthogonal或Reverse Biorthogonal中的一种或几种。小波分解级数为1、2、3、4或5中的一种或几种。归一化处理采用线性函数归一化或0均值标准化。

[0041] 步骤4:将步骤3中归一化处理后的模拟能谱的近似系数作为深度学习网络的训练样本从而建立深度学习模型,将归一化后的净计数谱的近似系数作为深度学习模型的输

入向量从而预测步骤2中的伽马探测器实测的能谱中核素的组成。

[0042] 具体的,采用模拟能谱样本训练深度学习并将它用于预测实测能谱样本核素组成。深度学习又称深度机器学习,是机器学习的一个分支,它集中于学习数据的深层结构。多层的深度学习网络可以更好的模拟人脑进行分析学习及数据解释。它已在计算机视觉、语音识别、自然语音处理等领域成功应用。所述的步骤4中的深度学习网络采用深度置信网络、深度神经网络、卷积神经网络、堆叠式自动编码器或卷积自动编码器中的一种或几种。所述的步骤4中的深度学习网络采用的深度学习框架为DeepLearnToolbox、Caffe、CNTK、TensorFlow、Theano、Torch、Keras、Lasagne、DSSTNE、MXNet、DeepLearning4J、ConvNetJS、Chainer 或Scikit-Learn中的一种或多种。所述深度学习网络包括3层神经网络,3层神经网络分别为输入层、隐含层和输出层,所述隐含层的个数为1-50。

[0043] 下面通过具体实例来对本发明进一步说明:

[0044] 通过蒙特卡洛程序对相应伽马探测器进行建模及感兴趣核素能谱进行模拟。首先把具体参数设置好,模拟伽马探测器,本实施例进行模拟的是 $3' \times 3'$  NaI (Tl) 探测器。本次模拟的放射性核素有 $^{57}\text{Co}$ 、 $^{75}\text{Se}$ 、 $^{60}\text{Co}$ 、 $^{133}\text{Ba}$ 、 $^{137}\text{Cs}$ 、 $^{192}\text{Ir}$ 、 $^{241}\text{Am}$ 、 $^{152}\text{Eu}$ 和 $^{238}\text{Pu}$ 。

[0045] 通过使用伽马探测器测量实际能谱并进行平滑及按时间比例本底扣除。采用的平滑算法是七点高斯平滑算法,其计算公式如下式所示。其中y表示能谱数据,i表示道数。

[0046]  $y(i) = 0.2438 * y(i) + 0.2050 * (y(i-1) + y(i+1)) + 0.1218 * (y(i-2) + y(i+2)) + 0.0513 * (y(i-3) + y(i+3))$  (1)。

[0047] 本底扣除采用的是按时间比例进行扣除,即实测核素能谱减去与之测量时间相当的天然本底谱。通过这一步骤,可有效的去除本底辐射的干扰。其计算公式如下式所示。其中 $y_1$ 、 $y_2$ 、 $y_3$ 、 $t_1$ 和 $t_2$ 分别为核素能谱、天然本底谱、净计数谱、核素谱测量时间和本底谱测量时间。

[0048]  $y_3 = y_1 - y_2 * t_1 / t_2$  (2)。

[0049] 采用小波分解技术提取模拟能谱和净计数谱的近似系数并将其分别进行归一化。任何能谱数据都包含信号和噪声两部分,通常我们将信号称为低频部分,而将噪声称为高频部分。在小波分析中,通常将低频部分和高频部分称为近似部分与细节部分。能谱数据通过单阶小波分解后,可分为近似部分和细节部分,这个过程相当于将一个低通滤波器和一个高通滤波器分别作用于能谱数据。而且,该过程可以迭代进行,即可继续将一个低通滤波器和一个高通滤波器作用于一个已得到的近似部分,迭代次数称为分解级数。

[0050] 归一化处理采用的线性归一化,向量y ( $x=0, \dots, N-1$ ) (N为向量维度)的线性归一化为:

[0051]  $Y = (amax - amin) * (y - ymin) / (ymax - ymin) + amin$  (3);

[0052] 其中,amax和amin分别为要归一化后的最大值和最小值,ymax和ymin分别为向量的最大值和最小值,y为向量中的任意一个。

[0053] 采用模拟能谱的近似系数作为样本训练深度学习并将它用于预测实测能谱样本核素组成。

[0054] 本施例采用的深度学习网络为深度置信网络,深度置信网络可以对训练样本进行无监督的学习,即能自动学习数据中的高阶相关性,可完成一个自动能谱数据特征提取的过程,而传统的神经网络依赖于手动特征提取,特征向量的维度等参数需要被确定,这个

过程对工作 人员专业知识要求较高,缺乏智能化。本实施例采用的深度学习框架为DeepLearnToolbox,搭建了3层神经网络,分别为输入层、隐含层和输出层,隐含层的个数由具体问题所确定,衡量标准是不出现过拟合或欠拟合现象。输入层神经元个数为128、隐含层神经元个数为 1024,输出层神经元个数为9的深度置信神经网络。9个输出神经元分别表示 $^{57}\text{Co}$ ,  $^{75}\text{Se}$ ,  $^{60}\text{Co}$ ,  $^{133}\text{Ba}$ ,  $^{137}\text{Cs}$ ,  $^{192}\text{Ir}$ ,  $^{241}\text{Am}$ ,  $^{152}\text{Eu}$ , 和  $^{238}\text{Pu}$ 这9种核素存在与否,用数字表示为‘1’或‘0’。‘1’表示该核素绝对存在,‘0’表示该核素绝对不存在,实际输出大于等于0.9即认为该核素存 在。将模拟能谱的近似系数作为样本训练的输入,建立神经网络模型,将归一化后的净计数 谱的近似系数作为神经网络模型的输入,输出核素识别的结果。

[0055] 下面通过具体的试验数据来对本发明的基于近似系数与深度学习的伽马能谱分析方法进 行验证。

[0056] 采用ORTEC公司生产的3' × 3' NaI (Tl) 探测器测量能谱数据。该探测器的能量范围是 30keV至3MeV,能量分辨率为7.7%FWHM(662keV能量处)。表1是本发明所使用的放射性源,共3种核素,为描述方便,分别将它们标记为Nucl-1,Nucl-2和Nucl-3。

[0057] 表1

[0058] 用于本文试验的放射源

[0059]

核素	$^{238}\text{Pu}$	$^{60}\text{Co}$	$^{137}\text{Cs}$
活度(μCi)	$8.89 \times 10^3$	1.59	1.42
编号	Nucl-1	Nucl-2	Nucl-3

[0060] 本发明采用探测率来评价核素识别算法的性能。如公式(4)所示,探测率表示的是正确 识别的数据占总数据的比例。

$$[0061] \quad \text{探测率}(\%) = \frac{TP + TN}{TP + TN + FP + FN} \times 100 \quad (4)$$

[0062] 其中,TP(true positive)表示正确正响应,TN(true negative)表示正确负响应,FP(false positive)表示错误正响应,FN(false negative)表示错误负响应。

[0063] 同时,根据探测率与距离的关系,计算了单个核素精确核素识别距离(ARID)。ARID表 示在探测率大于98.3%的条件下,可以精确核素识别的距离。

[0064] 深度学习训练样本的采集:

[0065] 采用蒙特卡洛程序MCNP模拟了 $^{57}\text{Co}$ ,  $^{75}\text{Se}$ ,  $^{60}\text{Co}$ ,  $^{133}\text{Ba}$ ,  $^{137}\text{Cs}$ ,  $^{192}\text{Ir}$ ,  $^{241}\text{Am}$ ,  $^{152}\text{Eu}$ , 和  $^{238}\text{Pu}$  这9种核素的伽马能谱,并通过电脑合成了它们的混合能谱,共511个模拟能谱,采用小波 分解技术提取模拟能谱的近似系数并将其归一化,再将它们全部作为深度学习训练样本,建 立深度学习模型。

[0066] 本实验的样本采集:

[0067] (1) 不同时间的样本的采集。图2为实验环境图。在伽马探测器的正前方A处测量了Nucl-1、Nucl-2和Nucl-3的能谱,重复测量10次,测量时间分别为1s、2s、3s、4s和5s。一共测量了150个能谱,全部作为实验测试样本。

[0068] (2) 不同核素个数的样本的采集。在探测器的正前方A处测量了Nucl-1、Nucl-2、Nucl-3、Nucl-1+Nucl-2、Nucl-1+Nucl-3、Nucl-2+Nucl-3和Nucl-1+Nucl-2+Nucl-3的能谱,重 复测量10次,测量时间为5s,一共测量了70个能谱,全部作为实验测试样本。

[0069] (3) 不同距离的样本的采集。在A至0共15个点,间隔为10cm,测量了Nuc1-1、Nuc1-2和Nuc1-3的能谱,重复测量10次,测量时间为10s,一共测量了450个能谱,全部作为实验测试样本。

[0070] (4) 运动放射源的样本的采集。假设人从0点出发,沿直线步行到A点,同时身上携带 $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ 。整个过程约耗时3s,速度约等于0.5m/s。通过设定取样间隔0.1s,由于计时的误差,共获得26个能谱,全部作为实验测试样本。

[0071] 将上述实验测试样本分别进行平滑及按时间比例本底扣除,具体按照公式(1)和(2)计算,再采用小波分解技术提取实测的能谱(净计数谱)的近似系数并将其归一化;再将归一化后的能谱的近似系数作为深度学习模型的输入向量进入输入层。

[0072] 实验结果:

[0073] 图3是不同时间下输出层 $^{238}\text{Pu}$ 通道输出值随样本编号变化图(只有 $^{238}\text{Pu}$ 存在于环境中)。从图中可以看出,在不同时间下, $^{238}\text{Pu}$ 的识别概率均高于阈值,即表示 $^{238}\text{Pu}$ 被识别出来。而且, $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ 的识别概率远低于阈值,即表示在整个过程中,未出现误识别,进而可以体现出,本发明提出的方法是一种特别稳定的核素识别方法。

[0074] 图4是不同时间下输出层 $^{60}\text{Co}$ 通道输出值随样本编号变化图(只有 $^{60}\text{Co}$ 存在于环境中)。从图中可以看出,在不同时间下, $^{60}\text{Co}$ 的识别概率均高于阈值,即表示 $^{60}\text{Co}$ 被识别出来。而且, $^{238}\text{Pu}$ 和 $^{137}\text{Cs}$ 的识别概率均低于阈值,即表示在整个过程中,未出现误识别,进而可以体现出,本发明提出的方法是一种特别稳定的核素识别方法。

[0075] 图5是不同时间下输出层 $^{137}\text{Cs}$ 通道输出值随样本编号变化图(只有 $^{137}\text{Cs}$ 存在于环境中)。从图中可以看出,在不同时间下 $^{137}\text{Cs}$ 的识别概率均高于阈值,即表示 $^{137}\text{Cs}$ 被识别出来。而且, $^{238}\text{Pu}$ 和 $^{60}\text{Co}$ 的识别概率均低于阈值,即表示在整个过程中,未出现误识别,进而可以体现出,本发明提出的方法是一种特别稳定的核素识别方法。

[0076] 下面表2是不同核素个数下各核素( $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ )的探测率(%)。从表中可以看出,本发明提出的核素识别算法不受核素个数的影响,在不同核素个数的情况,仍然对单个核素探测率高达100%,是一种性能较佳的核素识别算法。

[0077] 表2

[0078] 不同核素个数下,各核素( $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ )的探测率(%)。

[0079]

Number	$^{238}\text{Pu}$	$^{60}\text{Co}$	$^{137}\text{Cs}$
1	100	100	100
2	100	100	100
3	100	100	100

[0080] 图6是不同核素( $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ )的探测率(%)随距离的变化。从图中可以看出,对于活度分别为 $8.89 \times 10^3$ 、1.59和1.42 $\mu\text{Ci}$ 的 $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ 的ARID分别为60cm、100cm和120cm。也就是说,在满足最小可探测活度要求的前提下,本发明提出的核素识别算法不受距离的影响。

[0081] 图7是 $^{238}\text{Pu}$ 、 $^{60}\text{Co}$ 和 $^{137}\text{Cs}$ 在ARID处所对应的能谱。从图中可以发现,三幅图的能谱总计数较少,观测不到各核素的特征峰,但本发明提出的核素识别方法可以以100%的探测率将其识别出来,说明本发明提出的方法区别于传统核素识别方法,即基于寻峰的核素识



别算法，利用全谱形状进行核素识别，在识别时间上少于传统核素识别算法。

[0082] 图8是运动放射源样本在不同时间下各核素通道输出值。从图中可以看出，本发明提出的核素识别算法：在0.72s时，识别出了 $^{60}\text{Co}$ ；在1.18s时，识别出了 $^{137}\text{Cs}$ ；在3.04s时，识别出了 $^{238}\text{Pu}$ 。实验结果表明，本发明提出的方法可以充分利用全谱信息，以较快的速度识别出环境中存在的放射性核素，在现实中有较大的应用意义。

[0083] 图9是运动放射源样本各核素在识别时间点处对应的能谱。特别地，从图9.a和图9.b 可以看出，本发明提出的核素识别方法可以在能谱计数非常少的情况下，对能谱中可能存在的核素模式进行匹配并识别，以较短的时间便完成了核素识别任务，是一种性能较好的核素识别方法。

[0084] 本说明书中所描述的以上内容仅仅是对本发明所作的举例说明。本发明所属技术领域的技术人员可以对所描述的具体实施例做各种修改或补充或采用类似的方式替代，只要不偏离本发明说明书的内容或者超越本权利要求书所定义的范围，均应属于本发明的保护范围。

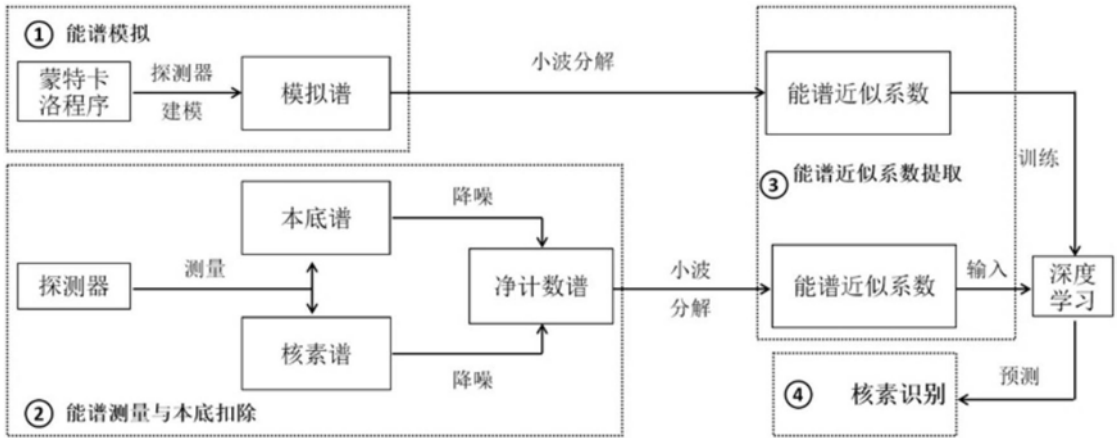


图1




图2




图3




图4

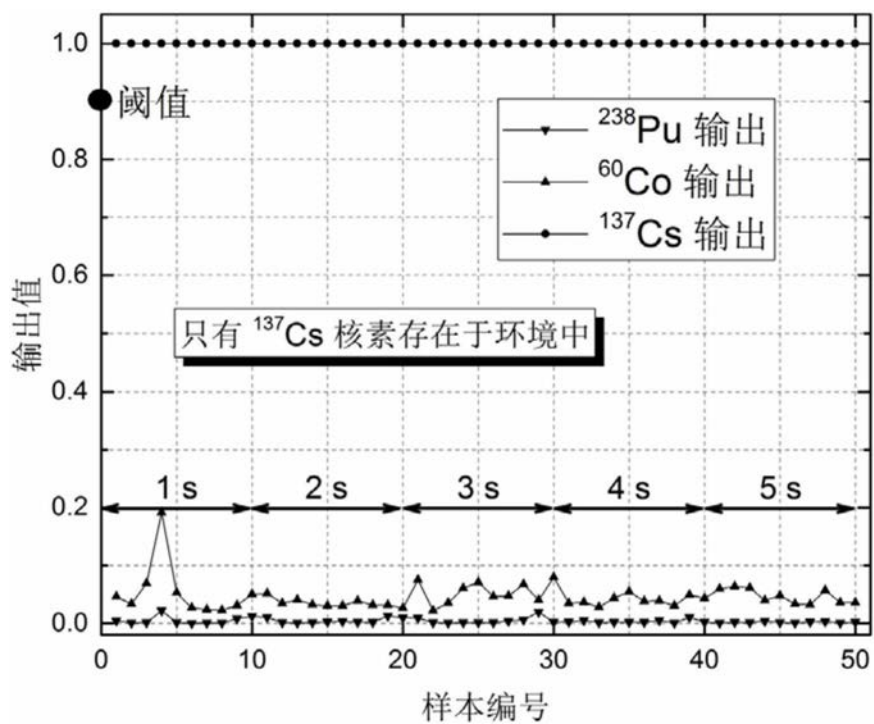


图5

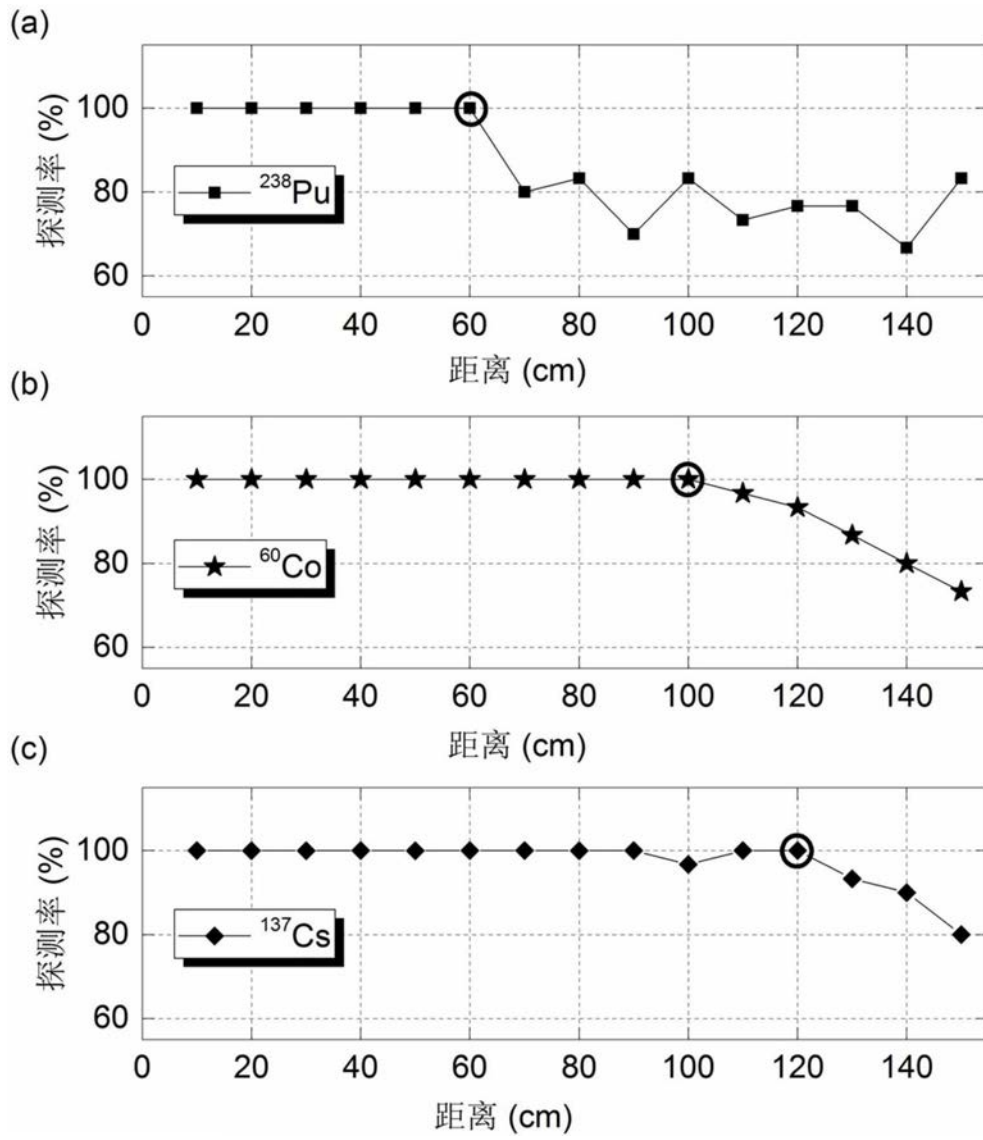


图6

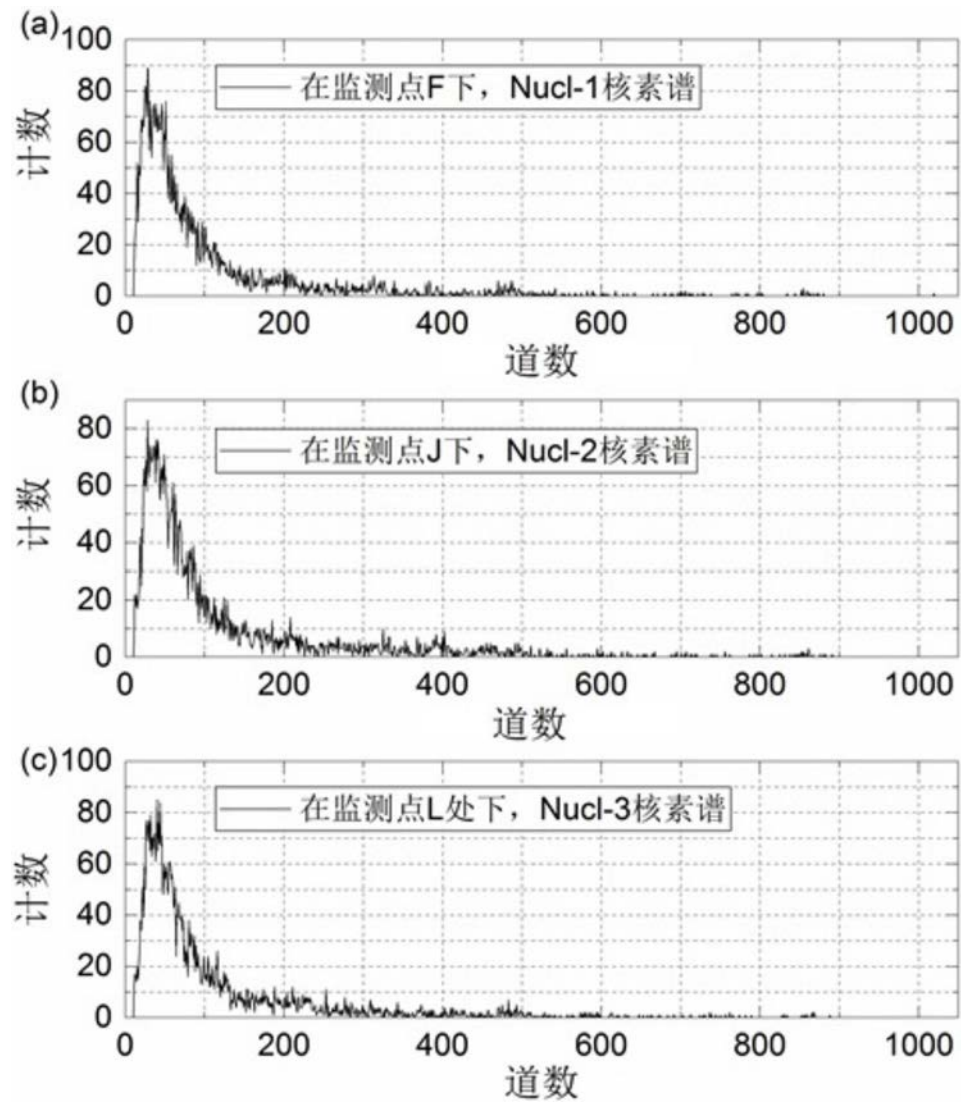


图7

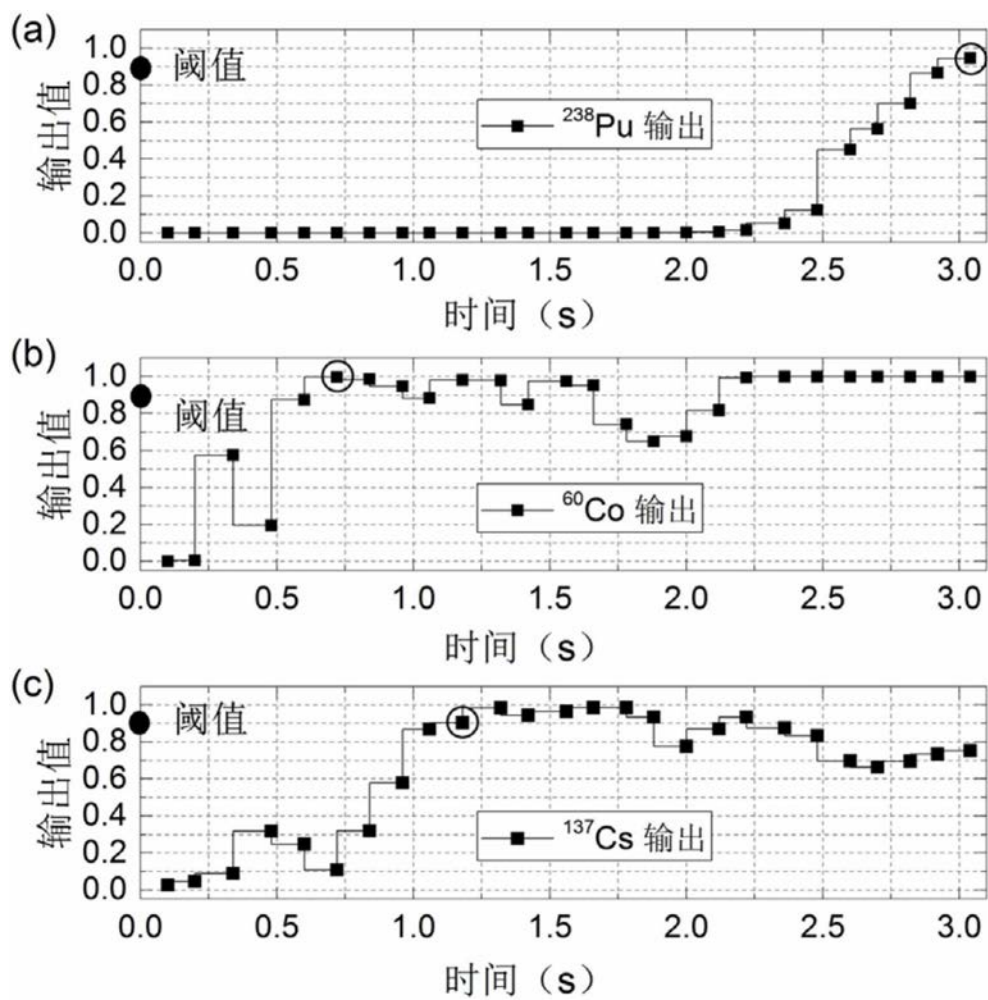


图8

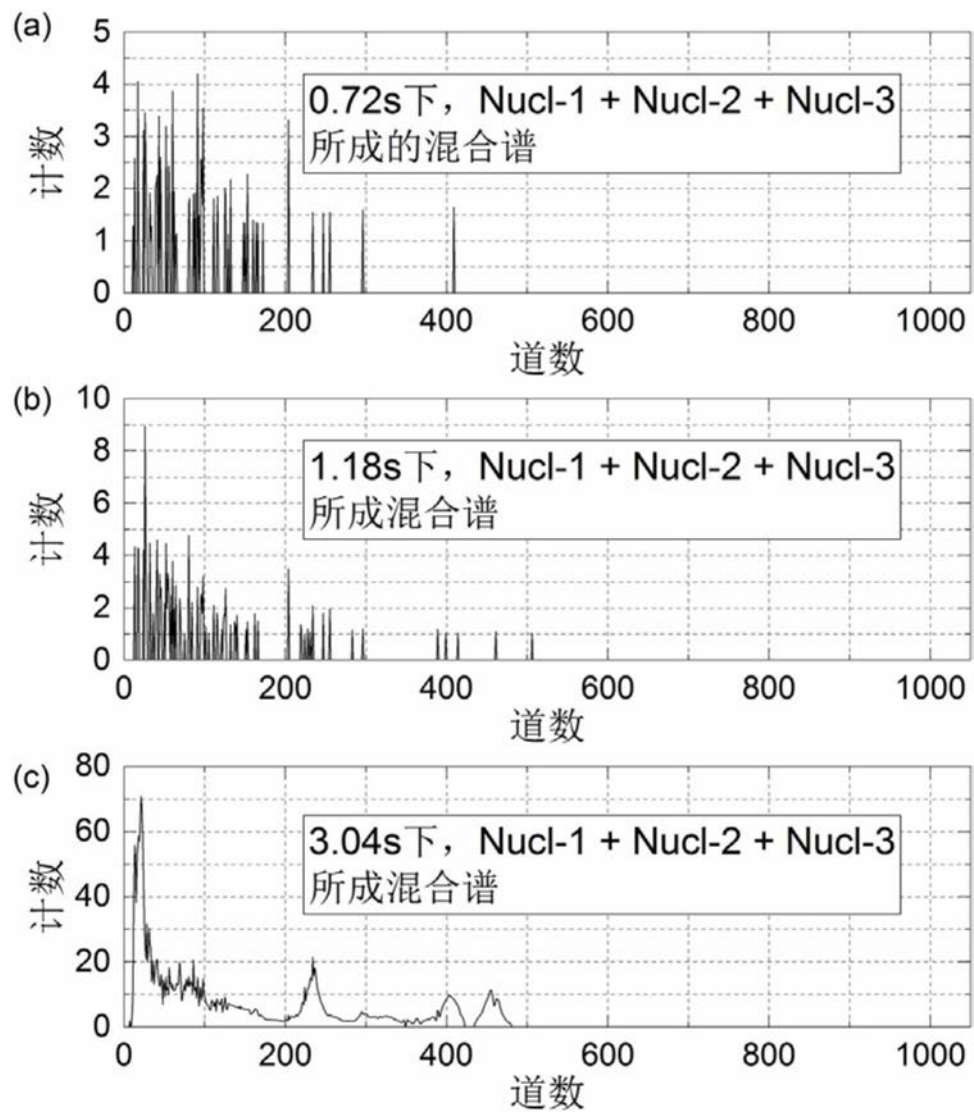


图9