

基于深度神经网络的空间目标常用材质 BRDF 模型

刘程浩¹, 李 智², 徐 灿³, 田琪琛¹

¹ 装备学院研究生院, 北京 101416;

² 装备学院航天指挥系, 北京 101416;

³ 装备学院航天装备系, 北京 101416

摘要 由于双向反射分布函数(BRDF)经验模型与半经验模型对材质散射特性描述时存在局限性,导致其拟合结果与实测数据的误差较大。针对此问题,基于深度神经网络(DNN)构建了一种适用于具有不同散射特性空间目标材质的 BRDF 模型。建立的深度神经网络模型基于 TensorFlow 实现,包含 4 个隐含层,并采用 AdaDelta 梯度下降法进行优化,结合 Dropout 方法进行正则。随机抽取材质测量数据的一部分作为训练样本,最终得到 BRDF 与入射天顶角、反射天顶角以及观测方位角的映射关系模型。大量的实验结果表明,建立的深度神经网络模型具有良好的材质特性描述能力,且对于相同材质,模型的拟合误差小于经验模型。

关键词 散射; 双向反射分布函数; 神经网络; 深度学习; 空间目标材质

中图分类号 O436.2 文献标识码 A

doi: 10.3788/AOS201737.1129001

BRDF Model for Commonly Used Materials of Space Targets Based on Deep Neural Network

Liu Chenghao¹, Li Zhi², Xu Can³, Tian Qichen¹

¹ Department of Graduate Management, Equipment Academy, Beijing 101416, China;

² Department of Space Command, Equipment Academy, Beijing 101416, China;

³ Department of Space Equipment, Equipment Academy, Beijing 101416, China

Abstract When the bidirectional reflectance distribution function (BRDF) empirical model and semi-empirical model describe the scattering characteristics of the material, the limitation of these models for the description of different scattering characteristics results in large errors between the fitting result and the measured data. To solve the problem, a BRDF model suitable for commonly used materials on space targets with different characteristics is constructed based on deep neural network (DNN). The DNN model, which contains four hidden layers, is based on TensorFlow implementation. It is optimized by AdaDelta gradient descent method, and combined with Dropout method for regularity. Part of the material measurement data is randomly selected as the training sample, and finally the mapping relationships between the BRDF and the angles of the incident zenith, the reflection zenith and the observation azimuth are obtained. A large number of experimental results show that the DNN model has good ability to describe the scattering characteristics of materials, and the fitting error of the DNN model is less than that of the empirical model for the same material.

Key words scattering; bidirectional reflectance distribution function; neural network; deep learning; materials of space target

OCIS codes 290.1483; 290.4210; 290.5880

1 引言

双向反射分布函数(BRDF)可以表示某种材质在某一入射条件下不同观测角度的反射特性,这种表示

收稿日期: 2017-07-03; 收到修改稿日期: 2017-07-20

基金项目: 国家 863 计划(2015AA7046104)

作者简介: 刘程浩(1993—),男,硕士研究生,主要从事空间目标光学散射特性测量与建模方面的研究。

E-mail: liuchenghaoxy@163.com

导师简介: 李 智(1973—),男,教授,博士生导师,主要从事空间安全方面的研究。E-mail: lizhizys@263.com

建立在几何光学的基础上,主要由材质表面粗糙度、介电常数、入射光波长及偏振等因素决定^[1]。目前, BRDF 在空间目标光学横截面积计算^[2]、空间目标姿态及运动特征反演^[3]、空间目标识别^[4]及计算机图像处理等领域有着广泛的应用。从理论上来说,使用基于 BRDF 的指标对某种材质进行描述需要已知该材质在上半球空间内的所有 BRDF 值,而现实条件下, BRDF 的测量受到制约,无法有效得到材质在任意入射和观测条件下的 BRDF 值。因此就需要利用有限的测量数据,借助 BRDF 模型对材质表面上半球空间内的 BRDF 分布进行合理推测,从而得到任意条件下的 BRDF 值。

一般来说, BRDF 模型主要分为三类:物理模型、经验(半经验)模型和数据驱动模型。物理模型是在一定物理原理的基础上得到的模型,此类模型的参数具有其特定的物理意义,如 Torrance-Sparrow 模型^[5]、Maxwell-Beard 模型^[6]等;经验模型是在明确材质表面物理特性以及实验测量结果的基础上,用简单的数学函数组合的形式进行描述的模型,此类模型表达式中的参数一般没有物理含义,其中既包含物理参数,又具有经验参数的模型称为半经验模型,如 Phong 模型^[7]、五参数模型^[8]、Minnaert 模型^[9]等;数据驱动模型是以机器学习等方法为基础,建立在大量实测数据之上的通用模型。

物理模型对材质的描述比较准确,但是需要已知目标材质的物理参数,因此应用中受到材质物理参数测量的限制,这也是经验(半经验)模型应用较为广泛的原因。经验(半经验)模型虽然易于使用,但是不同模型的适用范围有很大差异,泛化能力不强。因此,针对这两类模型的局限性,本文基于深度神经网络(DNN)建立了一种数据驱动模型,使用不同特性空间目标常用材质的 BRDF 实际测量数据进行训练,通过选择合理的正则化方法和优化方法来降低模型的过拟合,提高模型的泛化能力。

2 基于深度神经网络的模型构建

2.1 深度学习

深度学习是人工神经网络的一大分支。人工神经网络是通过模拟生物大脑神经信号传递的工作原理而提出的算法,其由多个结构简单、相互连接的处理器组成,每一个处理器可以看做一个神经元,用处理器之间的信息传递模拟生物信号在神经元之间的传递。其网络结构可分为可视层和隐含层,可视层包括输入层和输出层,其中隐含层和输出层具备学习能力。

深度神经网络由多层自适应的非线性单元组成,其内所有层都具有可训练的参数^[10]。深度神经网络与浅层网络相似,都能够利用函数来描述数据内部的联系和特征,但是由于网络结构的不同,深度神经网络相比于浅层网络具有更强的表达能力。浅层网络,包括单隐层网络、支持向量机(SVM)、逻辑回归等,都至多具备两个可学习层(隐含层和输出层),其对许多较简单的或者具有良好约束的问题有着十分突出的效果。但是现实生活中的复杂应用问题的数据结构往往比较复杂或者问题没有特定约束,此时对于浅层网络来说,需要的计算单元可能会呈现指数级的增长,使得其网络结构臃肿复杂,表达能力下降。而对于深度网络结构,层与层之间的计算单元互联,同层的计算单元之间相互独立,数据信号在层与层之间进行传递。以全连接结构为例,随着网络层次的加深,其每一条得分路径(信度分配路径,从输入到输出的信号传输路径)都是一条可学习的、连接数据和结果的因果链。这也就意味着,对于使用相同数量的计算单元,深度网络结构的表达能力远强于浅层网络^[11]。

对于 BRDF 来说,其所描述的是材质上半球空间内的光学散射特性,该特性与材质种类、表面粗糙度情况、光源情况等多种因素都有关;且在测量过程中,不同观测情况下的 BRDF 值也有很大差异。因此,影响 BRDF 分布的因素多且复杂,若要对其进行有效的建模就需要从测量数据中提取足够多的有效特征。而深度神经网络对于复杂问题的表达能力更强,在相同条件下能够提取更多的有效特征,因此,本研究尝试基于深度神经网络构建数据驱动的 BRDF 模型。

2.2 建模过程

在应用中,深度神经网络结构模型可以看作一个“黑箱”,这个“黑箱”有输入端和输出端,内部是多层计算单元。通过给定输入,“黑箱”经过提取输入数据的特征来完成从输入到输出的映射。同时,所使用的 BRDF 测量数据由 4 部分组成,分别为入射天顶角 θ_i 、观测天顶角 θ_r 、观测方位角 φ_r 以及 BRDF 值 f_o ,角度关系如图 1 所示,图中 V_i 为入射向量, V_r 为反射向量。




图 1 BRDF 测量角度示意图

Fig. 1 Angles schematic in BRDF measurement

深度神经网络模型的内部参数对于模型的训练结果的影响较大,本研究结合 BRDF 数据以及建模特点,提出了相应的深度神经网络模型的结构参数设计方法。

1) 模型的输入与输出

物理模型是在已知材质表面物理参数的前提下来预测材质上半球空间内的 BRDF 值;经验(半经验)模型则是根据材质的部分测量数据,通过优化算法反演出该材质在此模型下的参数来预测材质的 BRDF 值。因此无论使用何种模型预测 BRDF 值,都需要指明观测条件。所以,在建模中,将入射天顶角 θ_i 、观测天顶角 θ_r 、观测方位角 φ_r 作为深度神经网络模型的输入, BRDF 预测值 f_r 为输出。

2) 模型的网络结构和计算单元规模

虽然模型的输入为三个角度,但是决定某一方向上 BRDF 值的因素还包括材质表面粗糙度、介电常数、偏振等因素,所以神经网络需要提取的数据特征数远大于 3。同时,深度神经网络仅在相邻隐含层之间互连,学习过程中将上一层的输出作为下一层的输入,逐层对数据特征进行抽象,借此模仿人脑对事物特征提取的过程,因此理论上来说网络层次越深,越能得到更有效的特征。但是过深的网络会造成梯度消失,导致所有隐含层的学习能力下降,无法有效提取数据特征,使得整个网络模型的学习能力下降。为保证深度神经网络模型可以提取足够的特征且不造成学习能力下降,本研究构建的神经网络包含 4 个隐含层,按前馈信号传递方向,各个隐含层神经元的数量分别为 20、40、20、10。

3) 激活函数

本研究所使用的神经网络为全连接神经网络,网络中每一层的计算都可以表示为权重矩阵 W 与神经元组成的向量 x 相乘,再与偏置向量 b 相加:

$$y = W \cdot x + b, \quad (1)$$

若不对每一层的计算进行额外操作,该神经网络只能进行线性映射的表达,无法对非线性分布的数据进行有效建模,降低神经网络的学习能力。而激活函数的作用是为神经网络增加非线性因素,使得神经网络具备非线性映射学习能力。目前提出的激活函数有很多种,各有优缺点。而 BRDF 建模的目的是预测未测量角度下的 BRDF 值,因此激活函数不能出现饱和状态;同时该值恒大于 0,必须保证激活函数能够在函数值小于 0 时呈现抑制状态。

针对这两点,本研究选用 ReLU 函数作为神经网络的激活函数,表达式如下:

$$f(x) = \max(0, x), \quad (2)$$

该函数在输入信号 $x < 0$ 时,函数值 $f(x) = 0$; $x > 0$ 时, $f(x) = x$ 。该函数在函数值小于 0 时处于已抑制状态,同时函数值大于 0 时梯度恒等于 1,不会发生右饱和现象,满足 BRDF 建模的需求。激活效果如图 2 所示。

4) 损失函数、优化器及学习速率

BRDF 模型是用于预测不同材质在上半球空间内的 BRDF 值,因此 BRDF 建模属于回归问题。损失函数的作用就是比较神经网络预测的 BRDF 分布与相同角度下实际测量的 BRDF 分布的相似度,相似度越高,损失函数值就越小。本研究使用均方误差作为损失函数,表达式如下:




图2 ReLU函数激活效果。(a)激活前;(b)激活后

Fig. 2 Activation effect of ReLU. (a) Before activation; (b) after activation

$$E = \frac{|y_{\text{pre}} - f_0|^2}{|f_0|^2}, \quad (3)$$

式中 y_{pre} 为模型预测值, f_0 为实际测量值, E 为损失函数值。

本研究采用无监督预训练加有监督调优的方式进行训练,所以网络模型的前馈阶段为无监督学习,根据当前学习成果形成输出,计算损失函数值;然后进入反向有监督调优阶段,利用优化器对损失函数进行优化,反向微调神经网络各层的权值,进入下一次学习。在达到学习要求(即给定的损失函数值),或者达到规定学习次数之后停止学习,输出最终学习成果。本研究选择的优化器为 AdaDelta,是一种基于梯度的优化算法,可以针对不同参数调整学习速率,提高训练效率。

5) 正则化方法和训练方式

为了防止神经网络的过拟合,提高其泛化能力,需要对其进行正则化。本研究所选用的正则化方法为 Dropout,对训练样本中某一批数据进行训练时,随机隐藏一部分神经元,用未隐藏的部分网络进行拟合,该批次训练完毕之后恢复原隐藏部分,再重新随机选择隐藏神经元进行下一批次的训练。该方法可以减少相连接神经元之间的依赖性,提高神经网络的学习能力和泛化能力。




图3 Dropout示意图

Fig. 3 Dropout diagram

针对某种材质的测量数据,本研究随机选择全部数据的一部分作为训练样本,剩余部分为检验样本。每批次选择训练样本的 0.5% 进行训练,最大训练批次为 50 万次,保证所有训练样本都可以参加学习过程。最后使用检验样本进行建模效果评估,评估函数仍旧使用均方误差函数。

具体的建模步骤为:

- ① 选择某种材质的 BRDF 数据,构建参加训练的样本集 $(\theta_i, \theta_r, \varphi_r, f_r)$ 。
- ② 确定网络模型中优化器的学习率和 Dropout 概率,使用深度神经网络模型对选取的样本集进行训练,得到该材质的网络模型。
- ③ 使用模型对样本集的输入进行输出预测,判定模型训练准确率是否满足要求,若不满足则继续训练。
- ④ 将满足训练准确率的模型使用检验样本集验证模型的泛化能力,若模型的泛化能力满足要求则保存模型;否则重新调整模型参数后转步骤②,直到所得模型符合泛化能力要求。

综上,建模过程如图4所示。

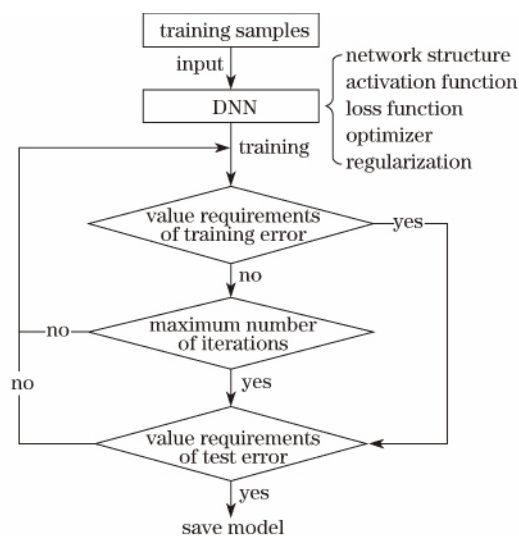


图 4 深度神经网络建模过程

Fig. 4 Modeling process of DNN


3 模型验证

对 10 种空间目标常用材质进行了数据测量。测量时,在兼顾不同入射情况下的材质特性,入射天顶角选择为 $2^\circ, 5^\circ, 15^\circ, 30^\circ, 45^\circ, 60^\circ, 75^\circ, 80^\circ$;观测天顶角 $-90^\circ \sim 90^\circ$,每隔 0.1° 记录一次。对于镜面反射特性较强的材质,观测方位角选取为 $0^\circ \sim 20^\circ$,每隔 1° 扫描一次;漫反射特性较强的材质选取为 $0^\circ \sim 90^\circ$,每隔 5° 扫描一次。每种材质约采集 30 万组数据。

3.1 模型有效性验证

为验证深度神经网络模型的有效性,将参与建模材质的 BRDF 数据随机抽取 90% 作为检验样本,剩余数据作为训练样本进行模型的训练和检验。下面给出其中两种材质的建模结果。

图 5 为覆金膜阳极板的实验测量 BRDF 数据与深度神经网络模型生成数据的比较。该材质镜面反射特性较强,测量方位角范围选择为 $0^\circ \sim 20^\circ$ 。给出在入射天顶角为 $2^\circ, 15^\circ, 60^\circ, 75^\circ$,观测方位角为 0° 条件下的对比图像。训练误差 $E_s = 0.0139$,检验误差 $E_t = 0.0176$ 。

图 5 覆金膜阳极板拟合效果。(a) $\theta_i = 2^\circ$; (b) $\theta_i = 15^\circ$; (c) $\theta_i = 60^\circ$; (d) $\theta_i = 75^\circ$ Fig. 5 Fitting effect of anode plate coated by gold film. (a) $\theta_i = 2^\circ$; (b) $\theta_i = 15^\circ$; (c) $\theta_i = 60^\circ$; (d) $\theta_i = 75^\circ$

从深度神经网络的拟合结果中可以看出,该模型可以准确地描述材质在不同入射天顶角下的散射特性。图 6 给出了训练过程损失函数的变化曲线,曲线上各点代表在当前迭代次数时的误差大小,反映了神经网络的学习过程。由于每批次训练所选择的样本不同且使用 Dropout 正则化方法,导致在模型训练前期损失函数值存在较大波动,但是随着训练的进行可以有效收敛,体现了该模型的有效性以及较强的学习能力。




图 6 覆金膜阳极板损失函数值下降曲线

Fig. 6 Loss function value decline curve of anode plate coated by gold film

图 7 给出环氧漆的实验测量数据与神经网络建模数据的比较。该材质漫反射特性比较明显,测量方位角的范围为 $0^\circ \sim 90^\circ$ 。给出入射天顶角为 $2^\circ, 30^\circ, 75^\circ, 80^\circ$, 方位角为 0° 时的对比图像。训练误差 $E_s = 0.0011$, 检验误差 $E_t = 0.0091$ 。

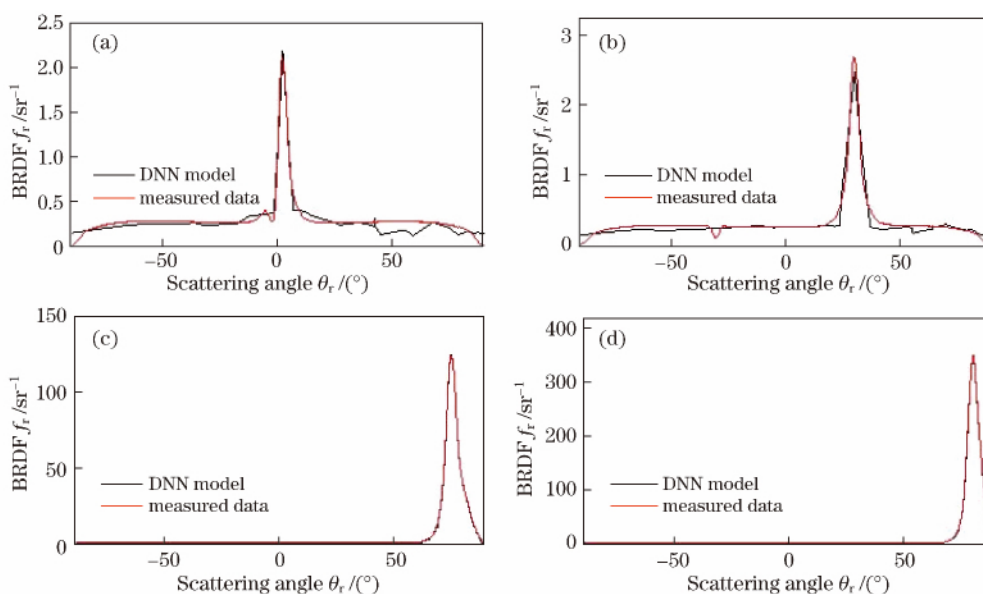


图 7 环氧漆拟合效果。(a) $\theta_i = 2^\circ$; (b) $\theta_i = 30^\circ$; (c) $\theta_i = 75^\circ$; (d) $\theta_i = 80^\circ$

Fig. 7 Fitting effect of epoxy paint. (a) $\theta_i = 2^\circ$; (b) $\theta_i = 30^\circ$; (c) $\theta_i = 75^\circ$; (d) $\theta_i = 80^\circ$

图 8 为环氧漆损失函数变化曲线,该曲线在全局迭代次数 2×10^5 之前呈下降趋势, 2×10^5 次之后存在函数值波动,但总体收敛于 0,同样反映出该模型的学习能力较强。

3.2 模型稳健性验证

对于深度神经网络的稳健性检验,这里分为两个部分进行。

第一部分为在同一样片测量数据中分 10 次随机抽取相同规模的训练样本,每次抽取训练样本后的剩余数据为该组训练样本的检验样本,用以检验不同的训练样本对建模结果的影响。

这里采用 2A12 白漆板的测量数据进行稳健性检验,每次抽取的训练样本的数量占比为 0.9,表 1 给出 10 次的训练误差和检验误差。




图 8 环氧漆损失函数值下降曲线

Fig. 8 Loss function value decline curve of epoxy paint

表 1 2A12 白漆板的建模误差

Table 1 Modeling errors of 2A12 white paint

| Training error | Test error | Average test error |
|----------------|------------|--------------------|
| 0.00741 | 0.01571 | 0.02279 |
| 0.03036 | 0.02320 | |
| 0.03145 | 0.01546 | |
| 0.04237 | 0.06529 | |
| 0.01871 | 0.01355 | |
| 0.01868 | 0.01634 | |
| 0.07684 | 0.03029 | |
| 0.02392 | 0.01927 | |
| 0.01839 | 0.01293 | |
| 0.01627 | 0.01586 | |

通过 10 次平均检验误差结果可以看出,使用相同规模的不同训练样本,神经网络模型的平均建模误差为 2.279%,建模效果良好。

第二部分为使用两个不同于第一部分的比例分别抽取 5 次训练样本,并保留对应的检验样本,结合第一部分的建模结果检验不同规模的训练样本对建模效果的影响。

这里同样使用 2A12 白漆板的测量数据,首先按 0.75 的比例随机抽取 5 次训练样本,然后按 0.5 的比例再进行 5 次随机训练样本抽取(即交叉验证)。建模结果如表 2 所示。

表 2 不同规模训练样本的建模误差比较

Table 2 Modeling errors comparison of training samples with different scales

| Ratio of training sample | Training error | Test error | Average test error |
|--------------------------|----------------|------------|--------------------|
| 0.75 | 0.01899 | 0.01836 | 0.01715 |
| | 0.03421 | 0.02942 | |
| | 0.01600 | 0.01036 | |
| | 0.02601 | 0.02160 | |
| | 0.00647 | 0.00600 | |
| 0.50 | 0.02500 | 0.02038 | 0.01664 |
| | 0.00497 | 0.00541 | |
| | 0.00878 | 0.01324 | |
| | 0.02046 | 0.01847 | |
| | 0.01593 | 0.02227 | |

由第二部分的平均检验误差可以看出,随着训练样本所占比例的下降,模型的检验误差并没有受到影响,这表明训练样本的规模并不影响深度神经网络模型的建模效果。

综合两部分的检验结果,深度神经网络模型能够在不同规模的训练样本中提取足够的有效特征,完成对 BRDF 值的预测,且预测误差较小,证明了深度神经网络模型的稳健性良好。

3.3 模型准确性验证

为验证深度神经网络模型的准确性,这里使用 Phong 模型^[7]和五参数模型^[8]的建模效果进行比较。下面给出两种材质的比较结果。

首先比较对漫反射特性较强材质的拟合效果,这里选用环氧漆进行比较,给出三种模型在入射天顶角为 $5^\circ, 30^\circ$,观测方位角为 0° 时的拟合图像,如图 9 所示。

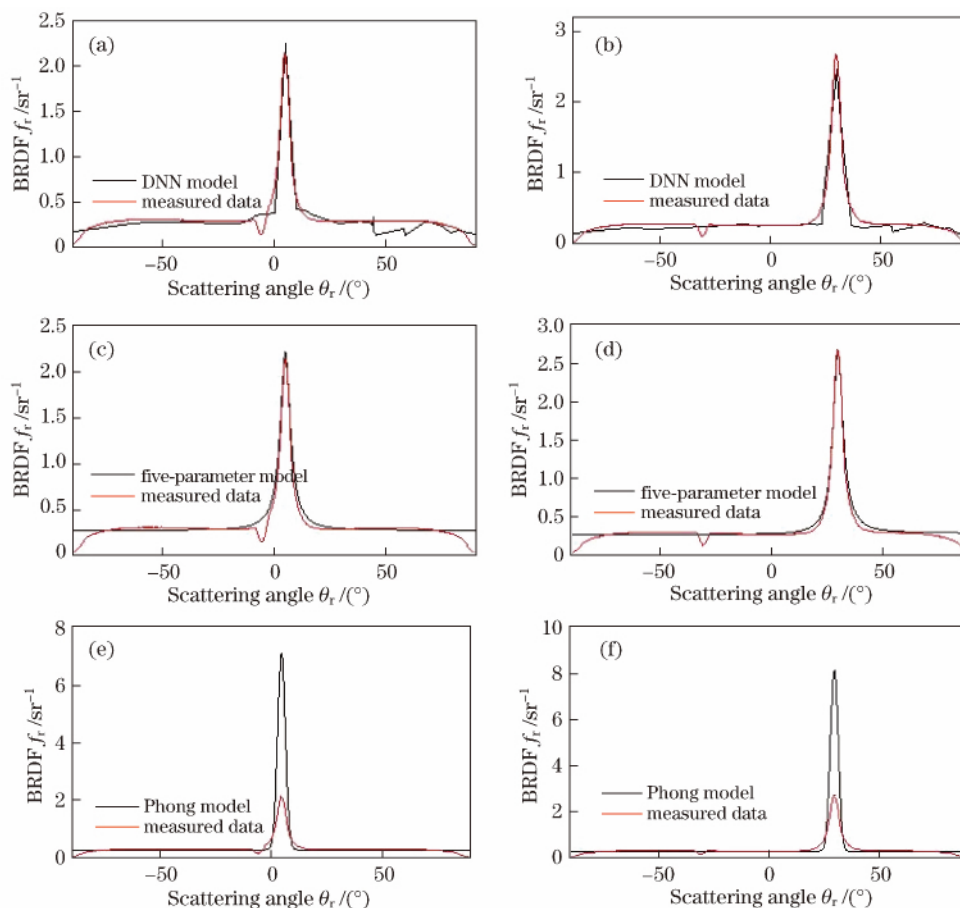


图 9 三种模型对环氧漆的拟合效果对比。深度神经网络模型: (a) $\theta_i = 5^\circ$, (b) $\theta_i = 30^\circ$;
五参数模型: (c) $\theta_i = 5^\circ$, (d) $\theta_i = 30^\circ$; Phong 模型: (e) $\theta_i = 5^\circ$, (f) $\theta_i = 30^\circ$

Fig. 9 Comparison of fitting effects of three models for epoxy paint. DNN model: (a) $\theta_i = 5^\circ$, (b) $\theta_i = 30^\circ$;
five-parameter model: (c) $\theta_i = 5^\circ$, (d) $\theta_i = 30^\circ$; Phong model: (e) $\theta_i = 5^\circ$, (f) $\theta_i = 30^\circ$

通过三种模型的拟合图像可以看出,对于漫反射特性较强的材质,深度神经网络模型和五参数模型的拟合效果均较好,其中深度神经网络的全数据拟合误差为 0.0027,五参数模型的拟合误差为 0.0495,而 Phong 模型的拟合误差为 0.7692。

下面比较三种模型对镜面反射特性较强材质的拟合效果,使用银色聚酰亚胺薄膜的测量数据进行拟合,给出入射天顶角为 $5^\circ, 30^\circ$,观测方位角为 0° 时的拟合图像,如图 10 所示。

通过拟合图像的对比可以看出,深度神经网络模型和 Phong 模型的拟合效果较好,全数据拟合误差分别为 0.0155 和 0.0528,而五参数模型由于对 BRDF 值突变过程的描述不太理想,导致拟合误差增大,为 0.1142。

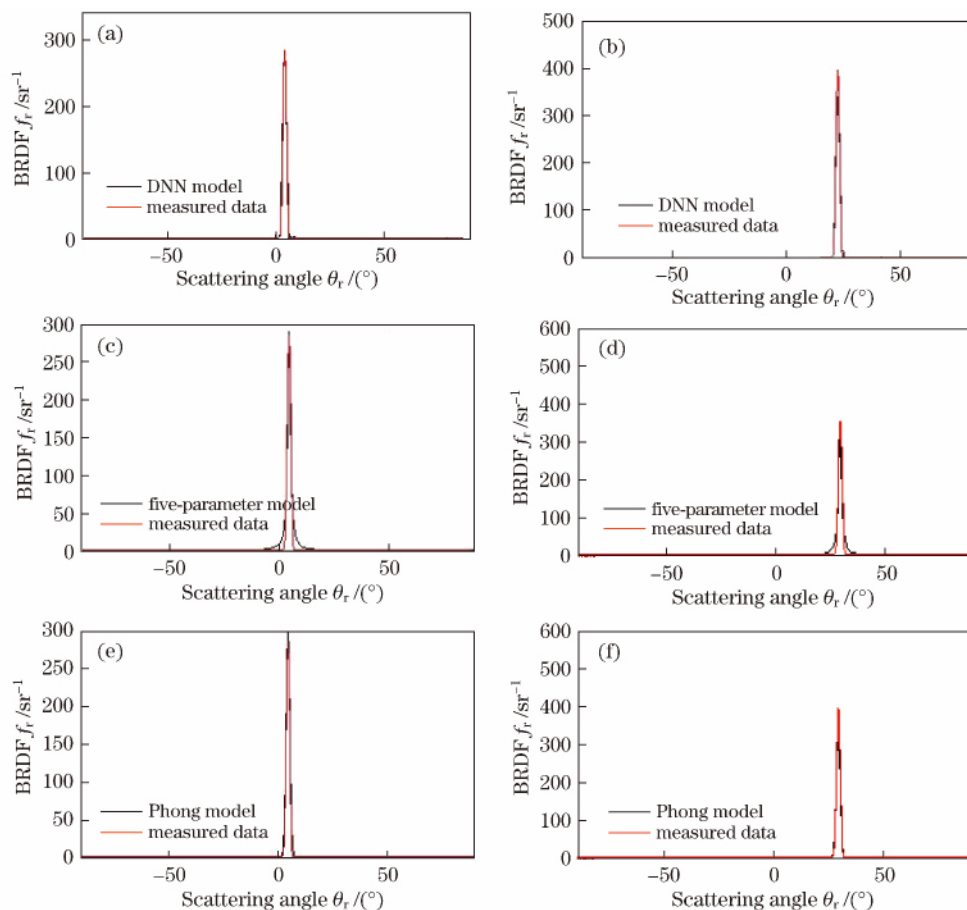


图 10 三种模型对聚酰亚胺薄膜的拟合效果对比。深度神经网络模型：(a) $\theta_i = 5^\circ$ ，(b) $\theta_i = 30^\circ$ ；

五参数模型：(c) $\theta_i = 5^\circ$ ，(d) $\theta_i = 30^\circ$ ；Phong 模型：(e) $\theta_i = 5^\circ$ ，(f) $\theta_i = 30^\circ$

Fig. 10 Comparison of fitting effects of three models for polyimide film. DNN model : (a) $\theta_i = 5^\circ$, (b) $\theta_i = 30^\circ$;

five-parameter model : (c) $\theta_i = 5^\circ$, (d) $\theta_i = 30^\circ$; Phong model : (e) $\theta_i = 5^\circ$, (f) $\theta_i = 30^\circ$

比较三种模型对两类不同特性材质的描述效果可以看出不同经验模型对材质特性描述的局限性,而深度神经网络对于两类特性材质的描述均有良好的效果,证明深度神经网络模型具有相对于经验模型更好的适应性和准确性。

4 结 论

基于深度神经网络,使用多种空间目标材质样片 BRDF 数据进行建模,建模结果显示,对于不同特性的空间目标材质,深度神经网络模型的拟合效果良好,可以准确地描述材质的光学散射特性;该模型对不同规模的训练样本学习后均能得到良好的 BRDF 值预测能力,证明其稳健性良好;使用两类不同特性材质数据,选择五参数模型和 Phong 模型进行拟合效果对照,结果显示深度神经网络模型的拟合效果优于经验模型,证明该模型相对于经验模型有更好的材质特性描述能力,具有广阔的应用前景。

参 考 文 献

- [1] Yuan Yan, Sun Chengming, Zhang Xiubao. Measuring and modeling the spectral bidirectional reflection distribution function of space target's surface material[J]. Acta Physica Sinica, 2010, 59(3): 2097-2103.
袁艳, 孙成明, 张修宝. 空间目标表面材料光谱双向反射分布函数测量与建模[J]. 物理学报, 2010, 59(3): 2097-2103.
- [2] Xu Can, Zhang Yasheng, Li Peng, *et al.* Calculation of optical cross section areas of spatial objects based on OpenGL picking technique[J]. Acta Optica Sinica, 2017, 37(7): 0720001.
徐灿, 张雅声, 李鹏, 等. 基于 OpenGL 拾取技术的空间目标 OCS 计算方法[J]. 光学学报, 2017, 37(7): 0720001.

- [3] Gou Ruixin, Du Xiaoping, Liu Hao. Advances in attitude inversion of space object based on photometric data[J]. Laser & Optoelectronics Progress, 2016, 53(10): 100002.
苟瑞新, 杜小平, 刘浩. 光度数据反演空间目标姿态的研究进展[J]. 激光与光电子学进展, 2016, 53(10): 100002.
- [4] Han Yi, Sun Huayan. Advances in space target optical scattering character research[J]. Infrared and Laser Engineering, 2013, 42(3): 758-766.
韩意, 孙华燕. 空间目标光学散射特性研究进展[J]. 红外与激光工程, 2013, 42(3): 758-766.
- [5] Torrance K E, Sparrow E M. Theory for off-specular reflection from roughened surfaces[J]. Journal of the Optical Society of America, 1967, 57(9): 1105-1114.
- [6] Maxwell J R, Beard J, Weiner S, *et al.* Bidirectional reflectance model validation and utilization[R]. Ann Arbor: Environmental Research Institute of Michigan, 1973: 10-35.
- [7] Phong B T. Illumination for computer generated pictures[J]. Communications of the ACM, 1975, 18(6): 311-317.
- [8] Wu Zhensen, Xie Donghui, Xie Pinhua, *et al.* Modeling reflectance function from rough surface and algorithms[J]. Acta Optica Sinica, 2002, 22(8): 897-901.
吴振森, 谢东辉, 谢品华, 等. 粗糙表面激光散射统计建模的遗传算法[J]. 光学学报, 2002, 22(8): 897-901.
- [9] Minnaert M. The reciprocity principle in lunar photometry[J]. Astrophysical Journal, 1941, 93(3): 403-410.
- [10] 吴岸城. 神经网络与深度学习[M]. 北京: 电子工业出版社, 2016: 81-87.
- [11] 李玉鑑, 张婷. 深度学习导论及案例分析[M]. 北京: 机械工业出版社, 2016: 4-8.